

# The Numapresse project

## Tools & Methods

Impresso — July 5th 2018

Pierre-Carl Langlais  
@Dorialexander  
[scoms.hypotheses.org](https://scoms.hypotheses.org)  
Alexander Doria (Wikipedia)





# Our focus: the newspaper

The project builds up on distant reading of digitized news archives (chiefly by the French National Library) using the high computing infrastructure of Humanum.

The corpora comprises several hundred thousands documents in XML (about 1,5 to) from leading French dailies and weeklies (1814-1945).

## Documents de presse numérisés en mode « OCR » du projet Europeana Newspapers

Mots-clés: Presse, gallica, Europeana Newspapers

Ce jeu de données contient les documents numériques des collections de presse traitées durant le projet européen Europeana Newspapers avec une reconnaissance du texte (OCR, *optical character recognition*).

### Sommaire

- [Contenu du jeu de données](#)
- [Contexte de production](#)
- [Formats du jeu de données](#)
- [Exemples d'utilisation](#)
- [API et jeux de données en relation](#)

### Contenu du jeu de données

Ce jeu contient la transcription réalisée par OCR d'environ 275 000 fascicules des collections de presse de Gallica traitées durant le projet Europeana Newspapers.

Tous les documents numérisés des titres suivants sont présents :

- Le Figaro
- L'Echo de Paris
- L'Univers
- La Presse
- L'Humanité
- Le Constitutionnel
- Le Petit Journal
- Le Siècle
- L'Action Française
- L'Intransigeant

### Fiche technique

Date de création ou de mise à jour :  
2015

Quantité :  
1 287 500 pages, 275 000 fascicules

Langue :  
Français

Formats :  
METS, ALTO

Licence :  
Gallica

Domaine :  
Gallica , dans le même domaine

### Télécharger

[Métadonnées \(23 Mo\)](#)

[L'Action française \(9 Go\)](#)

[L'Echo de Paris \(17 Go\)](#)

[L'Humanité \(9 Go\)](#)

[L'Intransigeant \(16 Go\)](#)

[L'Univers \(10 Go\)](#)

[La Croix \(12 Go\)](#)

[La Presse \(17 Go\)](#)

[Le Constitutionnel \(17 Go\)](#)

[Le Figaro \(21 Go\)](#)

[Le Petit Journal \(18 Go\)](#)

[Le Siècle \(21 Go\)](#)

[Le Temps \(25 Go\)](#)



## Our focus: the newspaper

In Numapresse, newspaper archives are not studied as a set of historical facts but as newspapers and as a part of a wider media ecosystem.

In practice we are bound to raise the following issues, which may not always be solved by digital methods:

- What are the leading news genre? Where do they come from and how have they evolved?
- What are the main poetic features of newspaper genres and discourses? How are the heterogeneous components (texts, data, images...) of a newspaper page articulated?
- Who is writing the newspaper? How is the newsroom organized?
- How do newspapers connect to one another? By what means do news objects travel and are reprinted and adapted across the world?

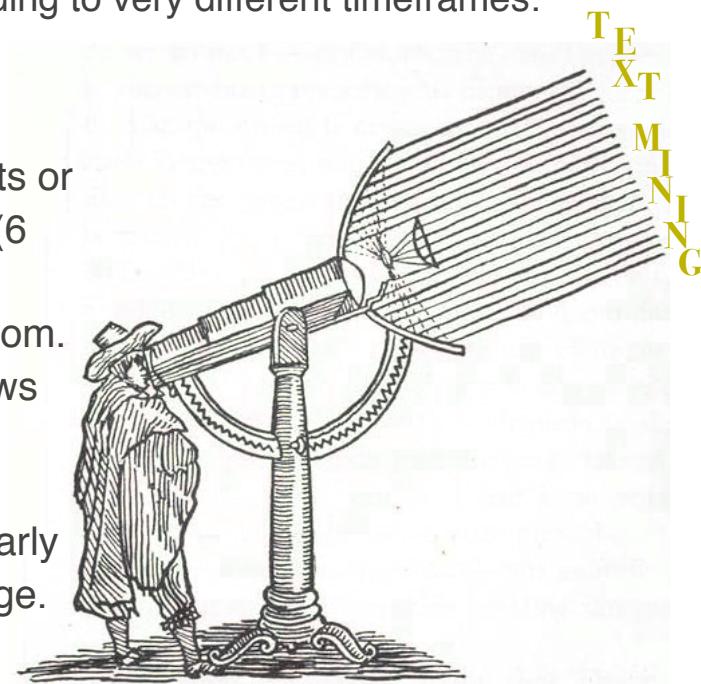


# Text mining as a adjustable lenses

The leading dailies are published continuously for a very long time (as much as 145 years for the *Journal des débats*) and cultural transformations can occur according to very different timeframes:

- Several weeks for the dissemination of a news or short term contracts (such as serial novels).
- Several months or a year to uncover some editorial experiments or to analyze the *regular* flow of reprints in the media ecosystem (6 months according to Cordell)
- Several years for the inner sociological workings of the newsroom.
- Several decades for the emergence and metamorphosis of news genre.

Clearly to deal with all these issues, we need to be able to regularly change our focus and shift between punctual and structural change.



# Zoom reading

Not only are distant and close reading constantly articulated within the project, but we usually experiment with different *distances*



# Text mining as a adjustable lenses

The XML files generated by the Library do not contain only the OCRed text but numerous contextual information that has been fundamental to integrate the multiple layers of the newspaper

- **Coordinates and persistent identifiers** of words, lignes, text blocks and images.
- **OCR confidence**
- **Size of the text and typographical layout** (bold, italic, font...).

```
- <Layout>
- <Page ACCURACY="99.68" HEIGHT="9782" ID="PAG_1" PHYSICAL_IMG_NR="1" QUALITY="OK" WIDTH="7166">
- <PrintSpace HEIGHT="8513" HPOS="230" ID="PAG_1_PrintSpace" VPOS="440" WIDTH="6356">
- <TextBlock HEIGHT="376" HPOS="2704" ID="PAG_1_TB000001" LANG="fr" STYLEREFS="TXT_1" TAGREFS="TAG_ST001" VPOS="509" WIDTH="2354">
  - <TextLine HEIGHT="376" HPOS="2704" ID="PAG_1_TL000001" STYLEREFS="TXT_1" VPOS="509" WIDTH="2354">
    <String CONTENT="LA" HEIGHT="372" HPOS="2704" ID="PAG_1_ST000001" STYLEREFS="TXT_1" VPOS="509" WC="1" WIDTH="574"/>
    <SP HPOS="3278" ID="PAG_1_SP000001" VPOS="543" WIDTH="1694"/>
    <String CONTENT="LIBERTÉ" HEIGHT="342" HPOS="4972" ID="PAG_1_ST000002" STYLEREFS="TXT_1" VPOS="543" WC="1" WIDTH="86"/>
  </TextLine>
</TextBlock>
- <TextBlock HEIGHT="60" HPOS="519" ID="PAG_1_TB000002" LANG="fr" STYLEREFS="TXT_2" VPOS="440" WIDTH="519">
  - <TextLine HEIGHT="60" HPOS="519" ID="PAG_1_TL000002" STYLEREFS="TXT_2" VPOS="440" WIDTH="519">
    <String CONTENT="Mardi" HEIGHT="52" HPOS="519" ID="PAG_1_ST000003" STYLEREFS="TXT_2" VPOS="448" WC="1" WIDTH="149"/>
    <SP HPOS="668" ID="PAG_1_SP000002" VPOS="447" WIDTH="29"/>
    <String CONTENT="1er" HEIGHT="47" HPOS="697" ID="PAG_1_ST000004" STYLEREFS="TXT_2" VPOS="447" WC="0.65" WIDTH="73"/>
    <SP HPOS="770" ID="PAG_1_SP000003" VPOS="444" WIDTH="24"/>
    <String CONTENT="mai" HEIGHT="50" HPOS="794" ID="PAG_1_ST000005" STYLEREFS="TXT_2" VPOS="444" WC="1" WIDTH="90"/>
    <SP HPOS="884" ID="PAG_1_SP000004" VPOS="440" WIDTH="24"/>
    <String CONTENT="1866" HEIGHT="51" HPOS="908" ID="PAG_1_ST000006" STYLEREFS="TXT_2" VPOS="440" WC="0.88" WIDTH="130"/>
  </TextLine>
</TextBlock>
- <TextBlock HEIGHT="52" HPOS="374" ID="PAG_1_TB000003" LANG="fr" STYLEREFS="TXT_3" VPOS="548" WIDTH="635">
  - <TextLine HEIGHT="52" HPOS="374" ID="PAG_1_TL000003" STYLEREFS="TXT_3" VPOS="548" WIDTH="635">
    <String CONTENT="papier" HEIGHT="39" HPOS="374" ID="PAG_1_ST000007" STYLEREFS="TXT_3" VPOS="561" WC="1" WIDTH="116"/>
    <SP HPOS="490" ID="PAG_1_SP000005" VPOS="560" WIDTH="19"/>
    <String CONTENT="et" HEIGHT="28" HPOS="509" ID="PAG_1_ST000008" STYLEREFS="TXT_3" VPOS="560" WC="1" WIDTH="33"/>
    <SP HPOS="542" ID="PAG_1_SP000006" VPOS="558" WIDTH="18"/>
    <String CONTENT="Tirage" HEIGHT="38" HPOS="560" ID="PAG_1_ST000009" STYLEREFS="TXT_3" VPOS="558" WC="1" WIDTH="118"/>
    <SP HPOS="678" ID="PAG_1_SP000007" VPOS="554" WIDTH="202"/>
    <String CONTENT="18" HEIGHT="33" HPOS="880" ID="PAG_1_ST000010" STYLEREFS="TXT_3" VPOS="554" WC="1" WIDTH="31"/>
    <SP HPOS="911" ID="PAG_1_SP000008" VPOS="550" WIDTH="23"/>
    <String CONTENT="fr." HEIGHT="31" HPOS="934" ID="PAG_1_ST000011" STYLEREFS="TXT_3" VPOS="550" WC="1" WIDTH="39"/>
    <SP HPOS="973" ID="PAG_1_SP000009" VPOS="548" WIDTH="27"/>
    <String CONTENT=")" HEIGHT="37" HPOS="1000" ID="PAG_1_ST000012" STYLEREFS="TXT_3" VPOS="548" WC="0.00" WIDTH="9"/>
  </TextLine>
</TextBlock>
```

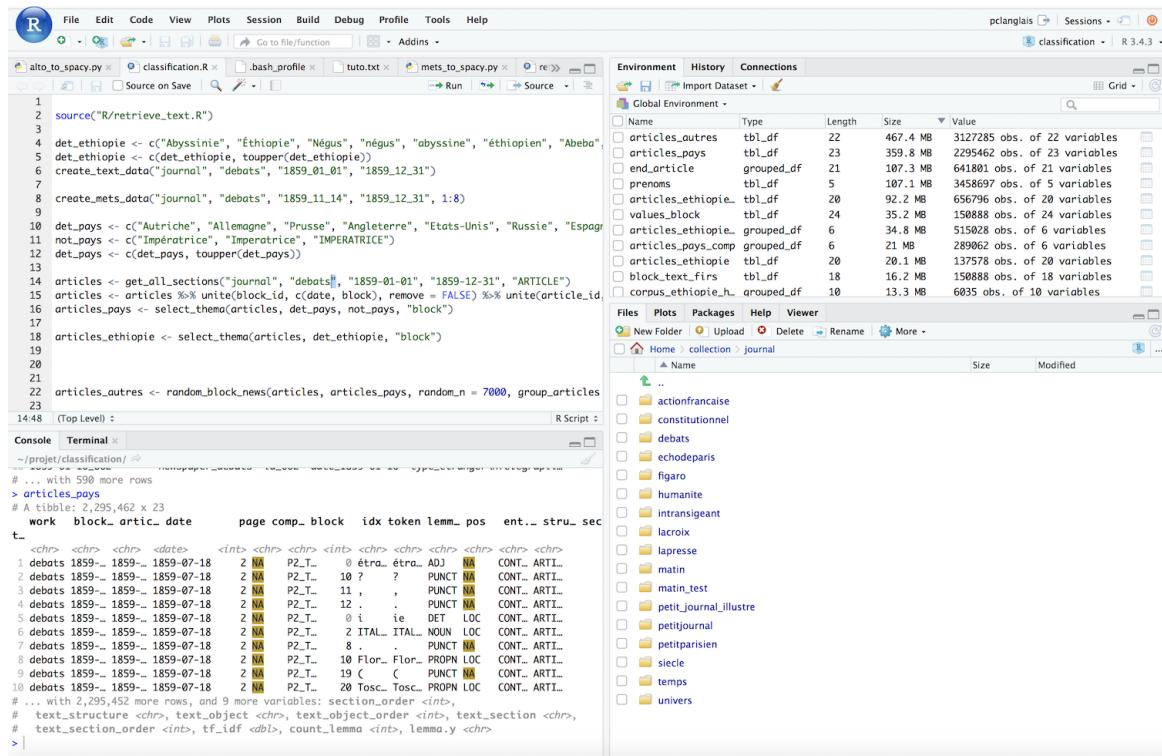


# Our method: pragmatism

- **“Whatever work”.** Not everything fits one algorithm and, in fact, not everything can be modeled. Conversely some research can only be undertook through programming and automation, such as reprint detection or genre classification..
- **Build on the past work.** Previous projects have already initiated extensive databases and/ or created precious tools (*ViralText*). We are particularly keen on reusing library data and formats in a comprehensive way.
- **Ensure collaborations.** Numapresse has been greatly stimulated by the collaborative spirit of news studies in France. Our next steps would be to produce intermediary tools formatted for the research on newspaper, that do not rely on an extensive technical knowledge.
- **Systematical application.** While small and medium scale experiments are extremely useful, we are more and more focusing on applying programs on a very long time frame (>50 years) and on comprehensive corpora.

# Our tool: Humanum super-computer

The programming interface hosted by Humanum allow us to run scripts on very big corpora and morph them into very big tables and to work collaboratively.



The screenshot shows the RStudio IDE interface. On the left, the code editor displays a script named `alto_to_spacy.py` containing R code for processing historical texts. The code involves reading files from a directory, creating a text dataset, and performing various operations like selecting sections, filtering by theme, and randomizing news articles. It also includes a section for morphological analysis using the spacy package. The console window at the bottom shows the execution of the script and some initial output. On the right, the environment pane shows a global environment with many objects and their details (length, size, value), and a file browser pane showing a directory structure for various news sources like `debats`, `echodepartis`, and `figaro`.

```
1
2 source("R/retrieve_text.R")
3
4 det_ethiopie <- c("Abysсинie", "Éthiopie", "Néгус", "негус", "abyssine", "éthiopian", "Abeba"
5 det_ethiopie <- c(det_ethiopie, toupper(det_ethiopie))
6 create_text_data("journal", "debats", "1859_01_01", "1859_12_31")
7
8 create_mets_data("journal", "debats", "1859_11_14", "1859_12_31", 1:8)
9
10 det_pays <- c("Autriche", "Allemagne", "Pруssie", "Angleterre", "Etats-Unis", "Russie", "Espagne"
11 not_pays <- c("Impératrice", "Imperatrice", "IMPERATRICE")
12 det_pays <- c(det_pays, toupper(det_pays))
13
14 articles <- get_all_sections("journal", "debats", "1859_01_01", "1859_12_31", "ARTICLE")
15 articles <- articles %>% unite(block_id, c(date, block), remove = FALSE) %>% unite(article_id,
16 articles_pays <- select_thema(articles, det_pays, not_pays, "block")
17
18 articles_ethiopie <- select_thema(articles, det_ethiopie, "block")
19
20
21 articles_outres <- random_block_news(articles, articles_pays, random_n = 7000, group_articles
22
23
14:48 (Top Level) : R Script :
Console Terminal ↗
~/project/classification/ ↗
# ... with 590 more rows
> articles_pays
# A tibble: 2,295,462 x 23
   work block_artic_date    page comp_block  idx token lemm_pos ent... stru...
   <chr> <chr> <chr> <date> <int> <chr> <int> <chr> <chr> <chr> <chr>
1 debats 1859— 1859-07-18 2 MA P2_T_ 0 étra_ étra_ ADJ MA CONT_ ARTI...
2 debats 1859— 1859-07-18 2 MA P2_T_ 10 ? ? PUNCT MA CONT_ ARTI...
3 debats 1859— 1859-07-18 2 MA P2_T_ 11 , , PUNCT MA CONT_ ARTI...
4 debats 1859— 1859-07-18 2 MA P2_T_ 12 . . PUNCT MA CONT_ ARTI...
5 debats 1859— 1859-07-18 2 MA P2_T_ 0 i ie DET LOC CONT_ ARTI...
6 debats 1859— 1859-07-18 2 MA P2_T_ 2 ITAL_ITAL_NOUN LOC CONT_ ARTI...
7 debats 1859— 1859-07-18 2 MA P2_T_ 8 . PUNCT MA CONT_ ARTI...
8 debats 1859— 1859-07-18 2 MA P2_T_ 10 Flor_Flor_PROPON LOC CONT_ ARTI...
9 debats 1859— 1859-07-18 2 MA P2_T_ 19 ( ( PUNCT MA CONT_ ARTI...
10 debats 1859— 1859-07-18 2 MA P2_T_ 20 Tosc_Tosc_PROPON LOC CONT_ ARTI...
# ... with 2,295,452 more rows, and 9 more variables: section_order <int>,
#   text_structure <chr>, text_object <chr>, text_order <int>, text_section <chr>,
#   text_section_order <int>, tf_idf <dbl>, count_lemma <int>, lemma.y <chr>
> |
```



# Our tool: Humanum super-computer

```
> matin_1926 %>% select(work, date, id_style, block_id, article_id, idx, token, lemma, pos, ent.type)
# A tibble: 13,689,656 x 10
  work    date   id_style      block_id      article...     idx token   lemma   pos   ent.
  <chr>  <date> <chr>        <chr>        <chr>      <int> <chr>   <chr>   <chr> <chr>
1 matin 1926-01-01 TXT_4 PAR_LEFT 1926-01-01_1_1_P1_TB00004 1926-01... 0 IÏÏF   IÏÏF   PROPN  ORG
2 matin 1926-01-01 TXT_4 PAR_LEFT 1926-01-01_1_1_P1_TB00004 1926-01... 5 LATEMP... LATEMP... PROPN NA
3 matin 1926-01-01 TXT_4 PAR_LEFT 1926-01-01_1_1_P1_TB00004 1926-01... 0 IÏÏF   IÏÏF   PROPN ORG
4 matin 1926-01-01 TXT_4 PAR_LEFT 1926-01-01_1_1_P1_TB00004 1926-01... 5 LATEMP... LATEMP... PROPN NA
5 matin 1926-01-01 TXT_5 PAR_BLOCK 1926-01-01_1_1_P1_TB00005 1926-01... 0 Os     Os     DET   NA
6 matin 1926-01-01 TXT_5 PAR_BLOCK 1926-01-01_1_1_P1_TB00005 1926-01... 3 balles balle NOUN  NA
7 matin 1926-01-01 TXT_5 PAR_BLOCK 1926-01-01_1_1_P1_TB00005 1926-01... 10 strenom... strenom... ADJ   NA
8 matin 1926-01-01 TXT_5 PAR_BLOCK 1926-01-01_1_1_P1_TB00005 1926-01... 19 msteorom... msteorom... NOUN  NA
9 matin 1926-01-01 TXT_5 PAR_BLOCK 1926-01-01_1_1_P1_TB00005 1926-01... 33 »       »       PUNCT NA
10 matin 1926-01-01 TXT_5 PAR_BLOCK 1926-01-01_1_1_P1_TB00005 1926-01... 35 i       ie     ADP   NA
# ... with 13,689,646 more rows
```

R text mining process preserve the complexities of the original text. Each word is a line in the table, that contain all the informations included in the digitized archives and add new ones (lemma, syntax analysis, named entities...) generated by Spacy.



# Plan

An introduction in five parts

- Classify the newspaper : making automated recognition of newspaper genre and forms.
- Toward a poetic analysis of news images : tracking aesthetic mutations through *deep learning*.
- Reconstruction of editorial structures.
- Mapping news circulation.
- The Numapresse database

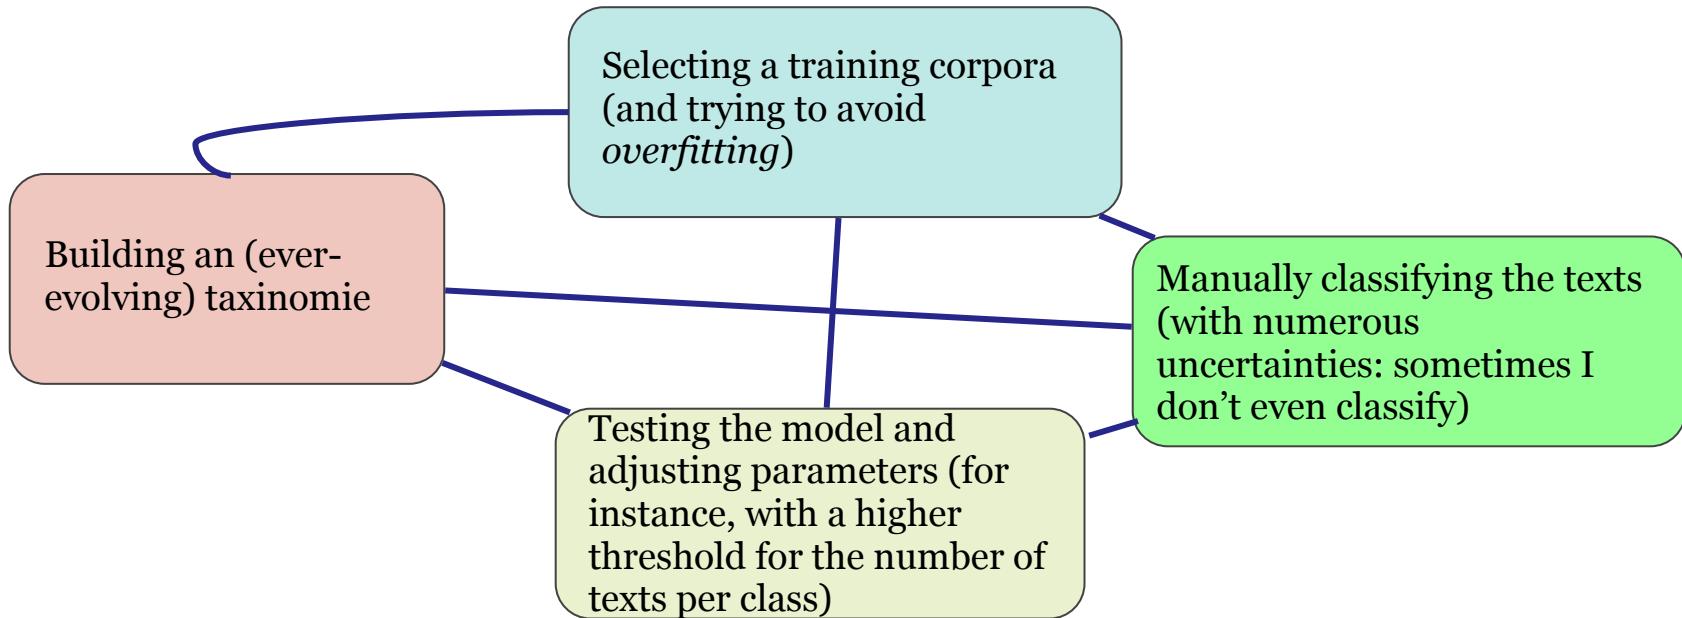
# **1. Classify the newspaper**

**Rules and grammar of automated recognition of  
newspaper genre and forms.**



# The principles of classification

A four-step process (with a lot of recursions)





# The principles of classification

Un événement imprévu vient de mettre en émoi toute la ville d' Ussel , un des chefs-lieux d' arrondissement de la Corrèze . M. Mignon , banquier de cette vn) , a disparu subitement le samedi 23 de ce mois , à quatre heures et demie du matin ; il est sorti de son domicile armé d' un fusil , et n' est pas rentré de toute ta journée . Vers le soir , on s' est enquisde sa on a été vainement le chercher à Saint - Exu- pery , à Saint - Ange ! et ailleurs . La justice a fait pen- dant la nuit une descente à son domicile et a posé les N scellés . Dimanche dernier , 24 janvier , cette disparition faisait le sujet de toutes les conversations les uns , et c est le plus grand nombre , pensent que M. Mignonc s' est suicidé ; les autres , qu' il a passé à l' étranger . Ott . l' a cherché dans les champs et te long des rivières , mais on n' est parvenu jusqu' à présent à découvrir aucune trace . On a remarqué que son bureau était /"/ très en ordre tout y était étiqueté . On a trouvé dans des sacs une quantité d' enets bien arrangés et envirom une dtzaine de mille francs en or et en argent . Som départ a été , à ce qu' on assure , sans préparatifs point de sacoches , pas de cheval ni de voiture . Voi ) & ` tout ce que l' on sait actuellement . Encore qnehmes . jours , et ce mystère sera peut-être expliqué . On écrit de Luçon ( Vendée ) , le 27 janvier Un ouragan épouvantable , qui a eu lieu dans 1~ mut du 25 au 26 de ce mois , a démolí une partie d & la voûte de notre belle et antique cathédrale , qui avait depuis bien des siècles résisté aux terribles coups de vent de sud-ouest . Le magnifique jeu s' est trouvé abtmé dans cette chute , ainsi les belles sculptures en bois qui le décorent . Le vent a été si violent , que le coq qui surmontait ta ° Hèche , et qui devait peser au moins de 25 à 30 a été enlevé et jeté à plus de 300 mètre : . Le drapeau tricolore en tête , qui se trouvait aux basses galeries de la nèche depuis la révolution de Juillet , et qui était maintenu par trois barres de fer dont chacune avait au moins 12. ou 15 centimètres de tour , a été arraché et est allé tomber à plus de 300 ' mètres dans la cour d' un habitant , qui a . été fort étonné de trouver chez lui cet étandard national . Heureusement il n' y avait alors personne dans car autrement , que de malheurs de plus à On estime à 40,000 ou 50,000 fr . au moins causé par cet ouragan

A genre is marked by the use of specific words (here, a *fait divers* of 1844)



# The principles of classification

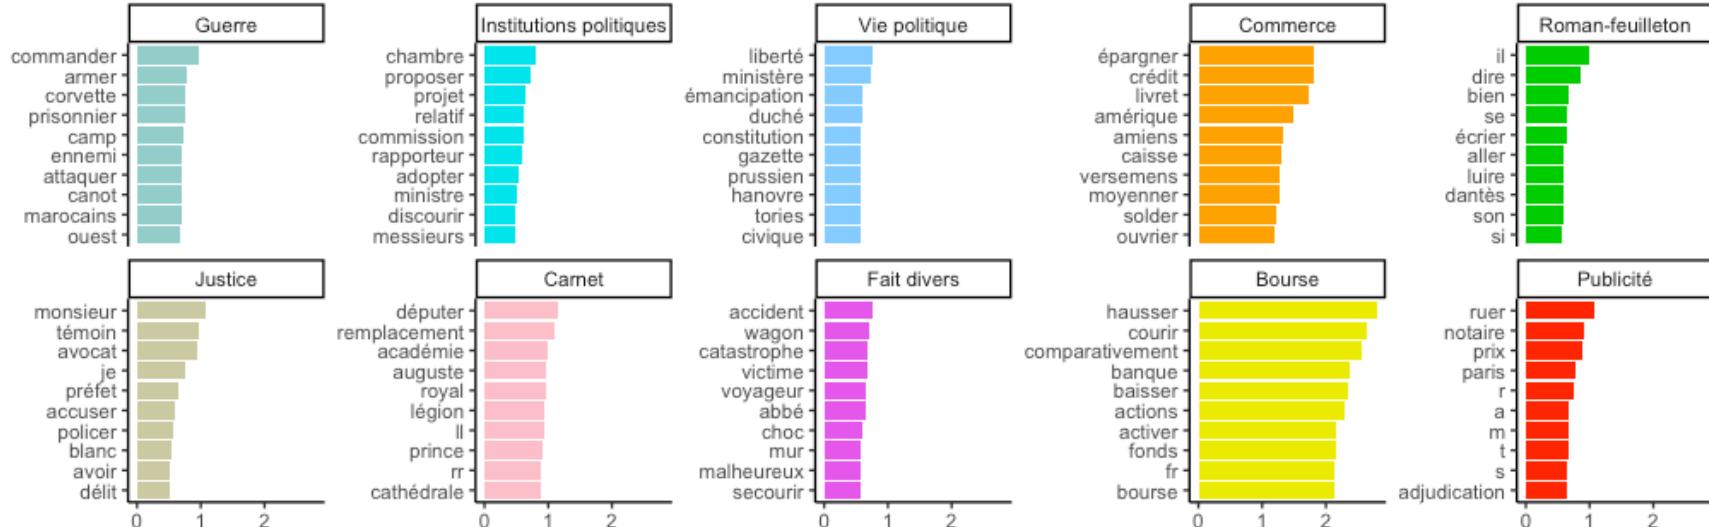
Currently, two models have been trained using supervised SVM.

- A « 1835-1855 » model, from 10 annotated issues of the *Journal des débats*. It recognizes 10 different genres..
- A « 1920-1940 » model from 20 annotated issues of *Le Petit Journal*, *L'Intransigeant*, *Le Matin* and *Le Petit Parisien*. It recognizes 20 different genres.

Later on, models will be implemented for every 20-30 years period of the history of the French daily press, as well as specialized models for some corpora (for instance, news magazine).



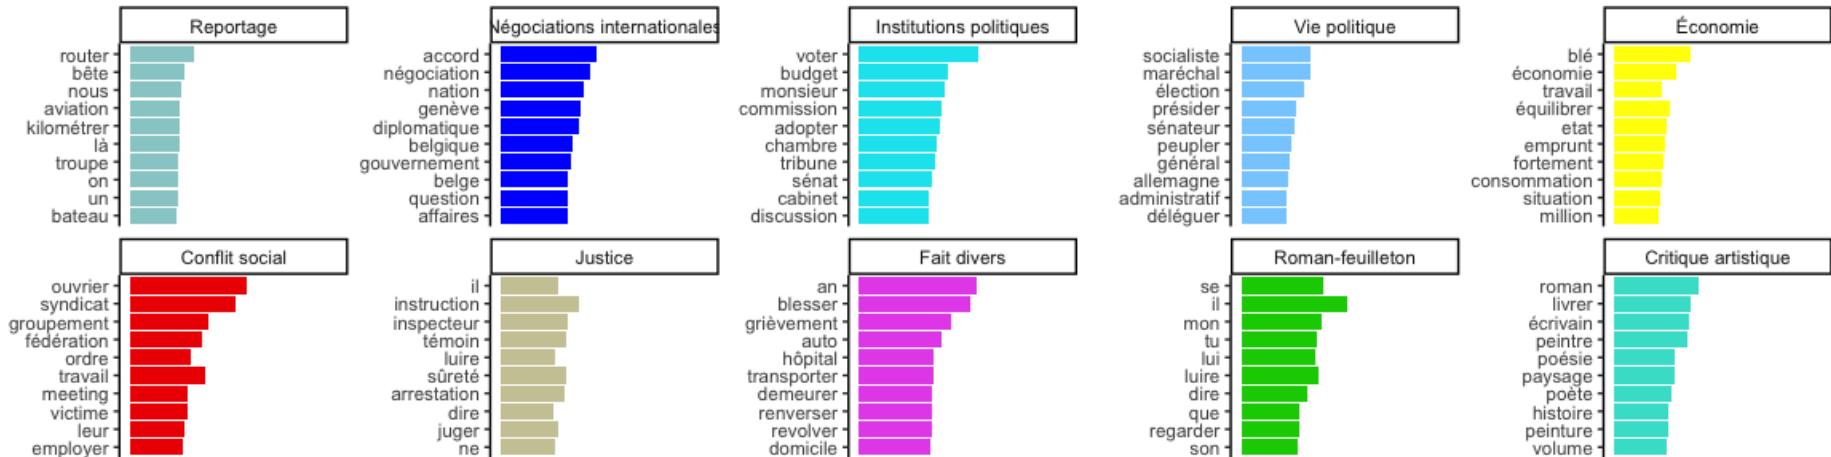
# 1835-1855 model



Models contain a “lexical sketch” of every genre, from the words that characterize them the most.



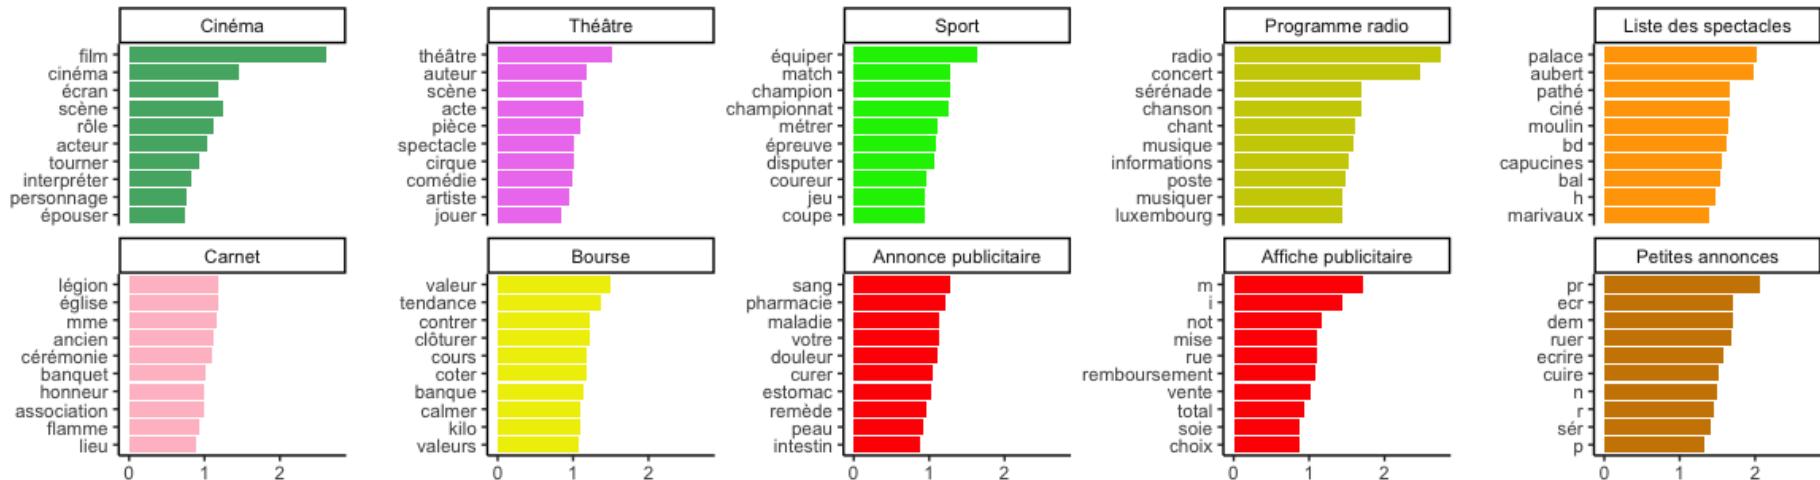
# 1835-1855 model



Models contain a “lexical sketch” of every genre, from the words that characterize them the most.

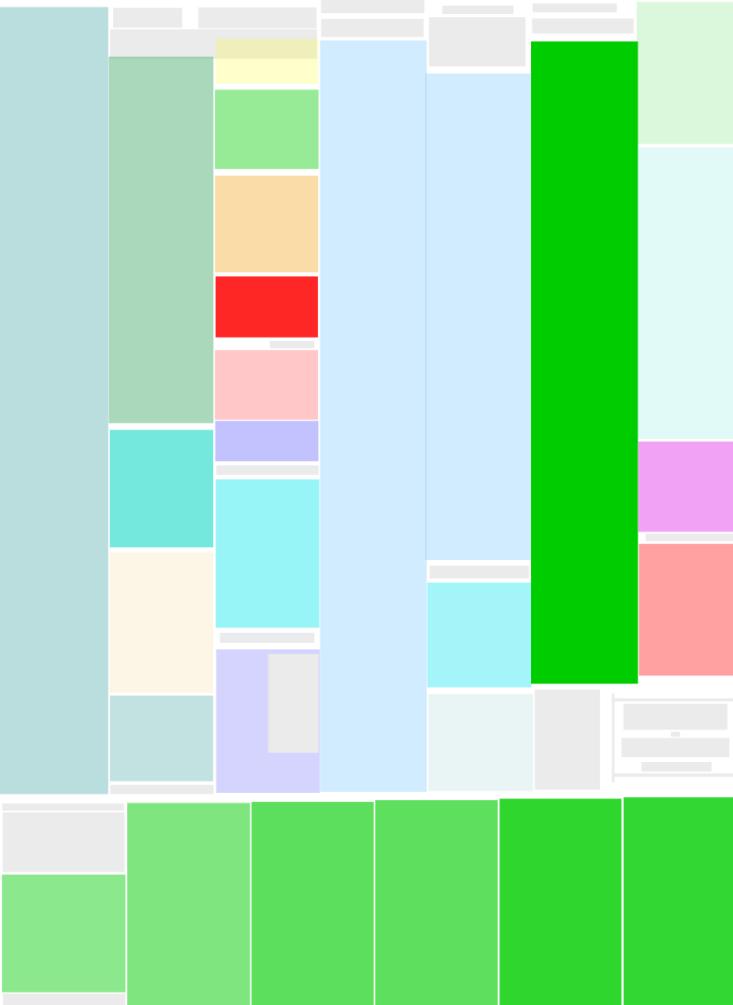


# 1835-1855 model

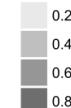


Models contain a “lexical sketch” of every genre, from the words that characterize them the most.





probability



genre\_predicted



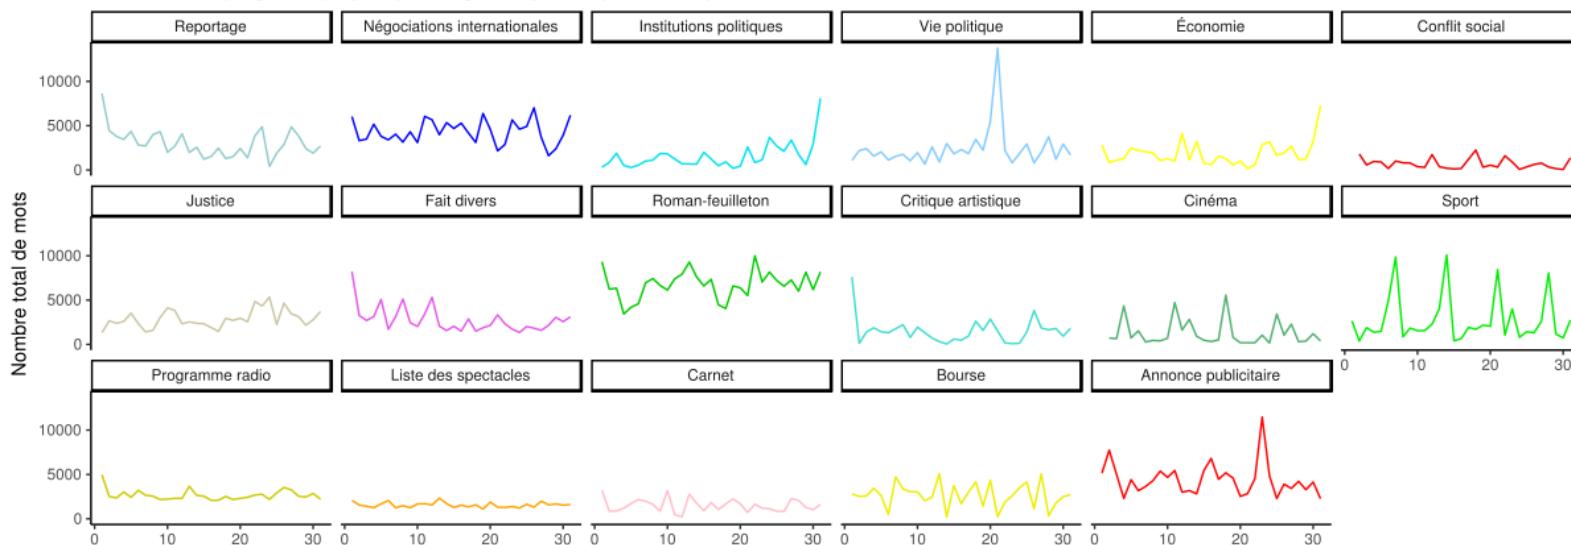




# Zooming out the genres

Classification des genres du Petit Parisien en octobre 1935

Nombre de mots par genre et par jours pour les genres ayant une probabilité supérieure à 40%



Although imperfects, models still allows to observe genre evolutions on a longer time frame, and to identify structural tendencies and punctual breaks.

# Zooming out the genres



Although imperfect, models still allow to observe genre evolutions on a longer time frame, and to identify structural tendencies and punctual breaks.

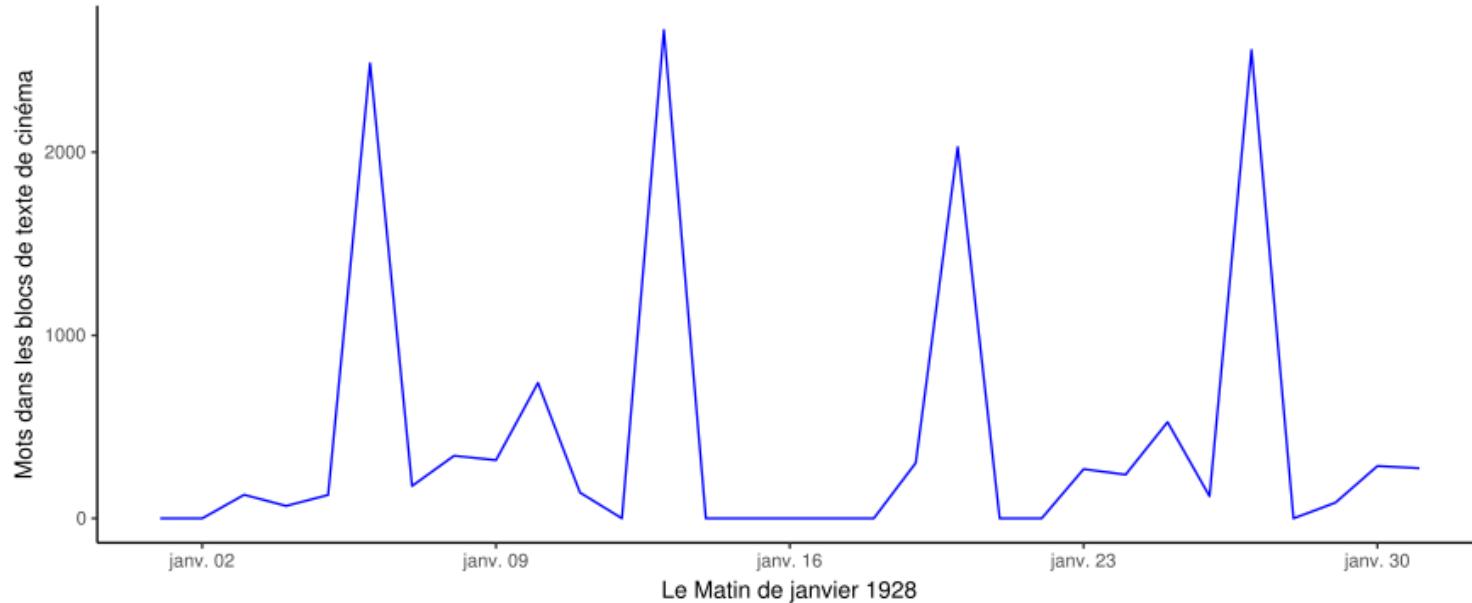
# Zooming out the genres



Although imperfects, models still allows to observe genre evolutions on a longer time frame, and to identify structural tendencies and punctual breaks.



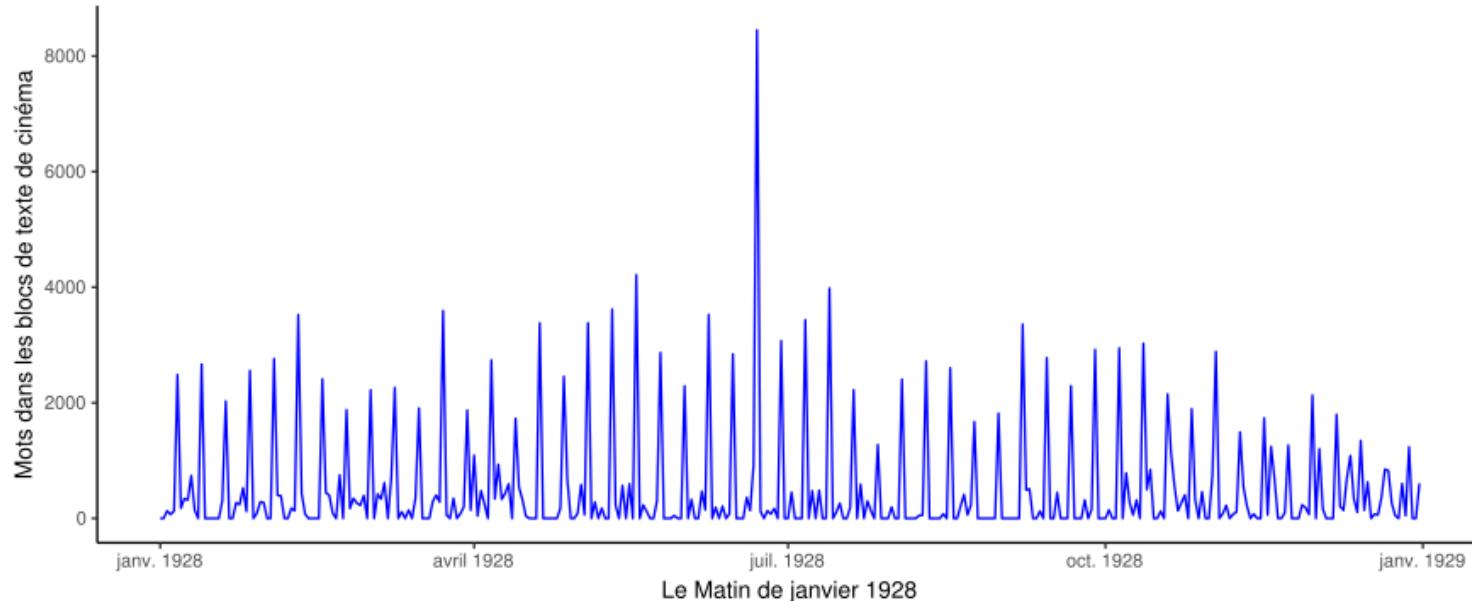
# Zooming out the genres



The model highlights the weekly rhythm of movie critics in January 1928, caused by the publication of a supplement on Friday.



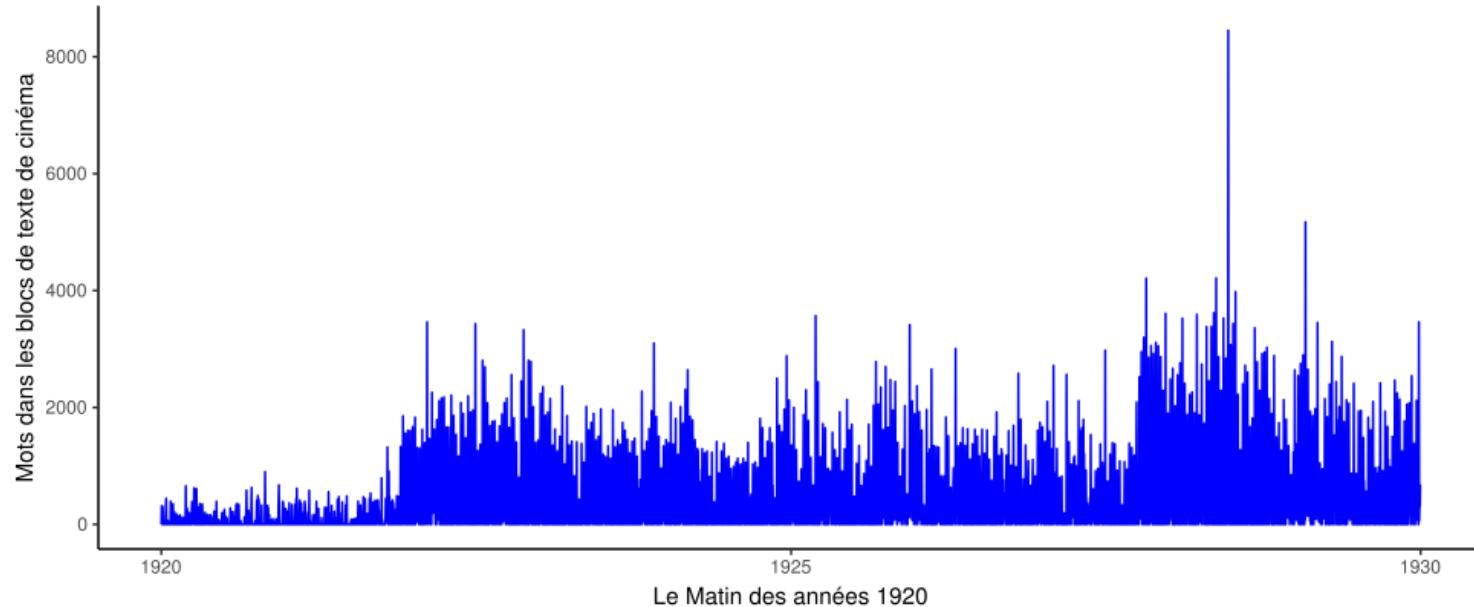
# Zooming out the genres



This cycle persists the whole year, with occasional variations of the length of the Friday supplement.



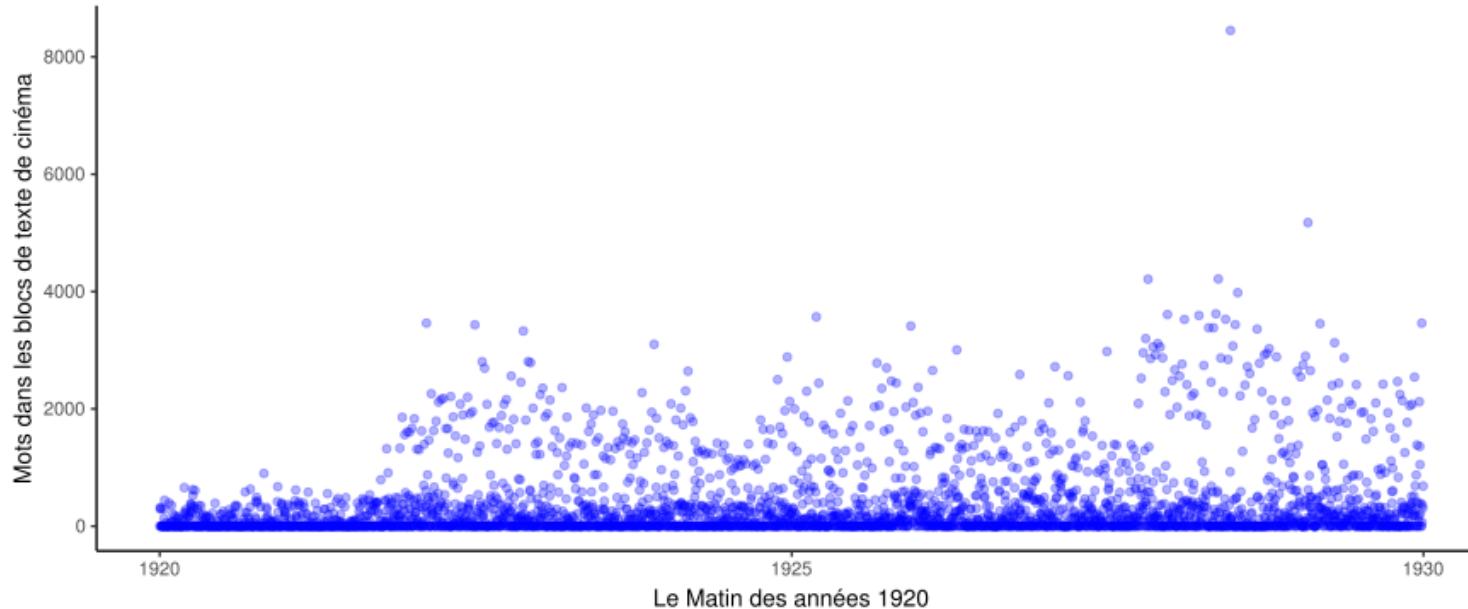
# Zooming out the genres



The weekly rhythm is itself part of a general growth in movie coverage across the 1920s



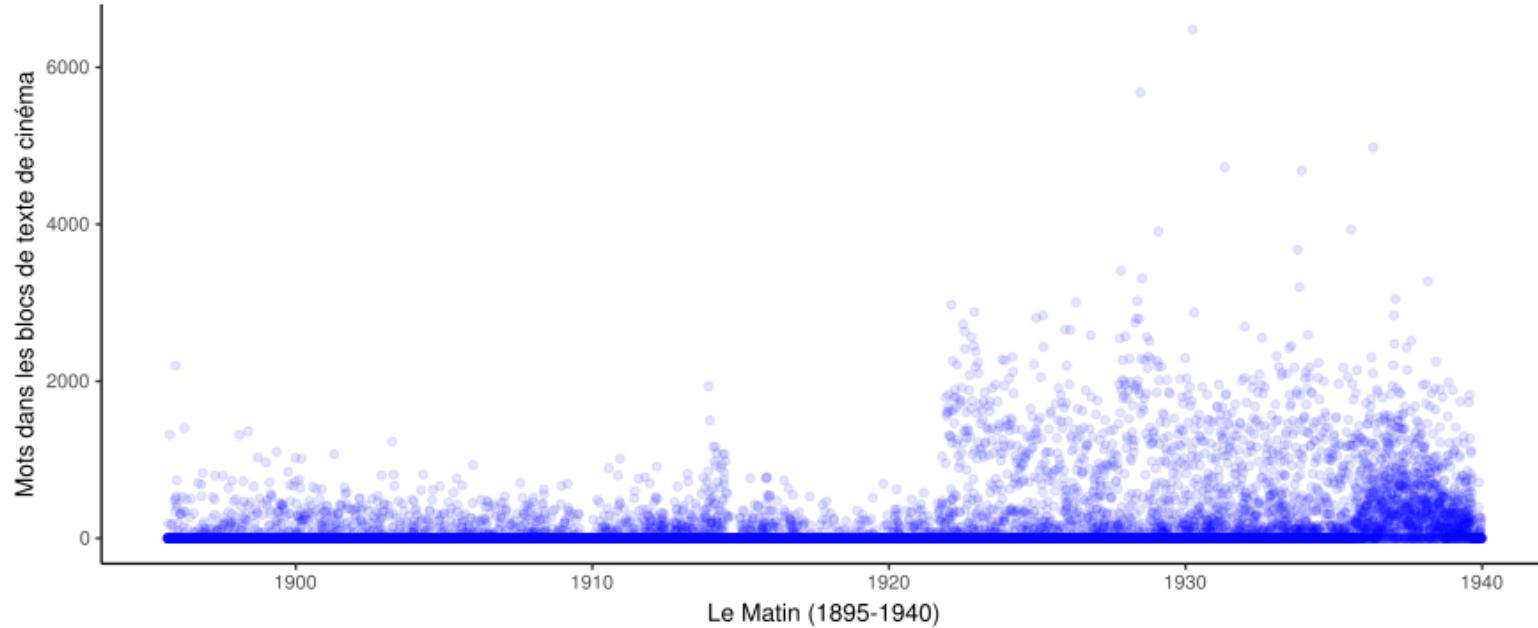
# Zooming out the genres



The weekly rhythm is itself part of a general growth in movie coverage across the 1920s



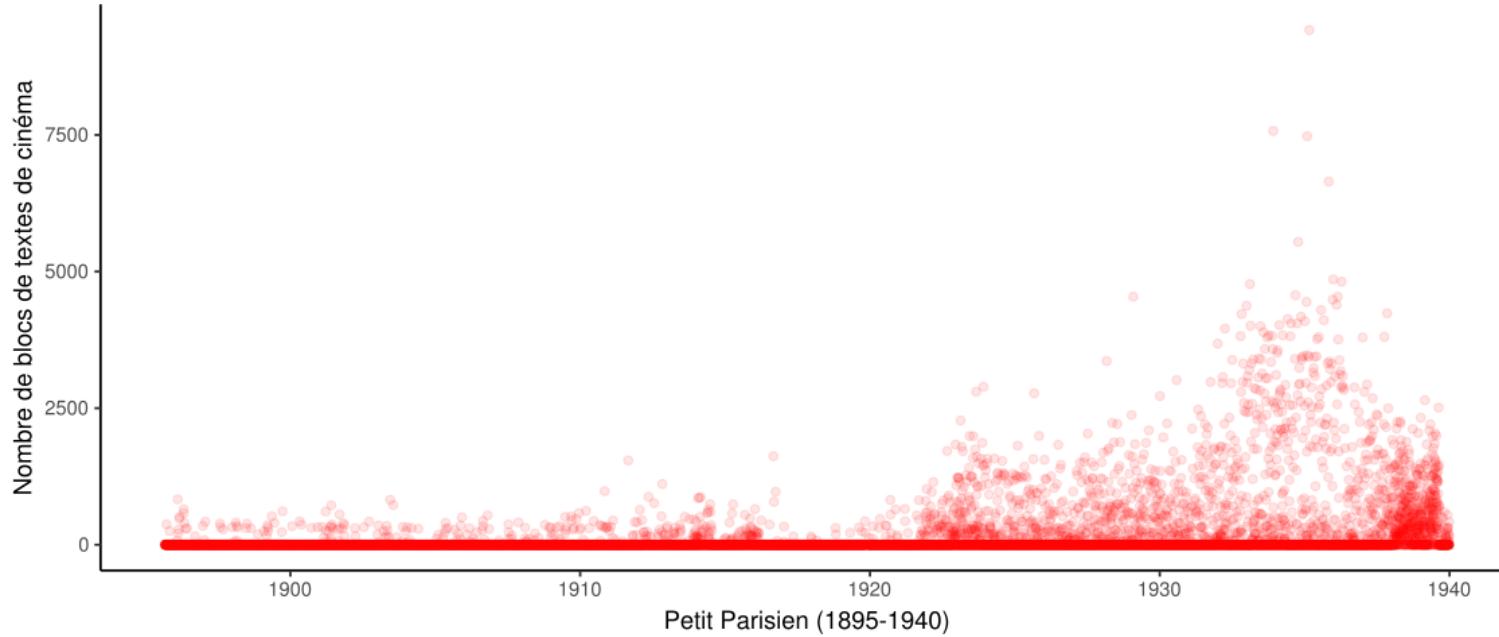
# Zooming out the genres



...and across the first half of the 20th century, after a momentary gap during WWI



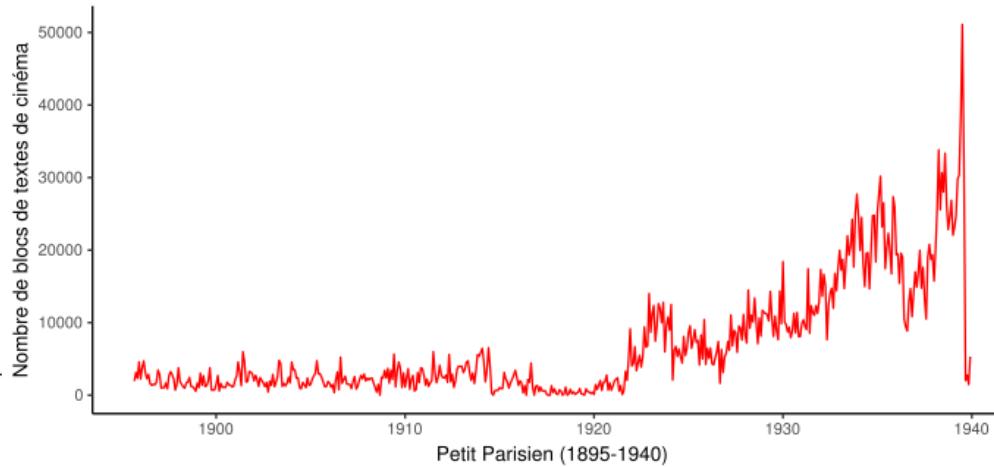
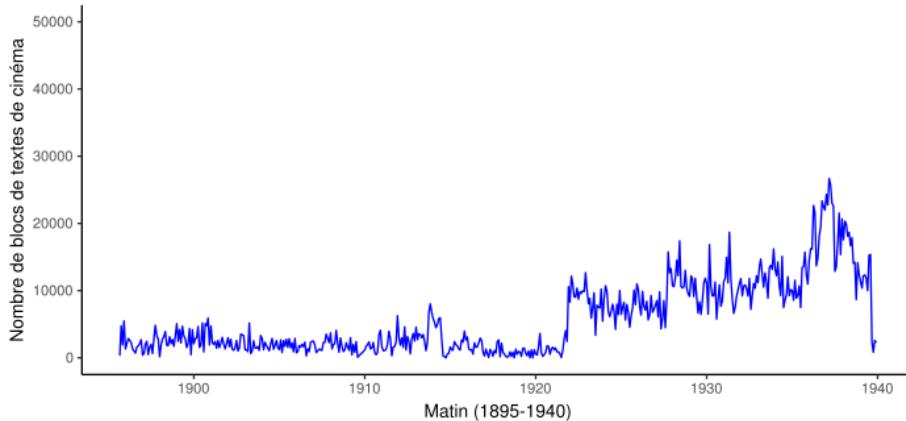
# Zooming out the genres



The *Petit Parisien* is marked by a somewhat similar evolution, although, movie coverage extends more dramatically by the end of the 1930s.



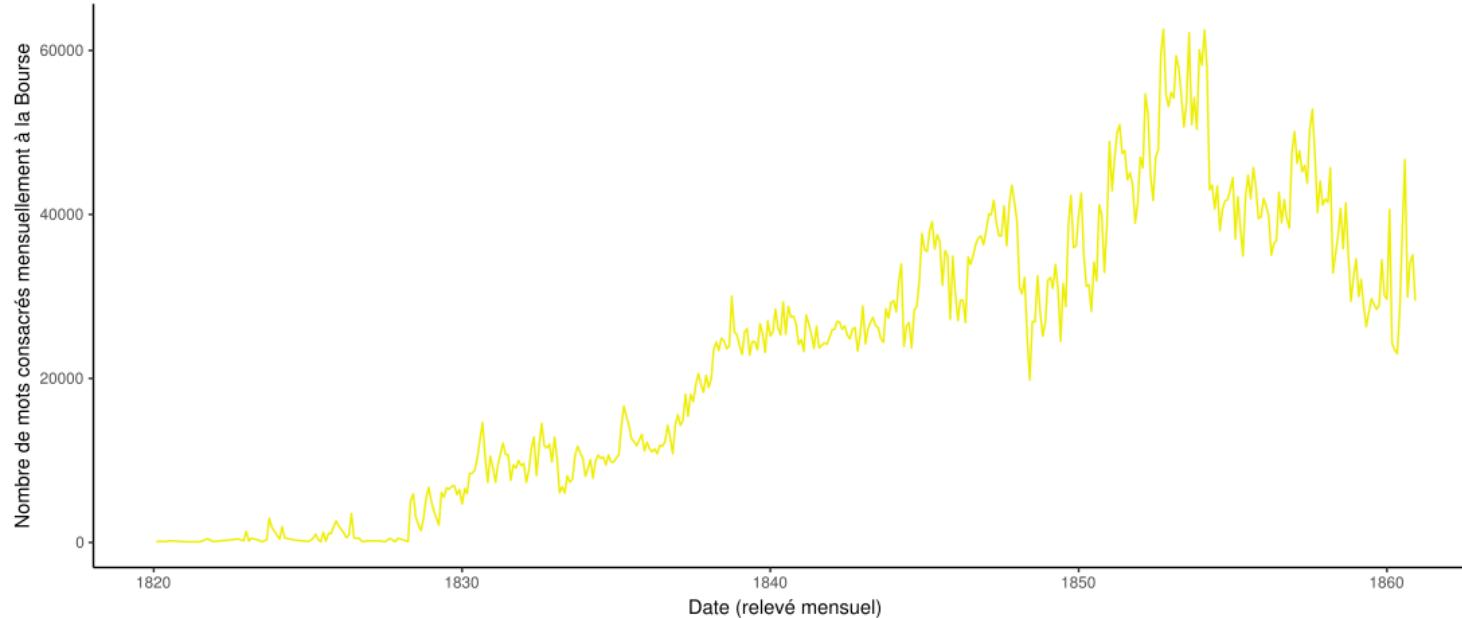
# Zooming out the genres



The *Petit Parisien* is marked by a somewhat similar evolution, although, movie coverage extends more dramatically by the end of the 1930s.



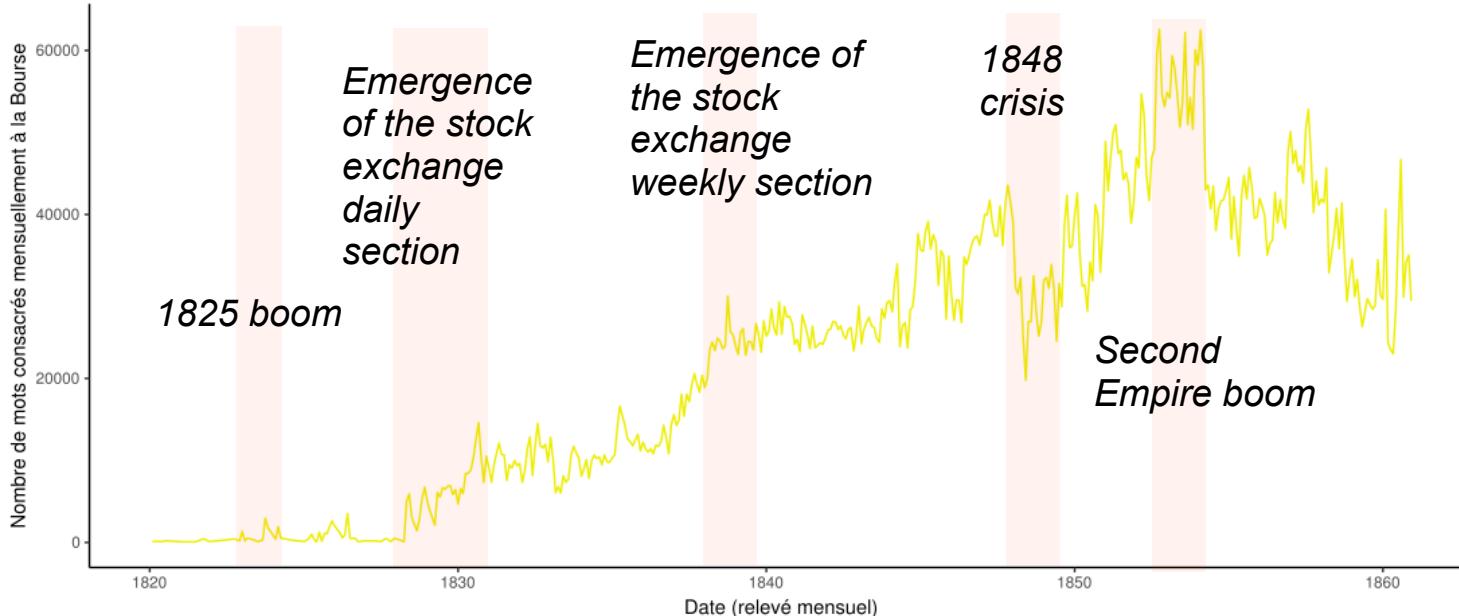
# Zooming out the genres



WWI is an exceptional factor, but genre evolution is frequently affected by outward historical events, such as economic crisis and booms with the stock section from 1820 to 1870

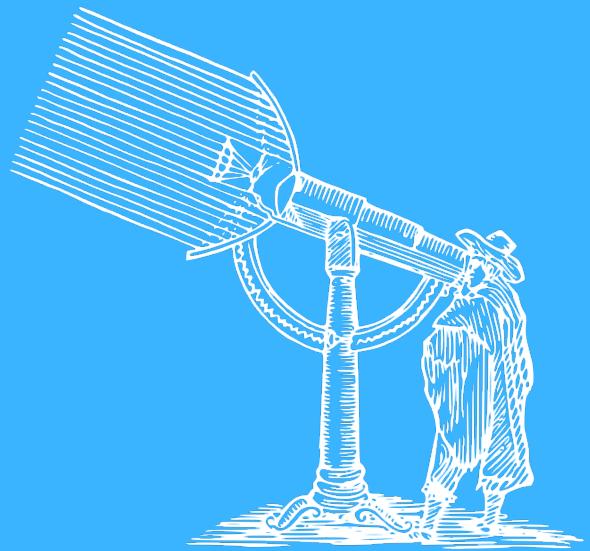


# Zooming out the genres



WWI is an exceptional factor, but genre evolution is frequently linked to outward historical events, such as economic crisis and booms with the stock section from 1820 to 1870

# What is the use of classification?





# Generate corpora *on-demand*

## Écritures du sport

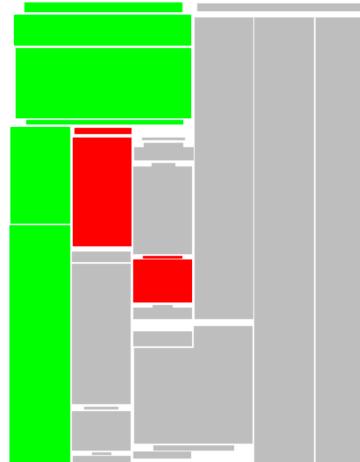
Le Matin du 1912-03-18, article n°78, page n°5



- lundi jsj3ox»£JJF

t % Les demi-finales du championnat de France de football rugby 3 FOIMTS COMTRE CE MATCH MÉMORABLE  
DURA 120 MINUTES

n ne fallut pas moins de deux mi-temps ! de 10 minutes chacune, de deux- prolongations, chacune de 20 minutes, pour que le Club de France battît le Stade Bordelais, au cours d'une partie mémorable et quelque peu angoissante pour les partisans des deux équipes. Cette partie prenra date dans l'histoire du football français, et l'on dira plus tard : Vous rappelez- vous ? C'était l'année où le Racing et Bordeaux firent deux prolongations. Car il est rare de voir une demi-finale aussi ardemment disputée que le fut celle d'hier. Les- deux équipes se présentèrent ainsi à Colombes, où vingt mille spectateurs se pressaient autour du terrain de jeu : Tacino Club : Lagarigues ; André, Lane, Burgui et Failliot : Cooper et iqueri ; Monniot, Fonsèque, Guillemin, Combemale, Bellen'ger, t erou. Vives et Decamps. Stade Bordelais : Tachoirès : Bruneau, Garré, Soulau et Piscard : Morgan et Chevalier : iWonner. Bona. /"/ de Beyssac. L- euvieille, Blanchard, Boyau, Sainte-Marie et Apolline. Griffiths, blessé, assistait au match en spectateur et Cooper le remplaçait dans l'équipé du. Racing : par contre G arrêt t. rétablî, avait repris sa place parmi les Borde- Jais. Par l'absence et la présence de ces 'deux /"/ hommes, l'équilibre de la partie faillit être rompu au profit du Stade Bordelais qui domina nettement son adversaire pendant la première mi-temps, au moment où le Racing jouait avec le vent qui- souffrait violement. Le Stade utilisait assez brillamment ses sorties de mêlée, tandis que Cooper mettait de la lenteur à profiter des occasions où le ballon sortait vers lui.



[Consulter la page sur Gallica](#)

An experimental extraction based on genre classification : every sports article in the *matin* in 1912.



# Generate corpora *on-demand*

## Écritures du cirque

Le Petit Parisien du 1943-01-09, article n°69 (page n°4)

### y <. >. « Importantes décisions à la F. B. Sur le ring du Cirque d'Hiver Les Bayonnais ne seront pas à la se M... Cm. r demand face aux avants staaistes j e France des poids mouche P<r k- o. à la 10 'reprise !

Notre dernier match de championnat entre l'Avirea Rayonnai », s nn \* dit l\* «- rmWnatian al André Verfer qui dirige le rugby an S lad \* Français. remonte à 1031. N\*us avions réngai le match mnl en face de ce

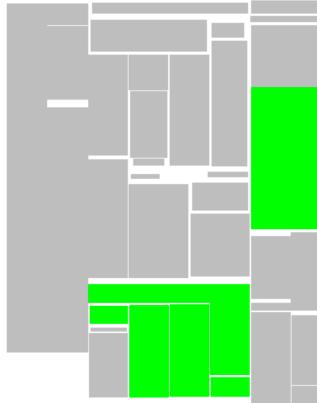
fameux Aviron qui Tenait de battre le Stade Toulicu » i\*. Alors jmtMisi ne pan réaliser dimanche un « ipleit dn intmr( « re ? Ft André Verger lions précisé qu \* l'équipe dn Stade Français c\*+t m > mesure Ae < /" adaptar an jeu allant et mobile des Rayonnais : it l'a prenre en battant le C + A. S. C\*, par a \* Far aillett\*, le \* éch < \* qui nota \* Tienent de la rét \* basque no nc apprenant que Celhny, grand ntriquen d'oinj jouera au centre aux roé » de Danger, le meilleur attaquant de l'heure. Zabalarta jouer » arrière. Il a bal en à la mélée. Alvarez à l'ouverture, et neuf pressentions ISTI J < t « mainte » permuat ion > en courre de Mali il reste à savoir si tee Bayounato ne aeroat pas doménis par lea avants d \* Stade Français qrls ■■■■■ raison, prétend posséder la meilleure troisième ligne du club avec Blond, Henry et Pésler. • Jild dehors de ee- mateb d'envergure, le » trois autres rencontres complynt également pour lea quarts dp fiai ale dn championnat de France « ont : Stade A. S. G : Toari\*, le Rniran- I., ■■■■■ Métro à Folters t Biarriti- l'ognac à Bayonne. ■■■■■ M, L-

D'importe » dérisions ont été prises hier soir par le comité directeur i dé la F. F. B. En voici l'essentiel : Le 'défi de Besneux à MonzraZ pour le titre de champion de zone occupé, poids mi-lourds, est accepté. Suppression des champions de zone à partir du 15 février, les champions des deux zones devant se rencontrer dans un démlL de trois mois pour le titre de champion de France. Le boxeur Médina rta proclamé champion de France poids mouche. La Fédération accordera des subventions aux olubs pour leurs professeurs à condition que cet professeurs soient diplômés de la F. N. E. Organisation, directe par lu Féde ration de toute \* les compétitions amateurs. Création d'utile caisse autonome pour aider- les Amateurs. 10 % des bons pour chaussures, gants et équipements seront remis aux prisonniers par l'intermédiaire des clubs.

CM OS . I ROGER Mit H FI.OT B era « ppasé au champion de Belgique de « poids moyen » Al Baker le 30 janvier i Bruxelles.

r—.- /'-r ! Hier soir, au Cirque d'Ijivr, leXord- Africain Ben Omar, cueUii d froid par- un « wihrf du gauche de Sli- ! « final, qui l'atteignit au visage, alla au, tapis pour neuf secondes. Ordre à son courage et aussi, il foul j bien le dire, à un science du ring, Brn I Omar put terminer le round. Puis, j ayant récupéré, il combla son handicap j et, au moment où il allait rejoindre au décompte des points le Xord- Africain fut de nouveau envoyé au sol pour huit secondes au huitième round. Cette fois, c'en était fini. Il subtil encore sept knock- downs et fit mis hors de combat néant la fin du dixième et dernier round, pour sa première défaite, Ben Omar fut battu par knocktrut. Mais quelle ardente bataille ! Nouvelle victoire du classique Jean Mougin et pi té usé exhibition de Monber qui batit Dunand aine joints.

! UEMAIX DIMANCHE, autour de 1 > pj\*ee d'eau des Suisses, k Versailles, ! seront dispute \* le challenge de efosiacountry Bené Poinetet et. la eu ope du ; Xombre. Ton » les grand \* elnb » de la, région parisienne sont engagés. i



[Consulter la page sur Gallica](#)

[Proximité au thème](#)

Indice de proximité au thème de **0.68** à partir des mots « *Cirque, Cirque* »

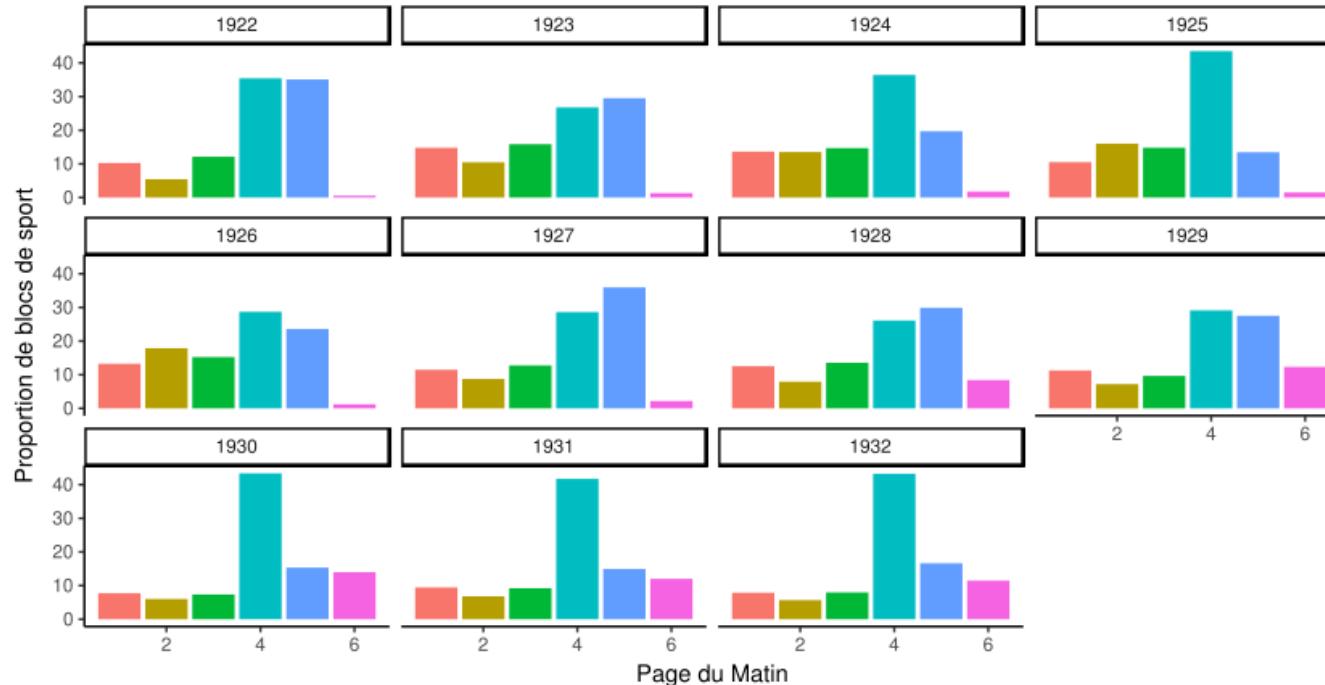
[Classification](#)

Sport (47.75 %), Publicité\_afiche (10.65 %), Bourse (5.95 %), Économie (5.59 %)

Classification can also serve to document a pre-existing corpora (here the circus in occupied France during WWII) and ease the reading process.



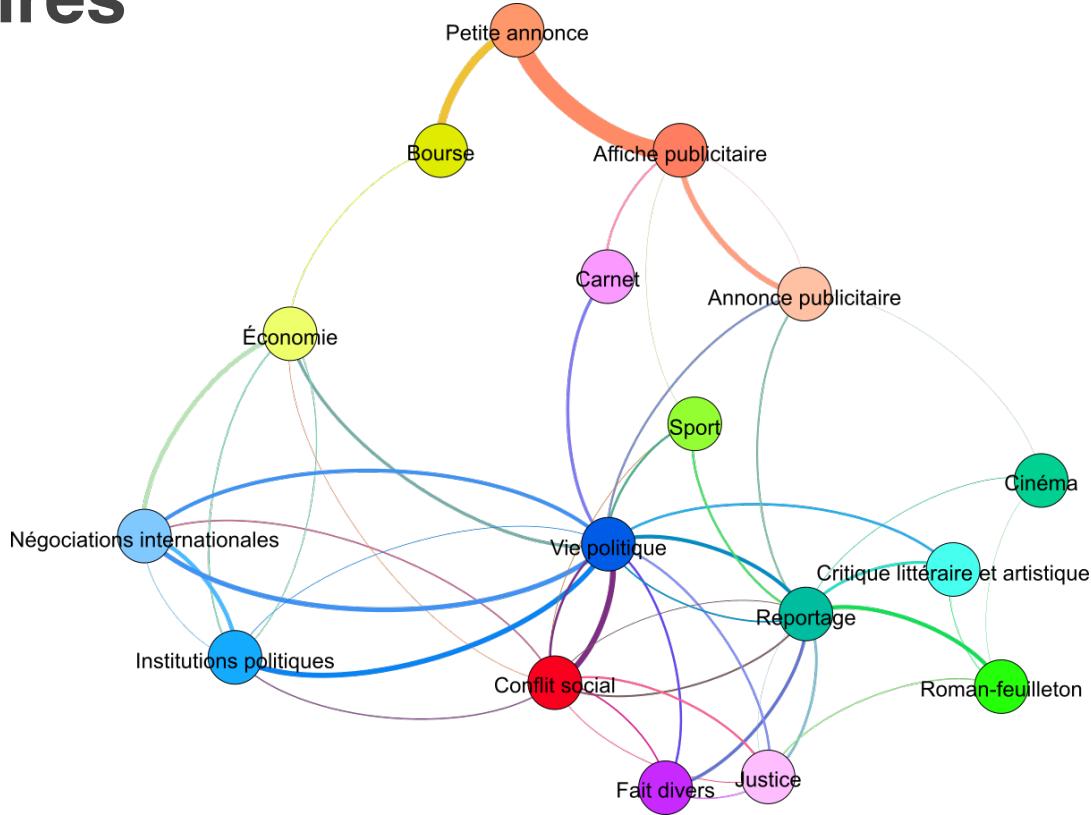
# Place the genres



During the 1920s, the place of the sports article within the newspaper is more and more specific: on page 4.

# Place the genres

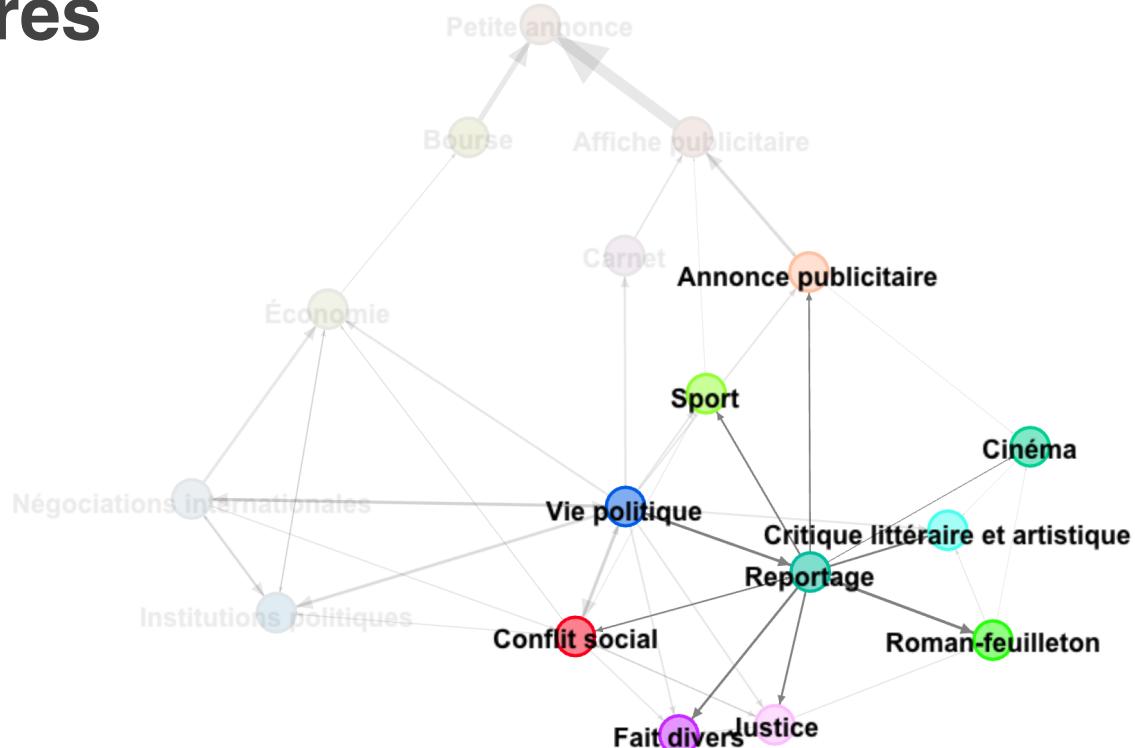
As each text block can belong to several genres (defined by probabilities), we can map all the frequent relations between genres into a network, with each link indicating the frequency of cross-classification...





# Place the genres

This visualization highlights “crossroads genre”, such as *reportage* which connect political, social and cultural sections of the newspaper...

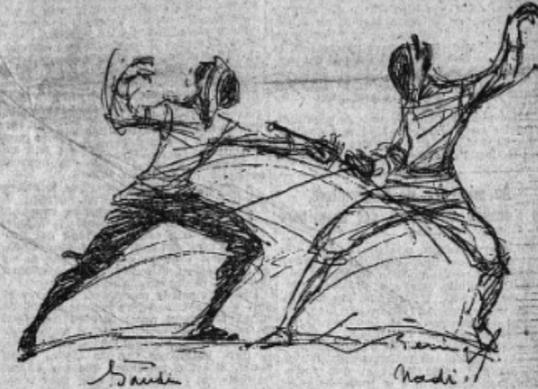




# Place the genres

A case of intertextuality: an account of fencing written like a serial novel of Alexandre Dumas (31 January 1922 : serial novel 30%, sport 35%)

**Par 20 touches contre 11  
LUCIEN GAUDIN le champion français s'assure la suprématie mondiale de l'esgrime au fleuret**



*Gaudin* *Nadi*

Après quelques préliminaires se composant d'essais de matches, et une contestation du duel, un xvii<sup>e</sup> siècle, de poèmes et de musiques militaires, les deux champions font leur entrée dans la salle et montrent à la piste.

Aldo Nadi d'abord grand, avère, flânant. Il salut l'assistance du fleuret et celle qui fait une ovation. Lucien Gaudin reçoit également les acclamations du public. Grand aussi, mais plus stoïque, il paraît faire le sourire sur ses lèvres. Il répond par un salut large et sincère respectueusement devant M. Maginot, ministre de la guerre, et le maréchal Foch.

Un même moment, en rentrant dans quelqu'un qui, l'élevant au-dessus de lui, cri : « Au nom de la France et Gaudin ! »

Il va se porter à son adversaire qui embrasse.

Les juges, postés de chaque côté de la piste, deux par deux, se finissent face, re-

font 3 à 2. Ensuite deux attaques consécutives sans résultat. Sur l'une d'elles, Gaudin para et riposte sous le bras. Contestation ; mais Trombert juge que le coup est bon et l'accorde.

Gaudin mène par 4 touches à 2, suivie d'une 5<sup>e</sup> touche sur un magnifique coup droit qu'Aldo n'a pu parer que très tard. Nouvelles acclamations (applaudissements rapides). Gaudin fait la piste belle et ferme le match — qui touche par une, deux. Par un double dégoux, il touche encore. C'est à 6 à 3.

Mais un coup est sujet à contestation et Trombert n'hésite pas à demander des hésitations. Les deux tireurs ont d'ailleurs retiré leurs masques et Gaudin tente de convaincre Aldo que sa touche est nettement valable.

La lutte reprend. Gaudin part à fond et on a juste le temps de voir le coup de bouton de son fleuret s'aplatis sur le poitrine de son adversaire. 7 touches contre 3.

Riposte de Aldo sur une attaque de Gaudin qui l'a paré. 7 contre 4.

Aldo attaque, Gaudin para. Aldo fait une remise et touche par contre 5. Puis Gaudin riposte sur la riposte de Aldo. 8 contre 5, grâce d'une autre riposte d'Aldo qui cette fois est homme : 8 à 6.

Attaque en marchant de Aldo qui suit le coup; Gaudin, solide sur ses jambes, para et riposte avant de recevoir son adversaire dans ses bras. 9 à 6. Nouvelle attaque de même style, mais là, Gaudin para avec violence et rapidité et riposte en coup droit. 10 à 6.

La seconde partie fut aussi vive et rapidement menée, quoique les deux tireurs fussent assez émouus.

Aldo attaque ; riposte droite de Gaudin, 11 à 6 ; Gaudin touche à l'épaule, 12 à 6 ; Aldo

fait un point sur une remise, 12 à 7 ; Gaudin fait 13 à 7 puis 13 à 8 sur une attaque et sans une riposte.

À ce moment Aldo s'impunit et frappe à la tête. Pini lui-même va près de lui et l'empêche de se calmer.

Sur une prise de fer de Aldo, Gaudin dégaine et para et fond. 13 à 8. Gaudin touche sans bras, riposte 13 à 8, puis se fait toucher deux fois par un coup direct de toute beauté, 15 à 10. Attaque de Aldo, riposte de Gaudin au bras, 16 à 10.

Aldo proteste avec véhémence.

— Vous n'avez pas le droit de parler, lui crise Pini.

Et fait une touche à l'épaule de Aldo et Gaudin compte 17 contre 10.

Gaudin emploie à présent les battements de fer. Au cours de l'an d'eux, il attaque en marchant et gagne 18 à 10. Mais alors, Aldo par un coup magnifique et une attaque fougueuse — la plus belle qu'il ait faite — marque la 11<sup>e</sup> touche.

Aldo est encore touché. Il proteste.

— Mais où l'ai dit Gaudin, 19 à 11.

Sur une attaque en marchant, Gaudin touche, mais Pini n'en veut pas et Trombert s'incline.

Enfin le dernier coup de bouton a lieu : sur une remarquable passe d'armes ; Gaudin attaque, Aldo riposte en marchant. Gaudin para et touche. Il a gagné par 20 touches contre 11.

C'est du diable dans la salle. Les deux hommes sont acclamés et Pini, montant sur l'autre, fait un long discours par lequel il présente de fréquentes rencontres entre Italiens et Français.

— J'ai mis tout ce que j'ai pu, tells en résumé, l'opinion de Gaudin.

— On ne m'a pas coupé 7 touches, celle est celle de Aldo Nadi.



# Place the genres

...or a stock exchange  
section partly written using  
verses in *Le Figaro*

Cela est gras, cela est sale, cela sent mauvais, cela ne se pourrait prendre qu'avec des pincettes, et encore qu'avec des pincettes rouillées, qu'avec des pincettes de rebut, qu'avec des pincettes de la rue de Lappe.

On me demande cependant des renseignements sur ces chiffons de papier qui, à leur origine, eurent une certaine valeur — nominale.

Voici ma réponse, une fois pour toutes :

Tout cela coûta — soyons francs —  
Quatre ou cinq millions, je gage.  
Si l'on vous en offre cent francs,  
N'en demandez pas davantage.

Paul Bury.

P.-S. — Je m'a erois que quelques vers se sont glissés dans cette chronique : je n'ai pas eu le temps de les remettre en prose.



# An archeology of genres

Each model has an expiratory date: we are going to use them on a 20-30 years basis.

Yet, it would still be instructive to use them in an “anachronistic” way. The issue is no longer to classify texts but rather to find the antecedents of a later established genre.

We have made a preliminary test on *Le Journal des Débats* in 1836, at a time where an established sport section did not exist.



# An archeology of genres

...and it turns out there were significant, although quite occasional sport articles, such as this lengthy feuilleton (septembre 9th, 1836) on the horse races on the *Champs de Mars*

**COURSES DU CHAMP DE MARS.**  
*Prix principal de 4,500 fr. et Prix royal.*

Figurez-vous les champs de la Troade : voilà dans le lointain Pergame; plus près, sur les bords de la mer, voilà les Grecs et leurs vaisseaux. Achille vient de combattre et d'immoler Hector. Il rend les honneurs funèbres à Patrocle. Il célèbre des jeux et ceux qui disputent le prix de la course des chars sont Antiloque, le fils de Nestor, Diomède et Ménelas. Quels noms! Quels jeux! Quel spectacle! Quelles courses que celles qui avaient Achille pour juge et dont Homère a chanté les vainqueurs!

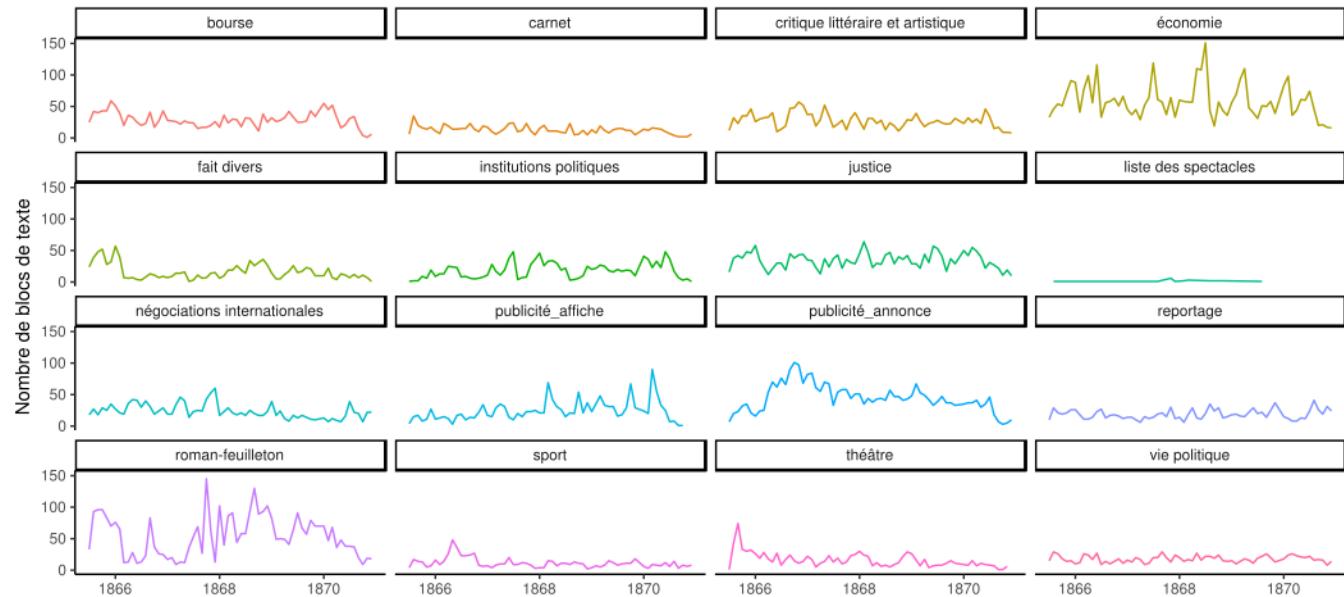
Je ne sais pas si les chevaux russes ont une origine grecque ou tartare; mais ils sont prompts, nerveux, infatigables, doués d'intelligence et plus dociles encore à la voix, qu'aux guides et qu'au fouet de leur conducteur. Placé sur le siège de sa voiture et menant quatre chevaux de front à la manière des chars antiques, un cocher russe, moins despote avec ses coursiers que ne l'est son maître envers lui, ne leur adresse jamais un ordre, une recommandation, une menace, sans leur en déduire les motifs.

M. Ancelot, dans un ouvrage intéressant, intitulé : *Six mois en Russie*, dit qu'il a fait traduire ces perpétuels monologues, qu'il interrompt quelquefois une chanson nationale. « Le cocher russe, continue-t-il, varie les discours et les inflexions de sa voix suivant l'âge, les forces physiques ou les qualités morales de ses quatre chevaux : il s'adresse à l'expérience du plus vieux et lui démontre la nécessité de donner un bon exemple ; il gourmande la paresse de celui qui, resté plusieurs jours à l'écurie, doit expier son inaction par une ardeur nouvelle. Le plus grand a sans doute trop de cœur pour se laisser vaincre par des chevaux moins vigoureux, et le plus jeune, heureux d'être associé à des coursiers rapides, doit à force de zèle se montrer digne d'eux. Ces paroles, tantôt bienveillantes, tantôt grondeuses, exercent un grand empire sur les chevaux russes, et quand leur guide est satisfait, il les nomme ses *petits pigeons*; c'est là la marque la plus flatteuse de contentement qu'il puisse leur donner. » Il y a, comme on voit, dans cette manière de presser, de blâmer ou d'encou-



# An archeology of genres

This anachronistic outlook can be deployed on a wider scales, such as the evolution of the genres of *La Liberté* from 1865 to 1870 using the model made for the 1920s and 1930s.



# Toward a library of models

Générothèque

Parcourir les modèles    Parcourir les corpus    Solliciter un modèle

**PRESSE DE L'ENTRE-DEUX-GUERRES**

**Métadonnées**

**Titre**  
Presse quotidienne de l'entre-deux-guerres

**Description**  
Modèle lexical permettant de détecter 20 genres journalistiques courants de dans la presse quotidienne de 1920 à 1940

**Type de modèle**  
SVM (Support Vector Machine)

**Format du modèle**  
Objet R (SVM)

**Corpus initial**  
22 exemplaires du *Matin*, du *Petit Parisien*, de l'*Intransigeant* et du *Petit Journal* ([Consulter l'ensemble du corpus](#))

**Taux de succès**  
75%

N. B. L'évaluation intègre des cas fréquents d'intertextualité qui ne constituent pas véritablement des "erreurs"

**Variantes**  
Version Figaro ou l'*Humanité* (intégration d'exemplaires annotés de ces deux titres : la qualité de reconnaissance plus basse, mais peut-être mieux adapté à leur classification)

Le modèle comprend les 20 genres suivants : *reportage*, *négociations internationales*, *institutions politiques*, *vie politique*, *économie*, *conflict social*, *justice*, *fait divers*, *roman-feuilleton*, *critique artistique*, *cinéma*, *théâtre*, *sport*, *programme radio*, *liste de spectacles*, *carnet*, *bourse*, *annonce publicitaire*, *affiche publicitaire* et *petite annonce*.

**Télécharger le Modèle**

The « Générothèque » project: a library of classification models

## 2. Toward a poetic analysis of news images

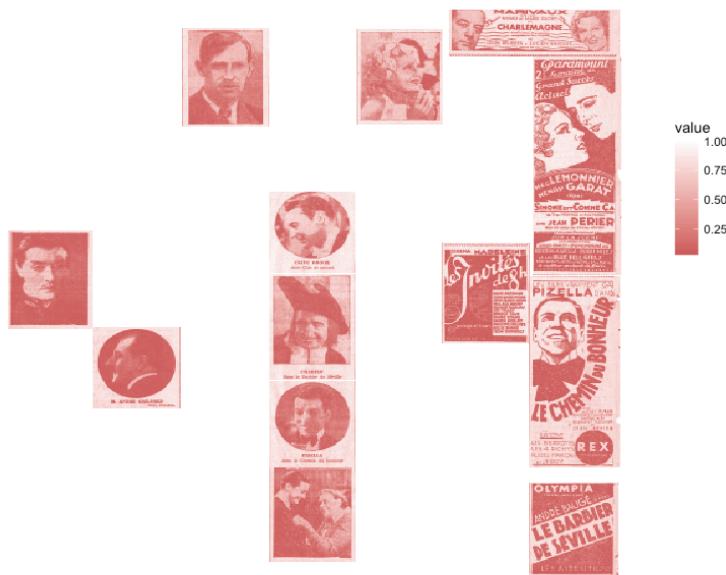
Tracking aesthetic mutations through *deep learning.*



# The news image: the spinal column of the XXth century newspaper

Starting in the 1900s, images became a very strong baseline of news structuration. With the digitized XML files from the BNF it is possible to extract all the illustrations, through their coordinates, and to reconstruct this polyphonic interaction between text and images.

Projection des images de la rubrique cinéma du Matin





# From text to image

Le Petit Journal du 1934-01-01, article n°9(page n°1)

The position of the image *within* the text allow to easily retrieve the thematic of the image through the automated classification of the surrounding text.

## DU NOUVEAU EN RUGBY

Les équipes nationales d'Angleterre et d'Australie ont donné hier, au stade Perahing, une démonstration fort agréable du rugby à treize joueurs. La partie qu'ils jouèrent-*r* la première de cette sorte disputée en France fort plaisante, fut mouvementée à souhait, facile à suivre et intéressa vivement les spectateurs. Notre cliché représente un joueur australien qui, s r étant emparé du ballon, va se trouver aux prises avec un Anglais. Les équipes nationales d'Angleterre et d'Australie ont donné hier, au stade Perahing, une démonstration fort agréable du rugby à treize joueurs. La partie qu'ils jouèrent-*r* la première de cette sorte disputée en France fort plaisante, fut mouvementée à souhait, facile à suivre et intéressa vivement les spectateurs. Notre cliché représente un joueur australien qui, s r étant emparé du ballon, va se trouver aux prises avec un Anglais.

[Consulter la page sur Gallica](#)

Classification générale : sport(99%)

Sous-classification : boxe(68%), tennis(29%), football(3%)





# From text to image



*Sport* (99%)



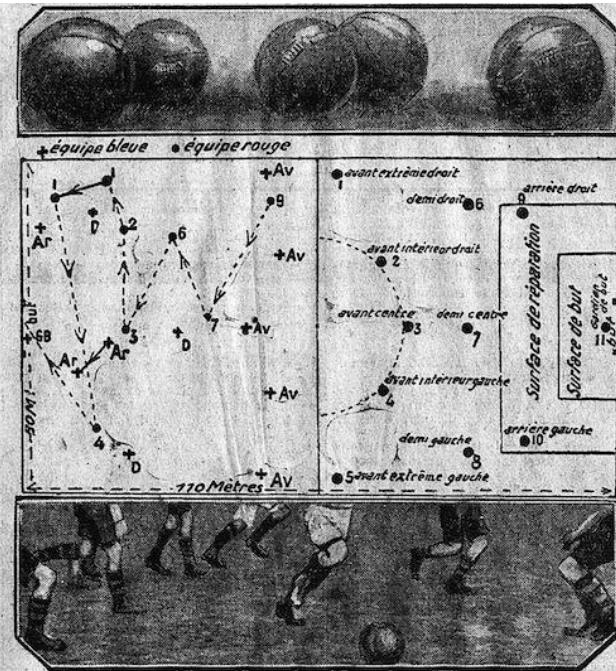
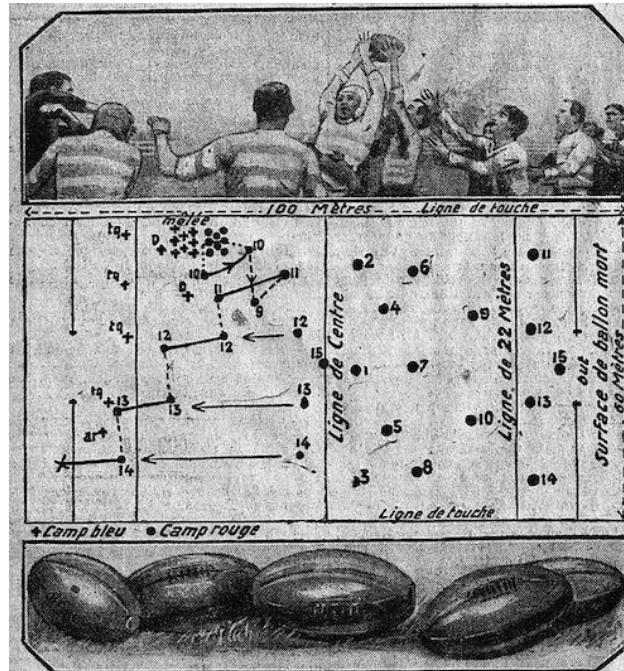
*Sport* (94%)



*Sport* (34%),  
*Carnet* (30%)

# From text to image

This classification by proxy ease significantly the consultation and identification of relevant images — such as this 1912 *dataviz* of a football match.





# The imperfect magic of DL models

Image classification has made significant progress during the last few years, through the generalized use of convoluted neural network.

Nevertheless, most comprehensive models (such as ImageNet) remain focused on contemporary classification

**=> Utiliser les récurrences de classification plutôt que d'accepter les classifications telles quelles. Si toutes les cartes sont classées comme des mots croisées cela peut être un critère valable.**



# The imperfect magic of DL models



*Joueur de baseball (0.18),  
Couverture de livre (0.12),  
Télévision (0.09), Ballon de foot  
(0.08)*



*Uniforme militaire (0.53),  
Gilet pare-balle (0.20),  
Télévision (0.05)*



*Couverture de livre (0.76),  
Joueur de baseball (0.13)*



# The imperfect magic of DL models



Space shuttle  
*(steampunk for the win)*



Crosswords (!)



# The (temporary) solution: using more abstract vectors

This approach has been experimented by the Netherland project SIAMESE: identifying cluster of similar images, through the next to last vector generated by the neural network.

Introduction

Live demo

Instructions

Examples

SIAMESE performs especially well in grouping clearly identifiable objects in advertisements. On the one hand, this is driven by the high number of advertisements for fashion (Fig. 1) and automobiles (Fig. 2). On the other, it also reveals that these advertisements for these products featured a consistent visual trend.

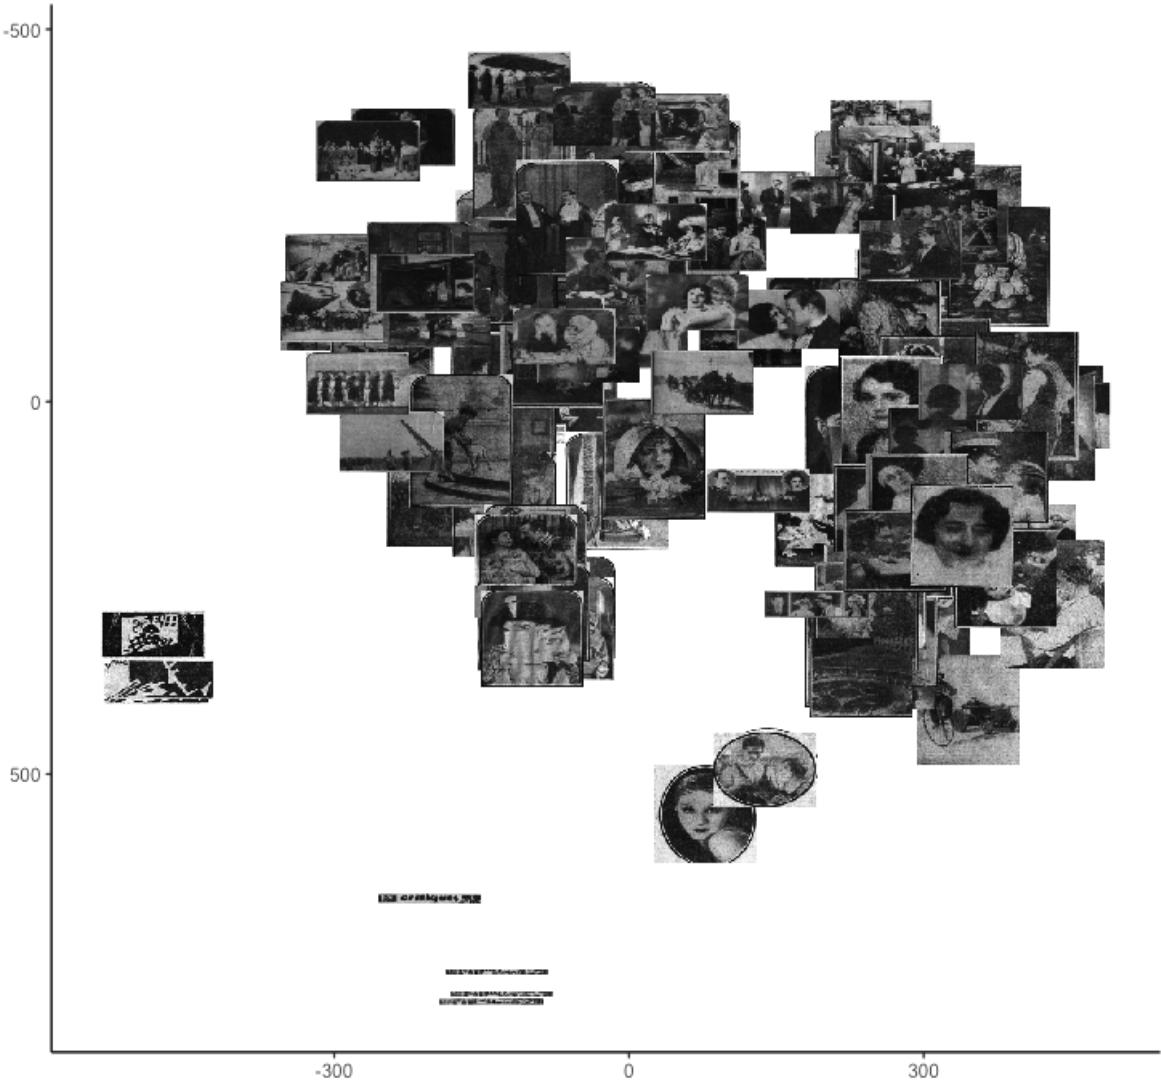


Figure 1. SIAMESE timeline view for fashion advertisements

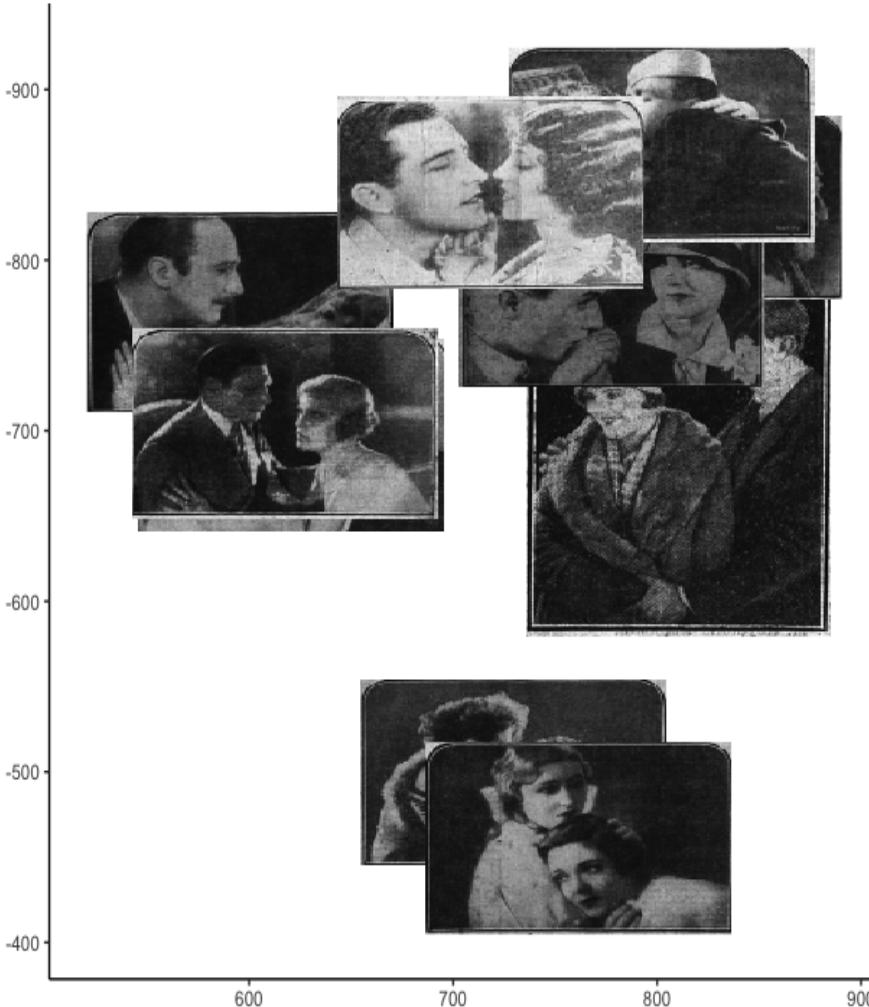


Figure 2. SIAMESE timeline view for automobile advertisements

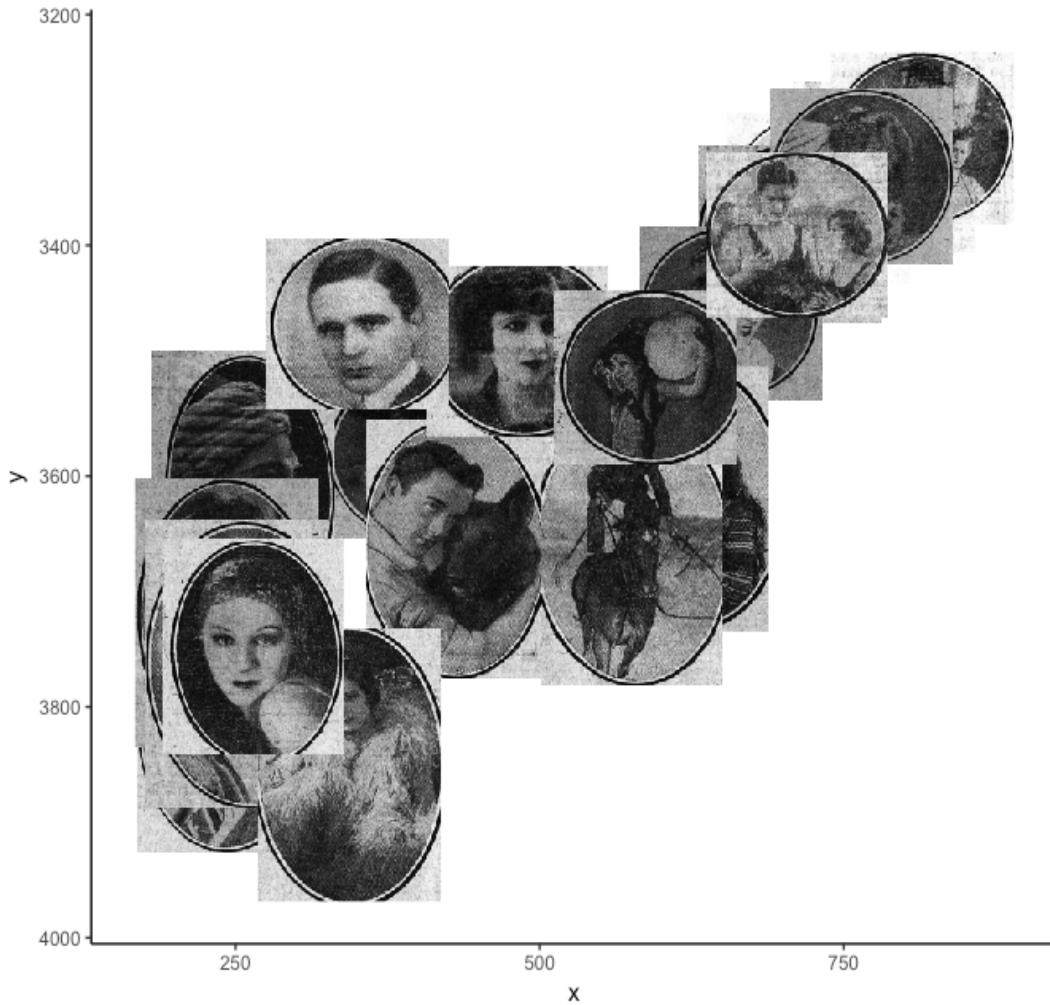
A random sample of all the images in the movie section of *Le Matin* from 1927 to 1929. Clustered images are likely similar.

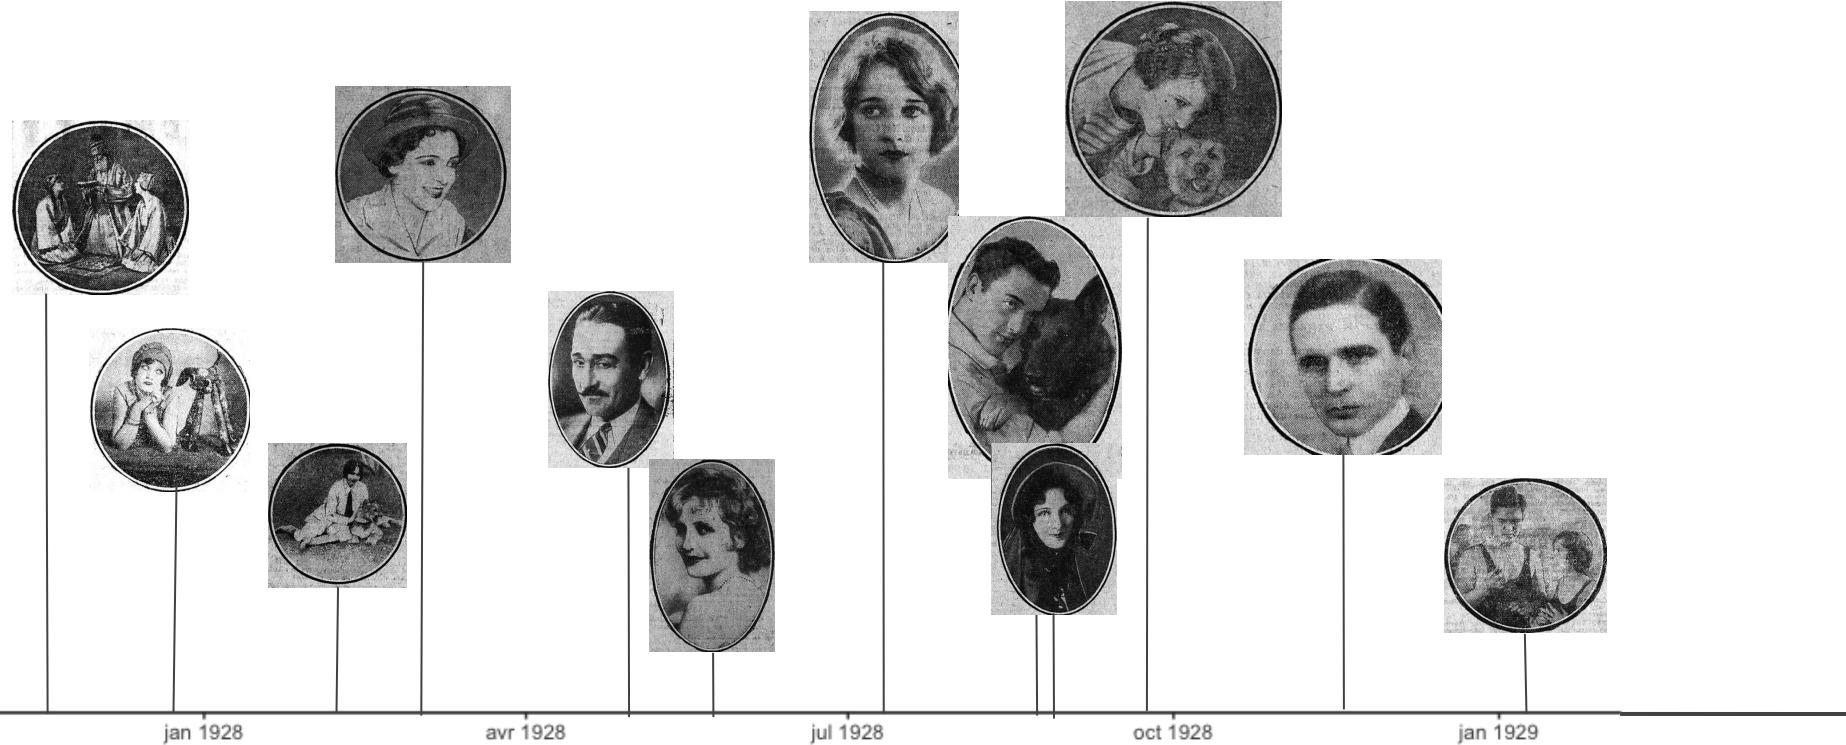


This “similarity” can be due to the topic represented: here we have a cluster of couples (that are mostly represented through Hollywood stereotype).



The neural network  
also identifies  
recurrent form and  
structure of images,  
such as the use of an  
oval medallion.





By crossing deep learning results with metadata we can recover long-time shift in the way images are made, such as the sudden disappearance of the oval medallion

### **3. Reconstruction of editorial structure**

**How to sight-read the polyphony of news**

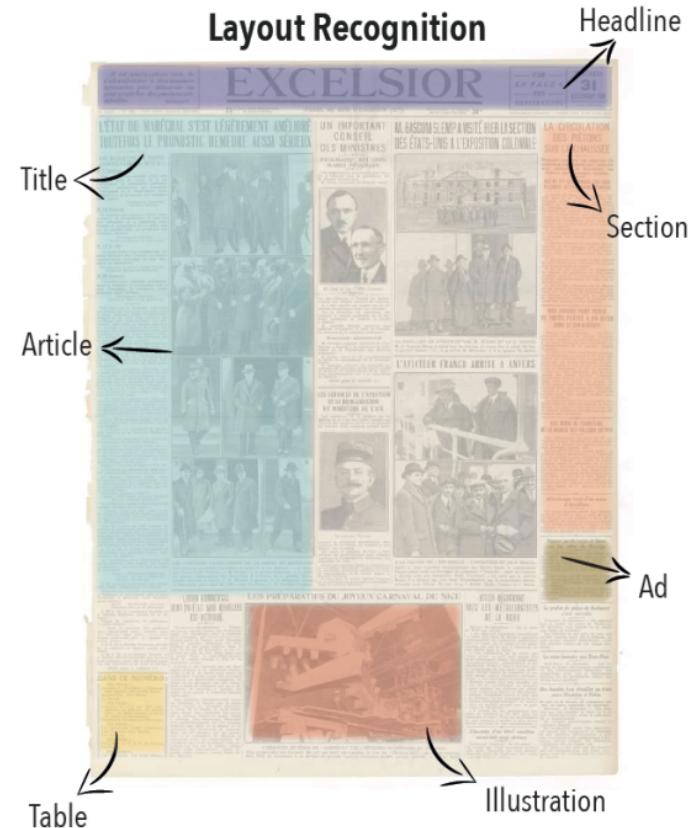


# Breakthroughs in layout recognition

The Europeana Newspaper (2012-2015) has digitized 2 millions pages using Optical Layout Recognition (OLR), that allows to retrieve article and news components using semi-automatic tools.

The French National Library applies OLR for its current digitization program.

The Newseye projects aims to create advanced automatic tools to generate OLR.



# Text as image

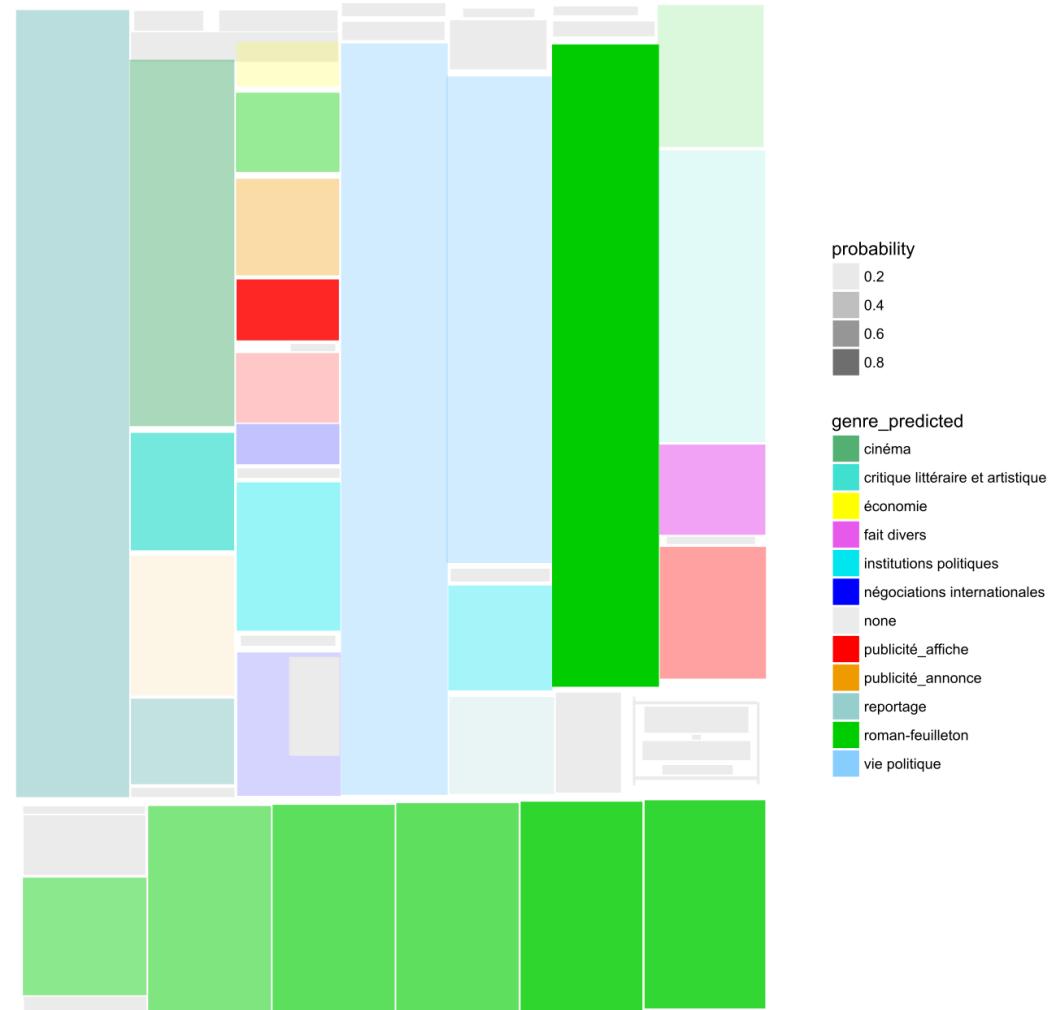
A project still experimental: training a model to identify editorial structure, thanks to the pioneering work of DH Segment. The initial tests on the feuilleton are conclusive. Advertisings, images, headers, should come next...





# Text as image

This will be especially valuable to further classify literary productions in the newspaper, serial novel being almost by definition in the *feuilleton* while other more fugitive forms (short story, verses...) may be placed in the higher part.





# Parse the metadata *in the news*

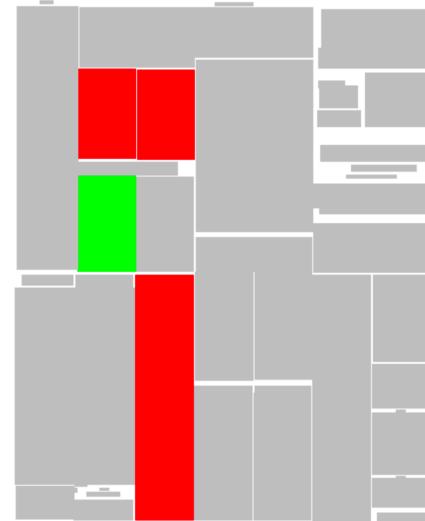
L'Intransigeant du 1935-09-06, bloc de texte n°p3b10(page n°3)

**Londres, 5 septembre** (de notre **corr. part.**, **par téléphone**).

— Les événements qui se sont déroulés hier à Genève ont consterné beaucoup d'Anglais, ils n'en ont surpris aucun. Le discours de M. Eden est l' expression même de l'idéalisme de nos amis d'outre- Manche, la traduction fidèle, sur le plan diplomatique et international des véritables sentiments de la démocratie britannique. Certes ; on considère Ici la situation comme fort grave. M. Stanley Baldwin,, premier ministre, a quitté Aix- les- Bains ; M. Mac, Donald a quitté les rlyages de l' Ecosse ; M. Neville Chamberlain, chancelier de l' Echiquier, a quitté la Touraine, le jardin de la France, pour revenir à Londres, où sir Samuel Hoare veille.

Il est à remarquer — et certains journaux anglais en font la constatation.— que le discours prononcé hier par le baron Aloisi,, devant le Conseil supérieur de Genève, est un peu moins fort quant aux termes et quant au fond que les rapports et livres de lady Simon, lord Buxton, lord Polwarth, enquêteurs bénévoles en Ethiopie, de M. Bussel, ancien ministre britannique à Addis- Abeba, et de sir Robert Corijndon, ancien gouverneur du Kenya, rapports et livres consacrés aux mœurs et à la civilisation des peuples bienheureux qui vivent sous l' allégeance du Négu.

On pense ici que l' heure n' est pas encore venue de jeter le manche après la cognée. Et cela pour les raisons suivantes :



[Consulter la page sur Gallica](#)

Lieu d'expédition : Londres (51.50°, -0.12°)

Date d'expédition : 5 septembre 1935 (1 jour avant publication)

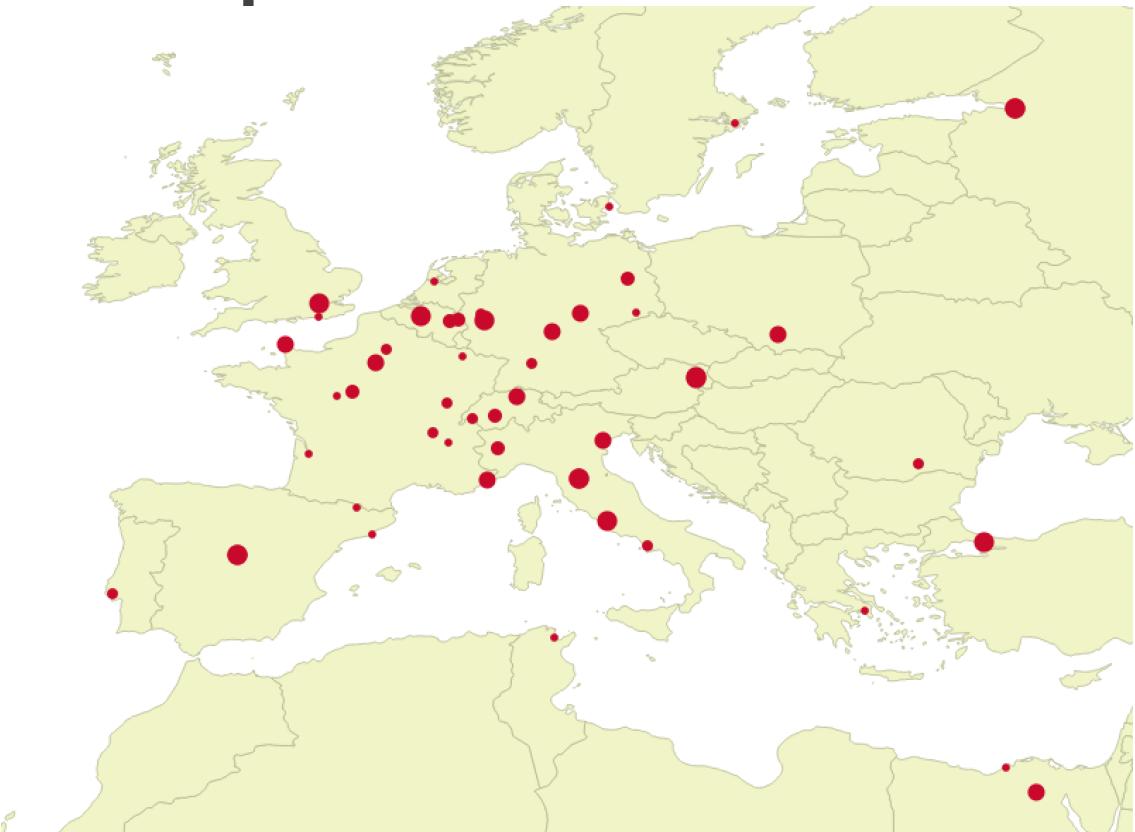
Auteur : correspondant particulier du *Matin* (Gérard Boutelleau ?)

Moyen d'expédition : téléphone



## Parse the metadata: places

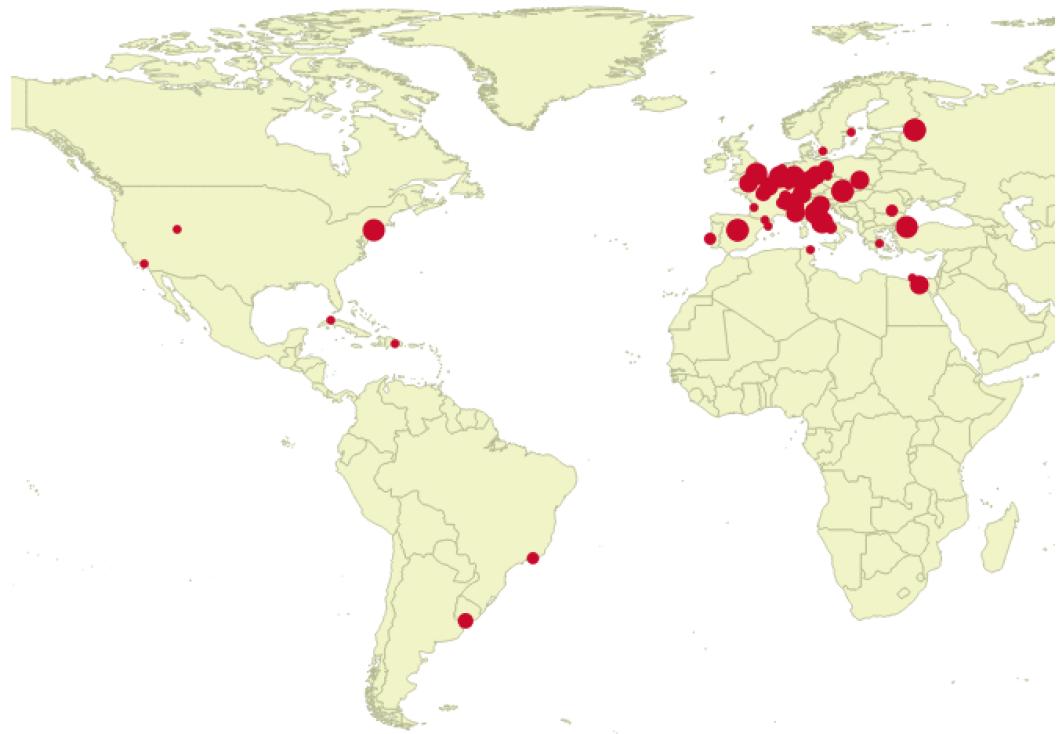
We have lead an initial case study on the emergence of French reporters in *La Liberté* (1865-1870). All the expedition places have been located and showed that the newspaper already managed a very large network across Europe and the Americas.





# Parse the metadata: places

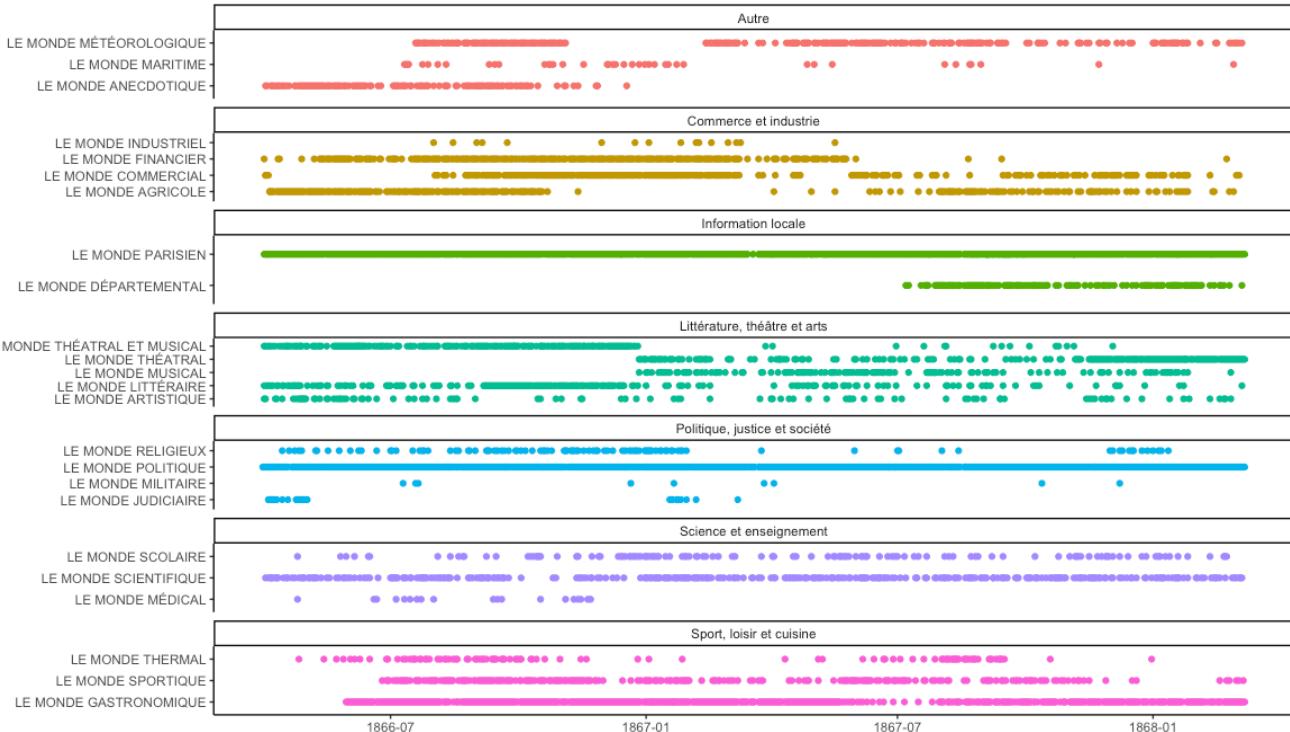
We have lead an initial case study on the emergence of French reporters in *La Liberté* (1865-1870). All the expedition places have been located and showed that the newspaper already managed a very large network across Europe and the Americas.





# Parse the metadata: titles

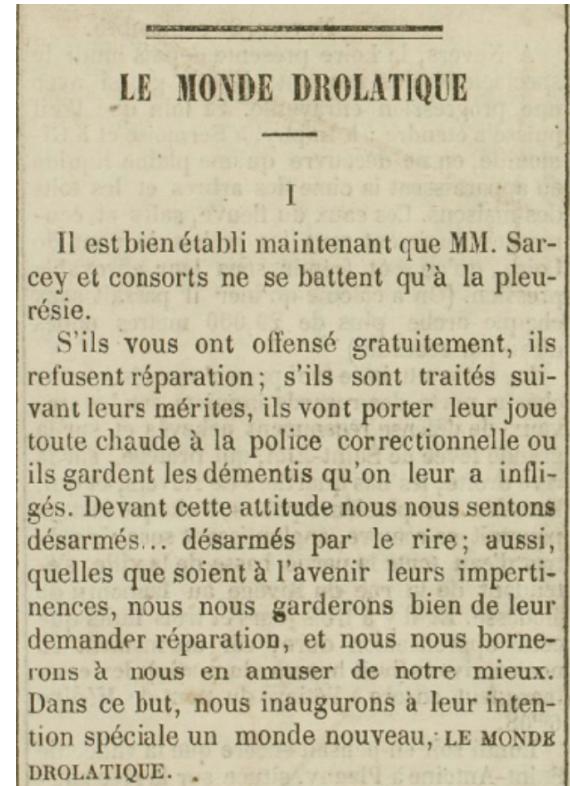
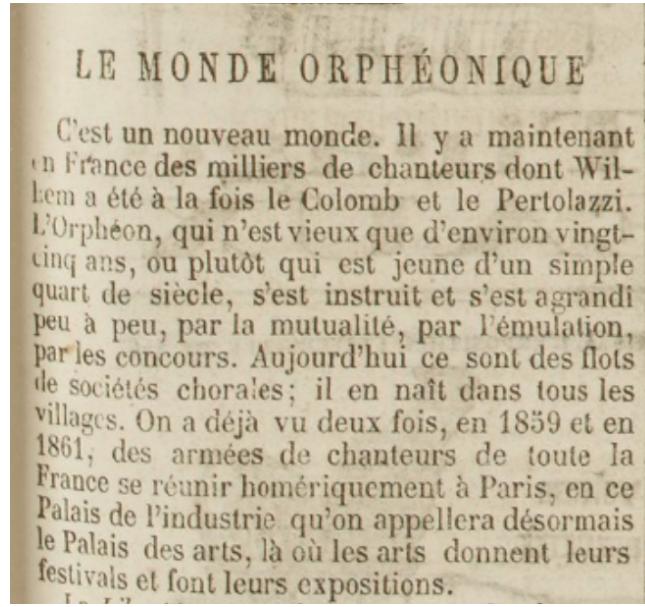
Titles can contain valuable information on the way the segmentations of newspaper texts initiated by the editors. For instance, *La Liberté* initiated extensive editorial experiments from 1866 to 1868 can gave birth to a lot of *first* in the history of French journalism (first sport section, first food column...)





# Parse the metadata: titles

We can also zoom to *failed* attempts with specialized section that could have become a regular part of French journalism but didn't (altogether, not for the worst reasons)





# Parse the metadata: signatures

Annotations Response

Name entity  
recognition has been  
greatly boosted by the  
development of an  
efficient tool for the  
French language,  
*Entity Fishing*. The  
specific issues raised  
by the OCR may be  
partly alleviated thanks  
to the pioneering work  
of *Newseye*.

Mme **KATE DE NAGY** et M. **CHARTEA VANEK** tiennent simplement de grandi rôles; ils sont sobres de gestes mal» puissants d'action. M. **RAYMOND AIMOS** a trouvé un rôle qui lui permet de montrer ses indéniables qualités d'**ACTEUR** et nous espérons le revoir **AIMAS** est un remarquable interprète de **CINÉMA PARLANT II**. sont tous excellents, d'ailleurs, les **ACTEUR\*** de ce film magnifique CitocS'lei comme à parade: Mme **LINE NORO**, superbe toujours **MADY BERRY**, si simple en son naturel Vers dnt le talent mérite des rôles plus amples, et MM. **RAYMOND CORDY**, nouveau Jolivet. mécano cette fois, niais rigolard et sentimental **H-A. SCHIEFTOW**, **ANDREW ÉUFLEJMAF**, **P. GENSCHAU**, **PIERRE PIÇRADE** et **RENT BERGERON**. Enfin, M. **PIERRE BLANCHARD**, dur, énergique, solide et fort comme il sied à Un chef. Belle création Nous n'en sommes plus à louanger M. **PIERRE BLANCHARD** qui est avec quelque\* autres l'honneur de notre **ART DRAMATIQUE**, mais une coupure malheureuse dans le texte tious trouble sur la personnalité de son personnage, L'hommer par cette amputation, devient une sorte d'aventurier alors qu'H «t comme beaucoup d'entre nom qui avons combattu, un dégoûté, un écœuré. N'empiche que Au bout du mond est une de ces oeuvres qui rous redciiEnt une magniSquç espérance dans l'art cinématographique C'est mieux que bleu, c'est beau.

## PIERRE BLANCHARD

Type: PERSON

Normalized: Pierre Blanchard

Domains: Medicine, Psychiatry

conf: 0.9994

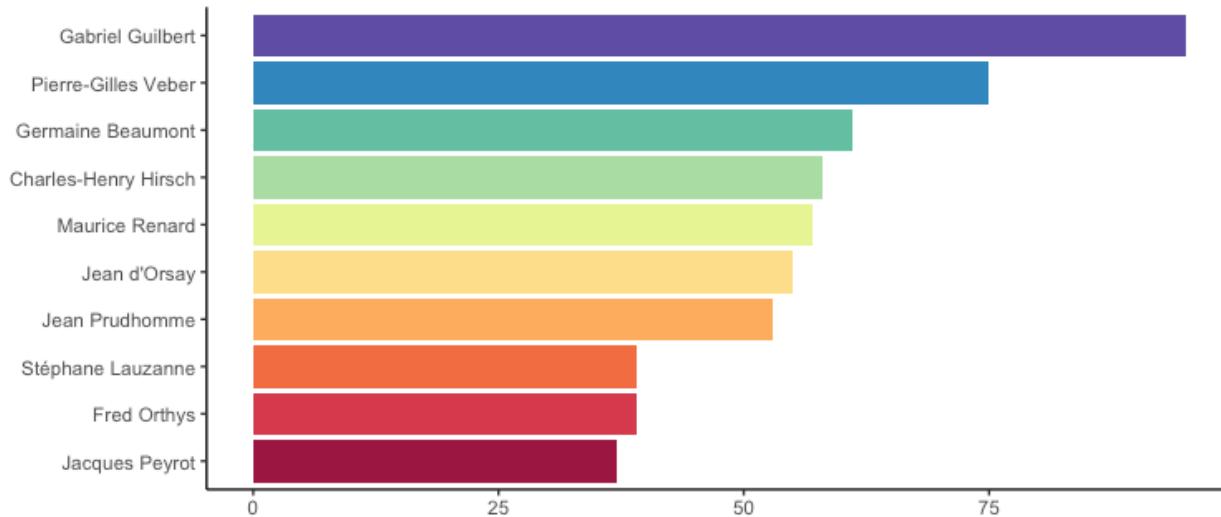


Pierre Blanchard, né Gustave Pierre Blanchard le à Philippeville (aujourd'hui Skikda, en Algérie), et mort le à Suresnes (Hauts-de-Seine) est un acteur et metteur en scène français.

place of interment	Q781858
sex or gender	Q6581097
occupation	Actor
occupation	Film director
occupation	Q10800557
VIAF ID	73772790
ISNI	0000 0001 1936 2114
IMDb ID	nm0087018



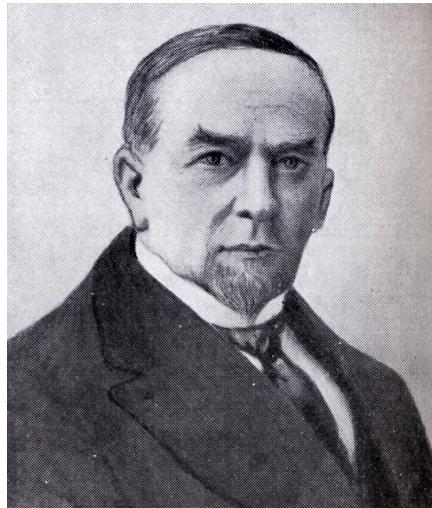
# Parse the metadata: signatures



The top ranking of the most productive writers of the *Matin* in 1935 includes well-known *plumes* (Germaine Beaumont, Maurice Renard) as well as... unexpected profiles

# Parse the metadata: signatures

**Gabriel Guilbert** is the more proficient author of 1935 and he acts as... the weatherman of the *Matin* (and he can't be located anywhere in bibliographic databases)



## L'HIVER DISPARAÎT DE LA FRANCE

A la Chandeleur, dit un antique proverbe, l'hiver se passe ou prend vigueur. Cette fête, en 1935, montrera que l'hiver se passe. Le temps doux du 1<sup>er</sup> février sera suivi le 2 d'une journée plus douce encore et les dernières neiges, au N-E. de la France, auront disparu. Les gelées du 1<sup>er</sup> février dans l'E., le Centre et le S. : -1° à Orléans, Rochefort ; -2° à Lyon ; -3° à Dijon ; -4° à Belfort, Clermont et Marseille, ne seront plus que des gelées blanches et le dégel sera général au cours de la journée.

Ce temps doux s'accompagnera de pluies dans la moitié N. de la France et pour plus d'un jour. C'est le régime des vents d'O. qui s'établit sur la France entière et qui sera avant-coureur du printemps.

Gabriel Guilbert.  
sur des services météorologiques  
du *Matin*.

### *Prévisions pour toute la France*





# Parse the metadata: signatures

Guibert is not an exceptional case. Both the “garden section” of Jacques Peyrot of the movie critics of Gilbert Bernard hasn’t been left much traces...

## CAUSERIE HORTICOLE

### D'autres murs D'autres jardins

Nous enjambons une grande rivière mais nous ne changeons pas de province. Ce n'est plus la même ville, mais c'est une ville du même Age, du temps où elles se tassent autour du château fort, autour de l'église, maisons contre maisons, avec des jardins comme mis en pénitence et qui en prenaient leur parti.

Le jardin de mon ami de lundi dernier s'offrait à nous dès la porte poussée : logis à droite, jardin à gauche, avec du pavé entre les deux. Pour atteindre le jardin de mon ami d'aujourd'hui, il faut traverser un vestibule, entrer dans un salon puis dans une salle à manger. Écartons les rideaux, le voici. Le soleil a mis moins de temps que nous ; il est entré par la grande porte du ciel.

Les arbres ont donné leurs fruits. Un parfum de compote d'abricots se mêle au bruit grêle du jet d'eau. La cloche du beffroi sonne lentement et des oiseaux se chamaillent, pour rire, dans le jasmin de Virginie (alias *bignonia*) qui s'accroche aux vieux murs et semble verser, par les cornes d'abondance de ses fleurs couleur feu, les plus belles promesses de l'avenir.

Le jasmin, les yeux se portent vers la tour qui le domine et qui fait partie du vénérable logis. C'est la tour d'Agnès Sorel. La belle Agnès habita cette maison, appuya ses jolies mains sur les pierres plates qui terminent le mur de la terrasse, regarda ces vœux quartiers en contre-bas que nous regardons avant de visiter du grenier à la cave (une cave à cinq étages, à cinq glacières) de ce logis solide qui, après tant de siècles ne demande qu'à revivre, qu'à sourire, en écoutant la musique nouvelle de son eau qu'une même source continue d'amener.

Jacques Peyrot.

## LES NOUVEAUX FILMS

### « Cavalerie légère »

Il y a dans ce film d'excellents combats. Un cirque en liberté, qui puisant dans son énergie, un clown poète, un garçon d'écurie qui joint à cette fomation le titre de baron, une mise en scène fastueuse et même un superviseur. Mais *Cavalerie légère* ne galope pas comme nous le voudrions parce que cette réalisation, version allemande d'un film français, version calquée pourrait-on dire, l'original n'ayant pas pu po goit du jour. Et voici l'erreur : nous sommes aux antipodes de la mentalité allemande. Babelsberg importe d'excellents artistes qui suivent mot à mot le travail de leurs confrères berlinois. On n'a même pas essayé de transposer, on copié et malgré le faste, la technique et la allure française, le résultat est tout à fait différent. On sait bien que cette formule sera abandonnée et qu'il n'y aura plus qu'une seule version, française celle-ci. Souhaitons que cette nouvelle soit vraie.

*Cavalerie légère* n'est pas un film mi-

litaire, mais le titre d'un ballet somptueux inventé par un clown qui sera dansé par une ballerine hongroise, écuyère à l'occasion que Chérubini, le directeur du cirque, recueillie par pitié. Naturellement, le dompteur directeur tout au long de sa protégée. La reconnaissance est pure ici : toute la star foraine s'amusera d'un valet de littére, qui, au contraire de Ray Blas, est vraiment noble, et l'amour à la fin triomphera parmi les fastes d'une mise en scène cossue, clinquante, dansante où l'on a gaspillé les danseuses, les chevaux et les hussards d'opérette. Réalisée par W. Hirschberg, et photographiée lumineusement, *Cavalerie légère* est interprétée par Gabriel Gabrio, puissant dompteur, heureux avec les tigresses, malheureux avec les danseuses. Constant Remy, clown inspiré et ému de Max Reinhardt, Louis Albert, et autres français, le résultat est tout à fait différent. On sait bien que cette formule sera abandonnée et qu'il n'y aura plus qu'une seule version, française celle-ci. Souhaitons que cette nouvelle soit vraie.

Gilbert Bernard.

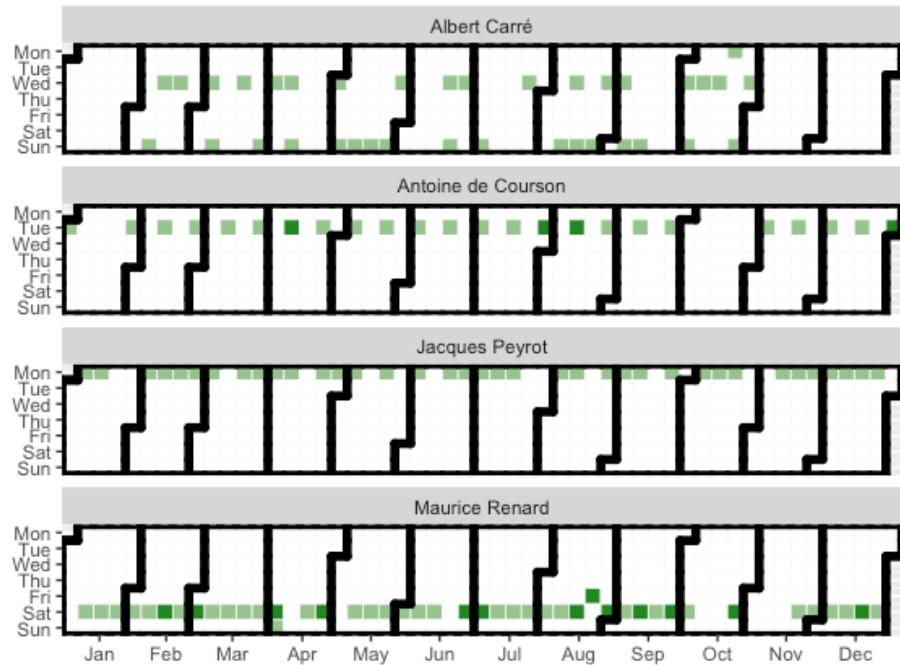
### « Veille d'armes »

Le Madeleine Cinéma présente en première exclusivité, un des films les plus importants de l'année : *Veille d'armes*. Marcel L'Herbier a su faire de la mise en scène de cette production dont l'amount et le noble sujet est inspiré d'une œuvre de Claude Farrère, de l'Académie française, et de Lucien Nepoty. Annabella et Victor Francen, avec Signoret et Pierre Renoir, Rosine Dérian, Roland Toutain et Robert Vidalin, de la Comédie-Française, sont les principales interprètes de *Veille d'armes*. Des scènes impressionnantes se succèdent avec une délicatesse et, en partie, à bord de navires de notre marine nationale. La poursuite d'un bâtimen corsaire dans la brume ; la fin d'un croiseur atteint par une torpille ; l'épisode du tribunal militaire où le capitaine répond de la perte de son vaisseau ont inspiré à Marcel L'Herbier autant d'images qui honorent son talent. La qualité de la réalisation et la valeur des interprètes, tout contribue au succès de cette belle œuvre.



# Parse the metadata: signatures

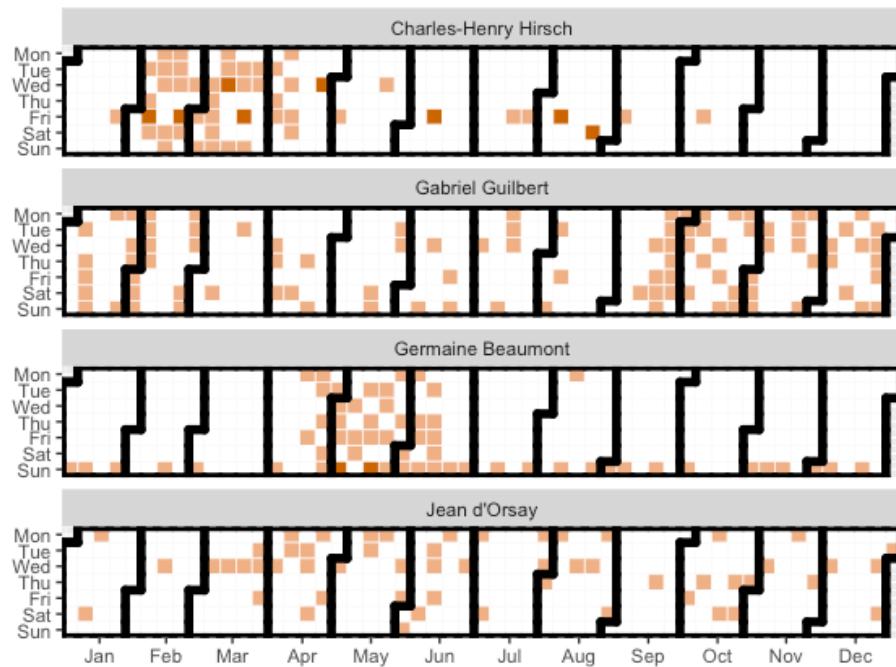
Thanks to signatures, we can infer to some extent the sociological and economic status of the writer within the newspaper. The regular collaborators write constantly on the same weekdays, through the entire year...





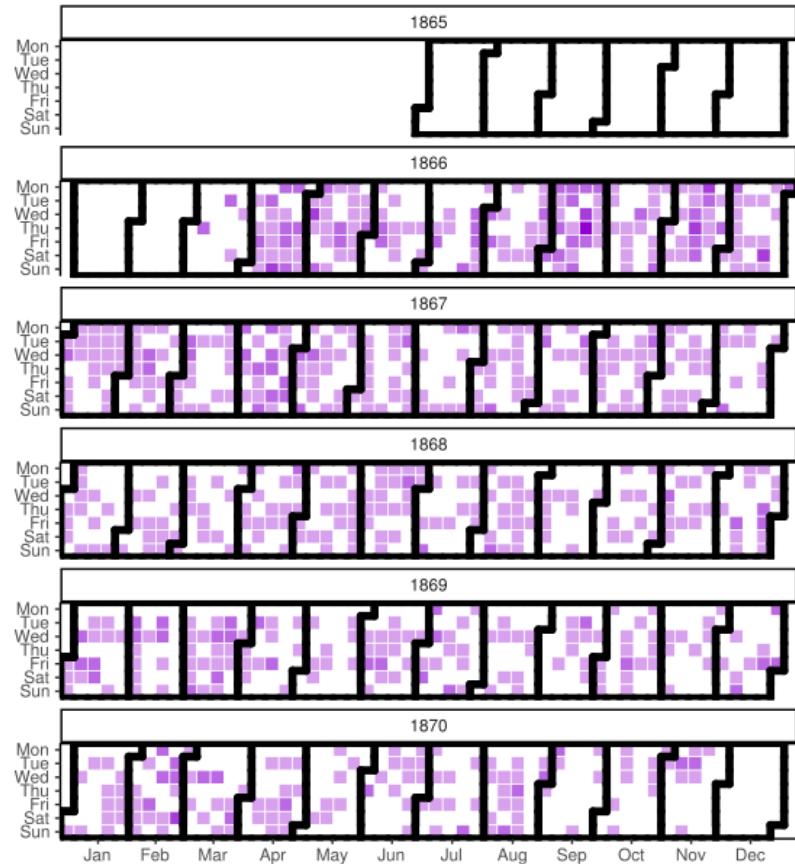
# Parse the metadata: signatures

...while some writers tends to have a much more haphazard presence, that may be in some cases caused by a more “contractual” status that may only lasts for several month of intensive activities.



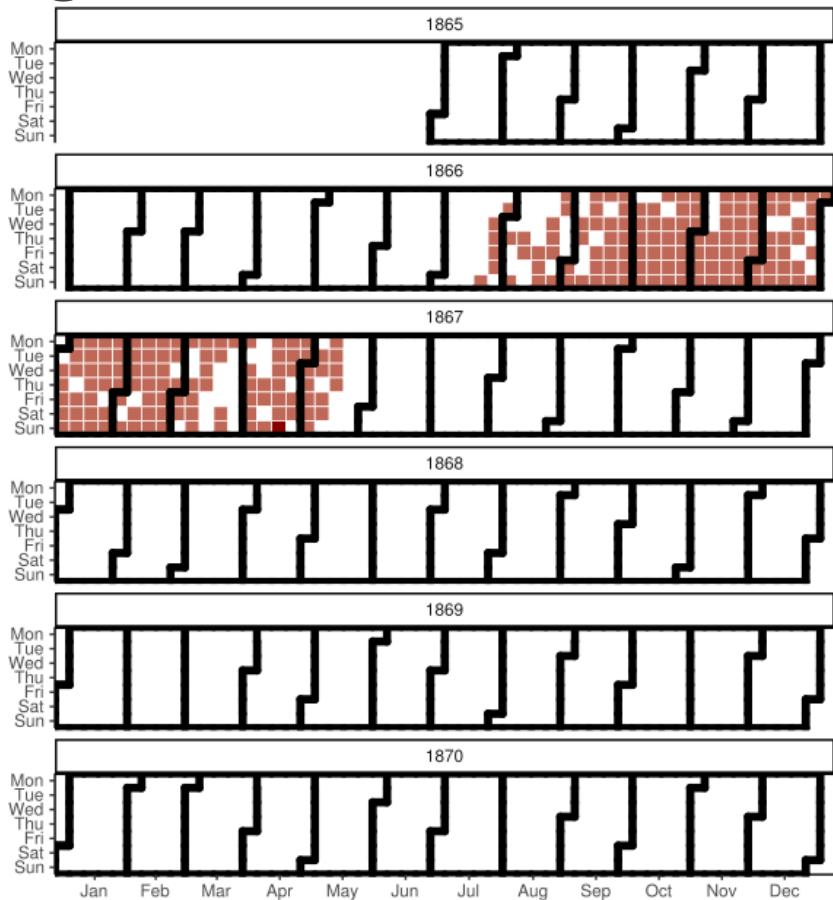
# Parse the metadata: signatures

For the *Liberté* we were able to extend this analysis on several years, thanks to the comprehensive annotations created by the French National Library that includes the signature (with METS files). For instance, the scientific journalist Wilfried de Fonvielle had secured a long-term contract.



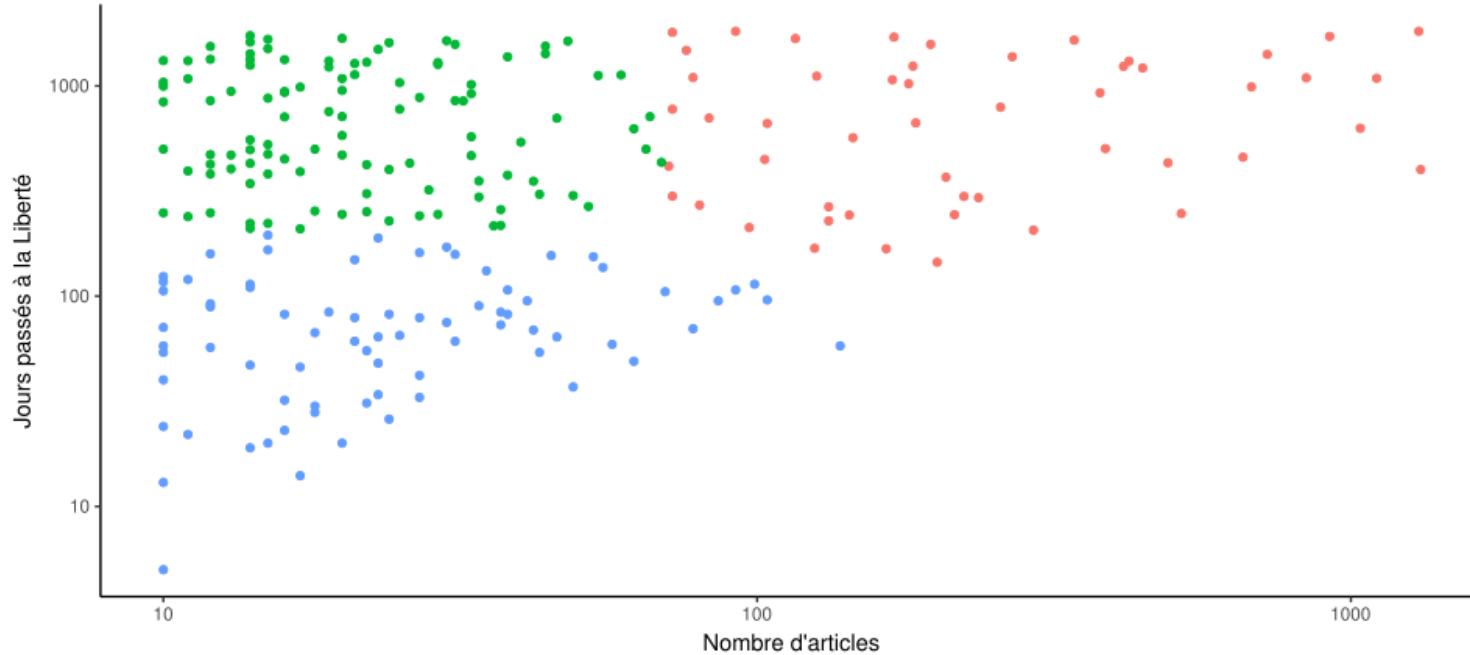
# Parse the metadata: signatures

...whereas the food chronicler,  
Brisse, was quickly fired.





# Parse the metadata: signatures



To some extent, theses status could be modeled and categorized (although with significant uncertainties, as signatures can include pseudonyms or some collaboration may not require an explicit signature).

# Parse the metadata: portraits

**ALFRED EDWARDS** qui vient de disparaître si brusquement, non pas de la scène du monde mais de la scène parisienne, fut une de ces personnalités qu'il ne faut pas négliger si on veut comprendre le temps où l'on vit. Il était né à Constantinople d'un père **ANGLAIS** et d'une mère **FRANÇAISE** qui s'appelait **CAPORAI**. Son père avait réa lisé en **TURQUIE** une fortune considérable, à l'époque des grandes et fructueuses en reprises et il courrait sur ses origines les légendes les plus variées. Selon que l'on voulait humilier **ALFRED EDWARDS** ou le fla gorner, son père avait été un banquier puissant prêtant à gros intérêts au **SULTAN** prodigue, ou un coiffeur profitant, pour spéculer des confidences des **PACHAS** qu'il tenait à sa discrétion sous la lame de son rasoir. Quoiqu'il en fût, M. et Mme **EDWARDS** s'étaient installés à Paris dans un hôtel voisin de celui de **M. THIERS**, place SaintGeorges, et comme leur fils unique avait à sa disposition beaucoup d'argent, il «in terrompit fort jeune ses études», selon la formule discrète (l'un de ses historiographes. pour faire tout simplement la fête, comme on disait en ce temps-là. On dit qu'il débute de bonne heure dans la presse. Il serait plus exact de dire qu'il fut attiré beaucoup moins vers le **JOURNALISME** que vers les journalistes par le désir de rencontrer des écrivains d'enormément d'esprit comme **AURÉLIEN SCHOLL**, **ALBERT WOLFF** et tant d'autres dont la réputation n'a pas survécu. La situation d'**ALFRED EDWARDS** lui permettait d'être un amateur et le crédit dont il jouissait dans les journaux lui servait plutôt à aggraver dans les échos de théâtre quelques mots élogieux pour les personnes auxquelles il voulait du bien, qu'à faire œuvre de ce qu'on appelle pompeusement le grand reportage. Le boulevard —puisque'il y avait encore un boulevard —apprit à connaître **ALFRED EDWARDS** quand **JULES CORNÉLY**, qui venait du **FIR/ARO ET DU GAULOIS**, —le **GAULOIS** de **TARBÉ DES SABLONS** qui passait l'été à Pourville, —fonda le Clairon, organe royaliste. 11 en était nominalement le **SECRÉTAIRE DE RÉDACTION** et ces fonctions ne l'occupaient guère. Sa situation n'était pas moins singulière, car il était à cette époque, —et pour une dizaine d'années en core, —sujet **ANGLAIS**. Il est vrai que le comte

## ALFRED EDWARDS

Type: PERSON

Normalized: Alfred Edwards



Domains: Health, Medicine, Enterprise, Commerce, Biology

conf: 0.9791

Alfred Charles Edwards, né à Constantinople le 10 juillet 1856 et mort à Paris le 10 mars 1914, est un journaliste et patron de presse d'origine anglaise, fondateur du quotidien *Le Matin*.

place of death	Paris
VIAF ID	31985591
sex or gender	Q6581097
place of birth	Constantinople
date of birth	1856-07-10
date of death	1914-03-10
place of interment	Père Lachaise Cemetery
Léonore ID	LH/891/20
country of citizenship	United Kingdom
instance of	Human

Journalists have always enjoyed to talk about... themselves. Since the Second Empire, journalists portrait becomes a widespread genre, that do not always contain very accurate information but at least document an important process of self-promotion.



# Parse the metadata: portraits

A first experimental trial of automated identification of journalist portraits in *Le Figaro* of 1862 (thanks to a metric of *personnalization* of a given texts)

	lemma	mean_tf_idf	count_lemma	pers_entity	page_id
<b>1</b>	Merluchette	0.031210693	32	0.6875000	figaro_1862-08-10_1_2
<b>2</b>	Ducuing	0.021026594	23	0.3913043	figaro_1862-11-23_1_5
<b>3</b>	Noé	0.004966037	84	0.9523810	figaro_1862-11-23_1_1
<b>4</b>	Cuit	0.011995387	17	0.4117647	figaro_1862-09-21_1_6
<b>5</b>	Delaage	0.006437054	27	0.9259259	figaro_1862-10-19_1_6
<b>6</b>	Chasles	0.003253814	49	0.5918367	figaro_1862-01-02_1_1
<b>7</b>	Foucher	0.004767351	26	0.8076923	figaro_1862-06-26_1_5
<b>8</b>	Malibran	0.005936120	53	0.7735849	figaro_1862-01-09_1_2
<b>9</b>	Polynice	0.011182846	31	0.3225806	figaro_1862-11-09_1_2
<b>10</b>	Gounod	0.002410257	48	0.3750000	figaro_1862-02-16_1_5
<b>11</b>	Zabban	0.021500261	10	1.0000000	figaro_1862-12-07_1_5
<b>12</b>	Escudier	0.013043389	29	0.4137931	figaro_1862-04-03_1_5
<b>13</b>	Etéocle	0.017756399	22	0.4545455	figaro_1862-11-09_1_2
<b>14</b>	Buhot	0.011184823	19	0.7894737	figaro_1862-01-02_1_7
<b>15</b>	Sand	0.002032593	173	0.9710983	figaro_1862-10-12_1_3
<b>16</b>	Champfleury	0.003917406	60	0.6833333	figaro_1862-10-09_1_6

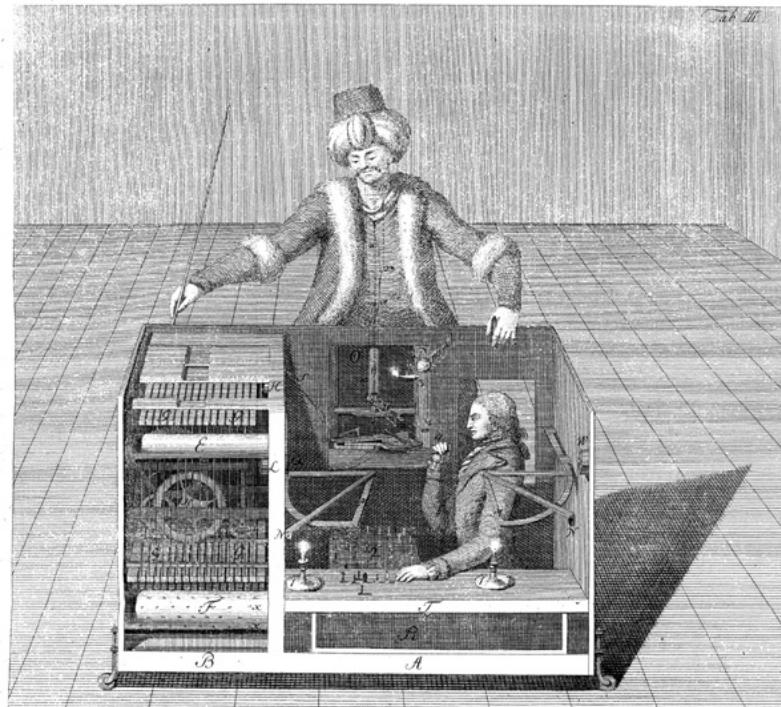


# The next challenges: automated recognition of the article

This technical challenge remains unsolved. Contractors for digital libraries mostly use the *digital labor* of developing countries.

A possible approach within Numapresse.

- Map all the information extracted through genre classification and editorial structure analysis (signatures, titles, global page geographies like the *feuilleton*)
- Use several competing definitions for an *article*. In the daily press before 1870, most news are made of free-floating paragraphs heavily recombined, without any titles or headers.





# The next challenges: mixing news texts with news archives.

22 août 1867.  
40 rue Pauquet

Mon cher neveu, je vous ay écrit et  
je vous ay écrit à la Liberté. Il le  
mouvement le prononce définitivement  
en Catalogne, allez-y... La Liberté  
vous[vs] remboursera tous vos frais  
de voyage et de dépêches — ne les  
épargnez pas et adressez les dépêches à M.  
Junca rue Montmartre 123.  
Mme Garre(?) ne m'a pas envoyé le  
discours Bazaine — mais vous avez  
dû reconnaître hier vos [manque un mot] ?  
Je mettrai à profit vs[vos] renseignements(?)  
sur M. de Kératry afin de ne  
prendre ce qu'il dira que sous//] bénéfice

Page n°1 ([Éditer](#))

22 août 1867  
40 rue Pauquet

Mon cher neveu, je reçois votre[vt] lettre et  
j'envoie vos notes à la Liberté. Si le  
mouvement se prononce définitivement  
en Catalogne, allez-y... La Liberté  
vous[vs] remboursera tous vos frais  
de voyage et de dépêches — ne les  
épargnez pas et adressez les dépêches à M.  
Junca rue Montmartre 123.  
Mme Garre(?) ne m'a pas envoyé le  
discours Bazaine — mais vous avez  
dû reconnaître hier vos [manque un mot] ?  
Je mettrai à profit vs[vos] renseignements(?)  
sur M. de Kératry afin de ne  
prendre ce qu'il dira que sous//] bénéfice

A partnered project of Numapresse, Giranium collects and transcribes the correspondence of the main French media tycoon of the XIXth century, Émile de Girardin. While this work has helped a lot to understand the inner working of a newspaper (*La Liberté*), much remain to be done with archives

## **4. Mapping news circulation and the media ecosystem**

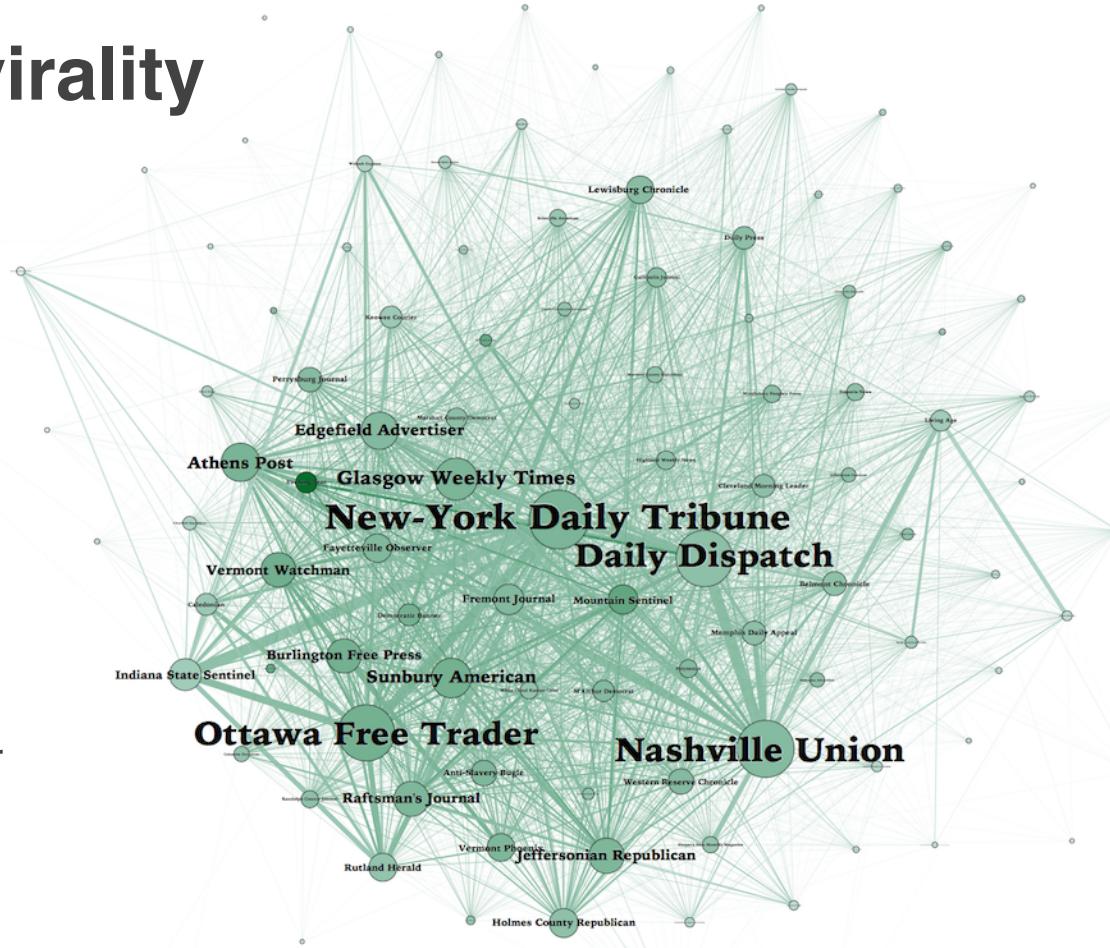
**From reprints to networks...**

# Modeling the virality

The **Viral Text** project lead by Ryan Cordell has initiated a new kind of tools to study XIXth century press: reprinting detection.

At a time where copyright did not apply to newspapers, copies were widespread and their identification can recover an extensive media ecosystem with regular “flows” between periodicals.

This research is now also extended to other countries through the **Oceanic Exchange** project.





# Modeling the virality

We have used the same methods as the Viral Text project coordinated by Ryan Cordell

- On account of OCR mistakes it is unlikely to match “exact” reprints.
- Using wide corpus implies a “combinatory explosion”: for 100 000 paragraphs there is 5 billions possible pairs of text.
- The solution: using a sample of “shared formula” (ngram) that serve to identify if a reprint is probable.

=> 108 articles were identified in at least a French and a Canadian newspaper

Malgré cette guerre, le mouvement commercial et industriel est très actif à Buenos-Ayres, à Rio-Janeiro et à Montevideo. Les meilleures nouvelles nous parviennent de toutes les provinces de la république Argentine; le grand chemin de fer du Sud a été entièrement livré au trafic; les recettes réalisées sur la partie primitivement ouverte à la circulation ont été très satisfaisantes; elles se sont élevées à 216,100 fr. pour 40 milles de longueur de trajet, pendant les dix-sept dernières semaines finissant au 10 décembre, soit en moyenne 264 fr. par mille et par semaine. Le 14 décembre, 28 milles nouveaux ont été mis en exploitation, ce qui porte à 75 milles la longueur totale du chemin exploité. Les travaux du Central-Argentin se poursuivent aussi avec activité.  
ERNEST DOTTAIN.

shared ngram:  
“Malgré  
cette guerre, le  
mouvement”

Courrier du  
Canada, 16  
February 1866

Journal des débats,  
26 january 1866

Malgré cette guerre, le mouvement commercial et industriel est très actif à Buenos-Ayres, à Rio Janeiro et à Montevideo. Les meilleures nouvelles nous parviennent de toutes les provinces de la république Argentine; le grand chemin de fer du Sud a été entièrement livré au trafic; les recettes réalisées sur la partie primitivement ouverte à la circulation ont été très satisfaisantes; elles se sont élevées à 216,100 fr. pour 40 milles de longueur de trajet, pendant les dix-sept dernières semaines finissant au 10 décembre, soit en moyenne 264 fr. par mille et par semaine. Le 14 décembre, 28 milles nouveaux ont été mis en exploitation, ce qui porte à 75 milles la longueur totale du chemin exploité. Les travaux du Central-Argentin se poursuivent aussi avec activité.



# Everything is viral

Wien, 16. März.

Lange haben wir Anstand genommen, an die Möglichkeit eines über dem zu Gastein geschaffenen Provisorium zwischen Österreich und Preußen entbrennenden Conflictes zu glauben. Auch heute noch scheint es uns ein geradezu wahnfremdes Beginnen, wenn die Politik des Grafen Bismarck im Ernst den Versuch machen sollte, die Entscheidung in Schleswig-Holstein auf die Spitze des Schwertes zu stellen, und nicht blos als Österreicher, sondern auch als Deutsche vermögen wir nur mit Grauen und Entsetzen der verhängnisvollen Folgen eines solchen Conflictes zu gedenken. Aber die Lage ist ernst, sehr ernst geworden, nicht weil in Österreich und Preußen die Truppen in Bewegung gesetzt werden, nicht weil die öffentliche Meinung allerwärts in Deutschland auf das tiefste erregt ist, sondern weil es dem Grafen Bismarck mehr und mehr zu gelingen scheint, den König selbst für seine Pläne zu gewinnen und dessen Persönlichkeit in einer Streitfrage zu engagieren,

On lit dans la *Nouvelle Presse libre* du 16 mars :

« Nous avons longtemps hésité à croire qu'un conflit pût éclater entre l'Autriche et la Prusse à la suite de la convention de Gastein. Aujourd'hui encore cela nous semble de la folie de la part de M. de Bismarck de vouloir trancher la question des duchés par le glaive. Néanmoins nous devons reconnaître que la situation devient très sérieuse.

« Ce ne sont pas les préparatifs militaires qu'on fait en Prusse et en Autriche ni l'agitation générale de l'Allemagne qui nous inspirent cette croyance; mais nous voyons que M. de Bismarck réussit de plus en plus à gagner le roi Guillaume à ses plans. Il y a quinze jours, le roi de Prusse était encore placé au-dessus des partis de son cabinet, et, après avoir entendu des avis divers dans le conseil du 28 février, il se réserva de prendre une décision par lui-même.

An article of the *Neue Freie Presse* of Vienna (17 March) on the Austro-Prussian war

Translated in the *Journal des débats* (21 March)

International news

Conflit austro-prussien.

On lit dans la *Nouvelle Presse libre* de Vienne :

« Nous avons longtemps hésité à croire qu'un conflit pourrait éclater entre l'Autriche et la Prusse à la suite de la convention de Gastein. Aujourd'hui encore, cela nous semble de la folie de la part de M. de Bismarck de vouloir trancher la question des Duchés par le glaive. Néanmoins, nous devons reconnaître que la situation devient très sérieuse. Ce ne sont pas les préparatifs militaires qu'on fait en Prusse et en Autriche, ni l'agitation générale de l'Allemagne qui nous inspirent cette croyance. Mais nous voyons que M. de Bismarck réussit de

Reprinted in the *Courrier du Canada* (11 April)



# Everything is viral

FEUILLETON DU JOURNAL DES DEBATS  
DU 4 SEPTEMBRE 1866.

LES BONNES FORTUNES  
PARISIENNES.

Les Amours d'un notaire.

(Voir les Numéros des 28, 29 et 30 août.)

IX.

Une fois dans le lieu saint, M<sup>e</sup> Loulou prit une mine recueillie dont je ne l'aurais pas crue capable. Elle me donna de l'eau bénite, se mit à genoux sur le pavé, et pria avec une singulière ferveur. Cette grande église me reportait à l'église de ma petite ville où j'avais prié si souvent un côte de ma mère. Je m'appuyai sur un pilier, et je restai tout entier dans mes souvenirs.

J'en fus tiré par la main de M<sup>e</sup> Loulou.  
— Tu as envie de pleurer; retiens-toi, les hommes doivent avoir du courage.

Et elle ajouta :

— Sais-tu pour qui j'ai prié? C'est pour ta maman.

Dieu me le pardonnera; mais je pris la chère enfant dans mes bras et je l'embrassai devant lui.

— Je crois, me dit-elle, que nous som-

mes très bons tous les deux, et que nous aurions pu être frère et sœur pour tout à fait.

Quand nous sortimes de l'église, M<sup>e</sup> Loulou me dit :

— Raconte-moi encore ta maman.

Et quand elle m'eut écouté :

— Je ne sais pas bien pourquoi je n'ai pas eu de maman, me dit-elle, ni de papa. Il paraît que j'ai été orpheline tout de suite; c'est M<sup>e</sup> la directrice qui m'a élevée; ce n'est pas une mauvaise femme, mais cela ne doit pas être la même chose. J'ai une tante à Dresden, qui envoie quelquefois des petits cadeaux à madame pour moi, mais elle n'est pas aussi amusante que ton oncle. Tout ce qu'il me dis de ton oncle m'amuse beaucoup.

Nous nous promenâmes longtemps dans les rues. M<sup>e</sup> Loulou me raconta son éducation et ses débuts: elle avait eu beaucoup de mal; une fois elle s'était cassé la jambe parce qu'un truc avait manqué sous elle; une autre fois on l'avait siéffée; évidemment le sifflet lui était resté sur le cœur plus que la jambe cassée.

C'était une cabale d'une grande danseuse jalouse, me dit-elle.

M<sup>e</sup> Loulou s'arrêta à toutes les boutiques. Elle s'acheta de l'eau de Cologne chez le vrai Farina et m'en donna un flacon.

Il faut que nous sentions bon pendant la route, me dit-elle, et puis après, s'il nous en reste, quand nous ouvrirons nos bouteilles, cela nous rappellera que nous sommes très bons tous les deux, et que nous aurions pu être frère et sœur pour tout à fait.

— Je crois, me dit-elle, que nous som-

mes très bons tous les deux, et que nous aurions pu être frère et sœur pour tout à fait.

Quand nous sortimes de l'église, M<sup>e</sup> Loulou me dit :

— Raconte-moi encore ta maman.

Et quand elle m'eut écouté :

— Je ne sais pas bien pourquoi je n'ai pas eu de maman, me dit-elle, ni de papa. Il paraît que j'ai été orpheline tout de suite; c'est M<sup>e</sup> la directrice qui m'a élevée; ce n'est pas une mauvaise femme, mais cela ne doit pas être la même chose. J'ai une tante à Dresden, qui envoie quelquefois des petits cadeaux à madame pour moi, mais elle n'est pas aussi amusante que ton oncle. Tout ce qu'il me dis de ton oncle m'amuse beaucoup.

Nous nous promenâmes longtemps dans les rues. M<sup>e</sup> Loulou me raconta son éducation et ses débuts:

elle avait eu beaucoup de mal; une fois elle s'était cassé la jambe parce qu'un truc avait manqué sous elle; une autre fois on l'avait siéffée; évidemment le sifflet lui était resté sur le cœur plus que la jambe cassée.

Il faut que nous sentions bon pendant la route, me dit-elle, et puis après, s'il nous en reste, quand nous ouvrirons nos bouteilles, cela nous rappellera que nous sommes très bons tous les deux, et que nous aurions pu être frère et sœur pour tout à fait.

J'en fus tiré par la main de M<sup>e</sup> Loulou.

— Tu as envie de pleurer; retiens-toi, les hommes doivent avoir du courage.

Et elle ajouta :

— Sais-tu pour qui j'ai prié? C'est pour ta maman.

Dieu me le pardonnera; mais je pris la chère enfant dans mes bras et je l'embrassai devant lui.

— Je crois, me dit-elle que nous sommes très bons tous les deux, et que nous aurions pu être frère et sœur pour tout à fait.

Quand nous sortimes de l'église, M<sup>e</sup> Loulou me dit :

— Raconte-moi encore de ta maman.

Et quand elle m'eut écouté :

— Je ne sais pas bien pourquoi je n'ai pas eu de maman, me dit-elle, ni de papa. Il paraît que j'ai été orpheline tout de suite; c'est M<sup>e</sup> la directrice qui m'a élevée; ce n'est pas une mauvaise femme, mais cela ne doit pas être la même chose. J'ai une tante à Dresden, qui envoie quelquefois des petits cadeaux à madame pour moi, mais elle n'est pas aussi amusante que ton oncle. Tout ce qu'il me dis de ton oncle m'amuse beaucoup.

Nous nous promenâmes longtemps dans les rues. M<sup>e</sup> Loulou me raconta son éducation et ses débuts: elle avait eu beaucoup de mal; une fois elle s'était cassé la jambe parce qu'un truc avait manqué sous elle; une autre fois on l'avait siéffée; évidemment le sifflet lui était resté sur le cœur plus que la jambe cassée.

cassée.

— C'était une cabale d'une grande danseuse jalouse, me dit-elle.

M<sup>e</sup> Loulou s'arrêta à toutes les boutiques. Elle s'acheta de l'eau de Cologne chez le vrai Farina et m'en donna un flacon.

— Il faut que nous sentions bon pendant la route, me dit-elle, et puis après, s'il nous en reste, quand nous ouvrirons nos bouteilles, cela nous rappellera que nous avons été à Cologne. Il ne faudra jamais l'oublier. Je suis très contente me dit-elle, d'avoir laissé tomber Cocotte; sans cela, nous ne nous serions peut-être pas parlé, car en voyage je suis très fière, et je ne dis jamais rien à personne; et comme cela n'a pas fait de mal à Cocotte, cela nous a toujours valu notre amitié.

Quand nous sortimes de l'église, M<sup>e</sup> Loulou me dit :

— Raconte-moi encore de ta maman.

Et quand elle m'eut écouté :

— Je ne sais pas bien pourquoi je n'ai pas eu de maman, me dit-elle, ni de papa. Il paraît que j'ai été orpheline tout de suite; c'est M<sup>e</sup> la directrice qui m'a élevée; ce n'est pas une mauvaise femme, mais cela ne doit pas être la même chose. J'ai une tante à Dresden, qui envoie quelquefois des petits cadeaux à madame pour moi, mais elle n'est pas aussi amusante que ton oncle. Tout ce qu'il me dis de ton oncle m'amuse beaucoup.

Nous nous promenâmes longtemps dans les rues. M<sup>e</sup> Loulou me raconta son éducation et ses débuts: elle avait eu beaucoup de mal; une fois elle s'était cassé la jambe parce qu'un truc avait manqué sous elle; une autre fois on l'avait siéffée; évidemment le sifflet lui était resté sur le cœur plus que la jambe cassée.

(A CONTINUER.)

*Les Amours d'un notaire* of Pierre-Jules Hetzel in the *Journal des débats* (4 September).

Serial novels

Reprinted (without attribution) by the *Gazette de Sorel* (8 December)



# Everything is viral

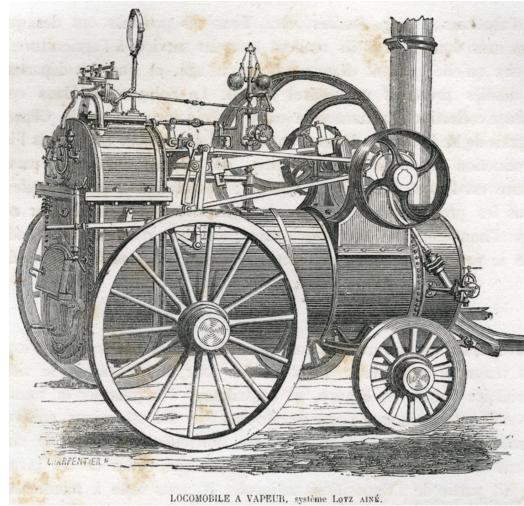
— Nous avons parlé dernièrement d'une locomotive construite pour marcher sur les routes ordinaires, et qui, partie de Nantes en traînant à sa remorque un certain nombre de voitures, est arrivée à Paris, après avoir effectué son trajet dans les meilleures conditions.

Ce premier essai de locomotion au moyen de la vapeur sur les voies publiques sera bientôt suivi d'essais analogues, car on nous parle, dit *le Moniteur*, d'une nouvelle voiture qu'on verra prochainement circuler dans les rues de Paris concurremment avec nos voitures de place.

Ce véhicule, inventé par un ingénieur auquel on doit un grand nombre de créations nouvelles, a la forme d'un fiacre ordinaire, à part l'avant-train, dans lequel sera placée une petite chaudière; cet avant-train sera précédé d'une cinquième roue, roue directrice, au moyen de laquelle le conducteur pourra tourner ou oblier à discrédition, et dont l'usage doit enfin donner un démenti à cet ancien dicton qu'on appliquait à quiconque était inutile : « Il sert comme une cinquième roue à un carrosse. »

The trial of an experimental "car" in  
the *Journal des débats* (22  
September)

Scientific and technical news



— Les journaux ont parlé d'une locomotive construite pour marcher sur les routes ordinaires, et qui, partie de Nantes, en trainant à sa remorque un certain nombre de voitures, est arrivée à Paris après avoir effectué son trajet dans les meilleures conditions. Ce premier essai de locomotion au moyen de la vapeur sur les voies publiques sera bientôt suivi d'essais analogues, car on parle d'une nouvelle voiture qu'on verra prochainement circuler dans les rues de Paris, concurremment avec les voitures de place. Ce véhicule, inventé par un ingénieur auquel on doit déjà un grand nombre de créations nouvelles, a la forme d'un fiacre ordinaire, à part l'avant-train dans lequel sera placée une petite chaudière; cet avant-train sera précédé d'une cinquième roue, roue directrice, au moyen de laquelle le cocher pourra tourner ou oblier à discrédition, et dont l'usage doit enfin donner un démenti à cet ancien dicton qu'on appliquait à quiconque était inutile : *Il sert comme la cinquième roue à un carrosse.*

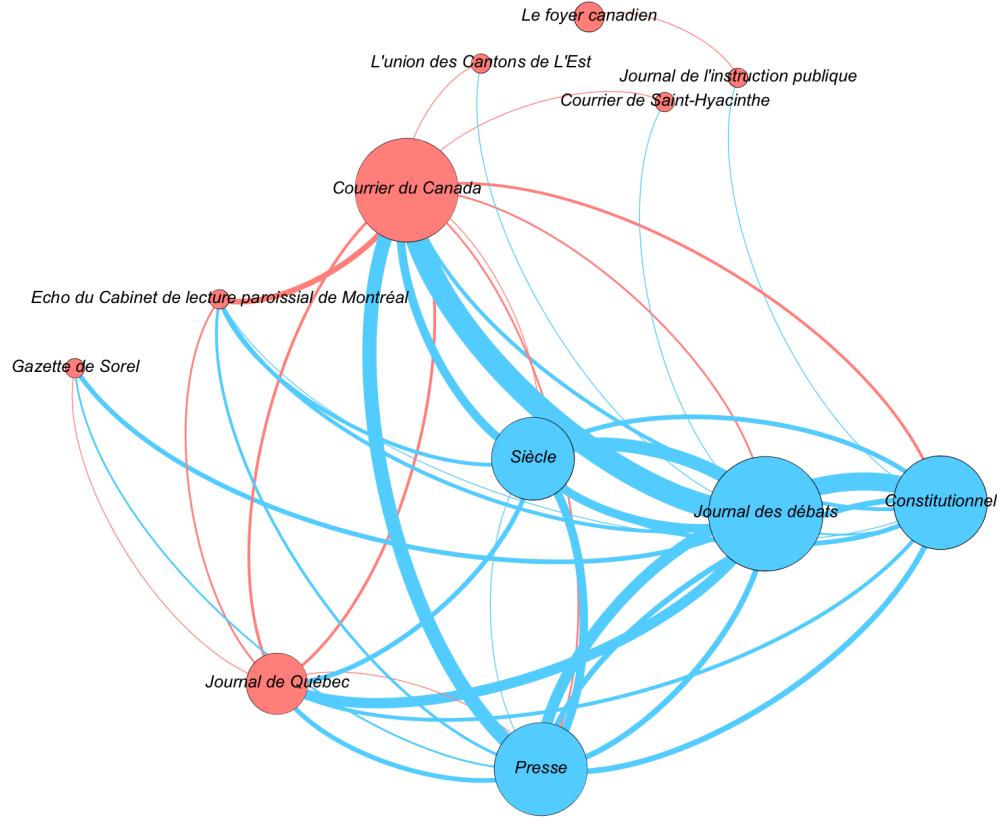
Reprinted in the *Écho du cabinet de lecture paroissial* (15 October)



# Mapping transatlantic networks

A network visualisation shows that some newspapers are key intermediaries: the *Courrier du Canada* in Québec, the *Journal des débats* in France

Network of “influential” newspapers (those that have been republished)

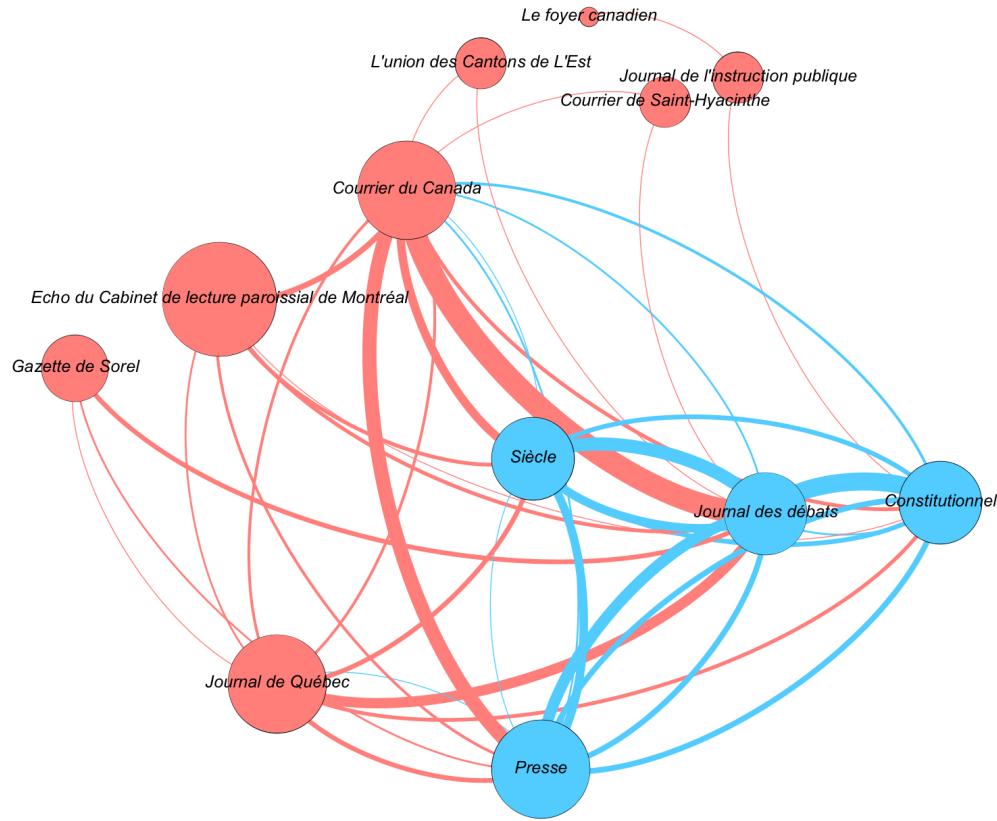




# Mapping transatlantic networks

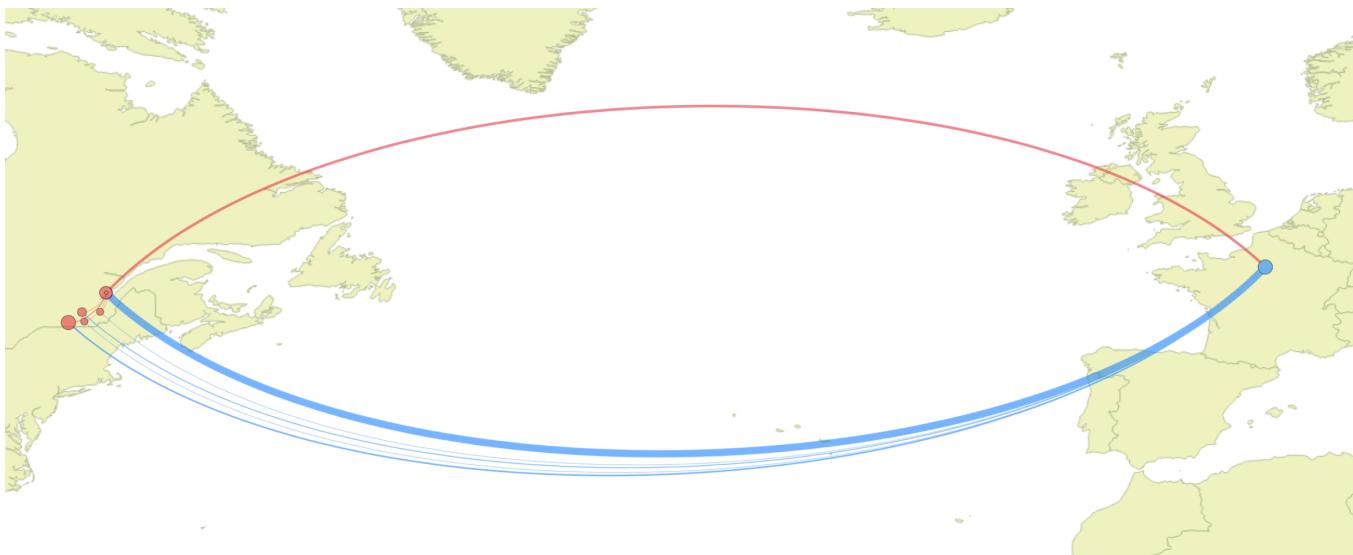
A network visualisation shows that some newspapers are key intermediaries: the *Courrier du Canada* in Québec, the *Journal des débats* in France

Network of “influential” newspapers (those that have been republished)





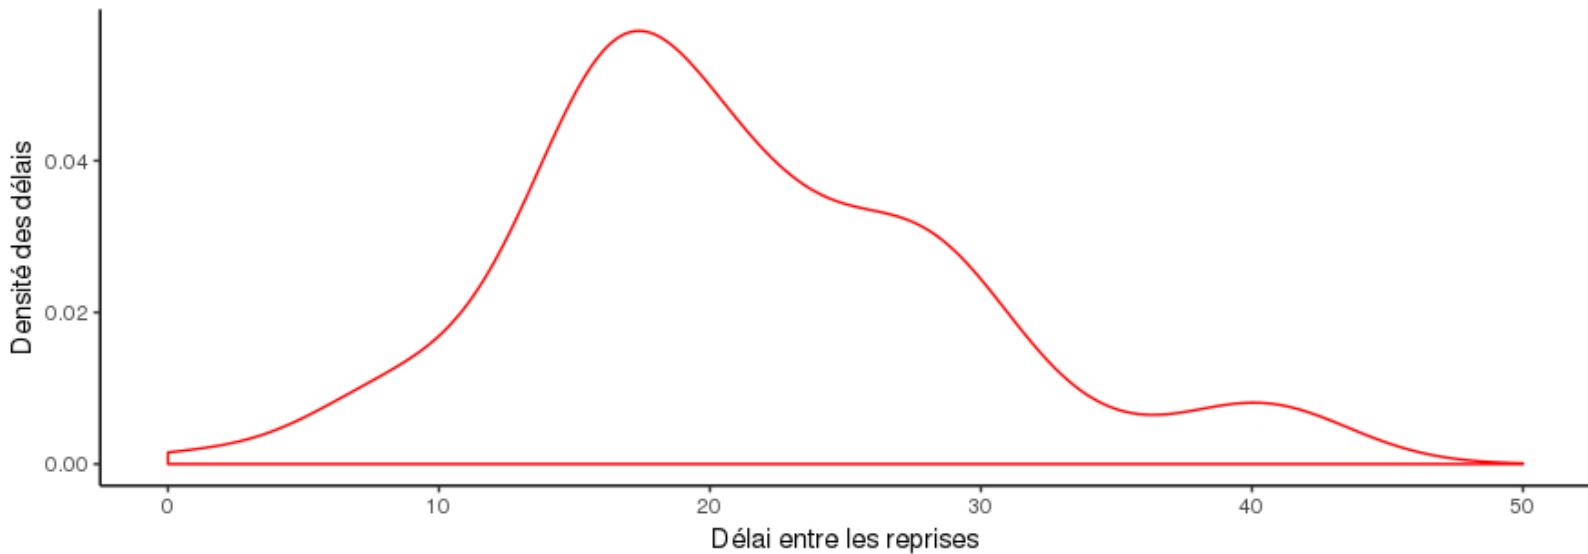
# Mapping transatlantic networks



A geographic look at our network: news from France tends to arrive first in Québec and then to ship on the Saint-Laurent all the way till Montréal.



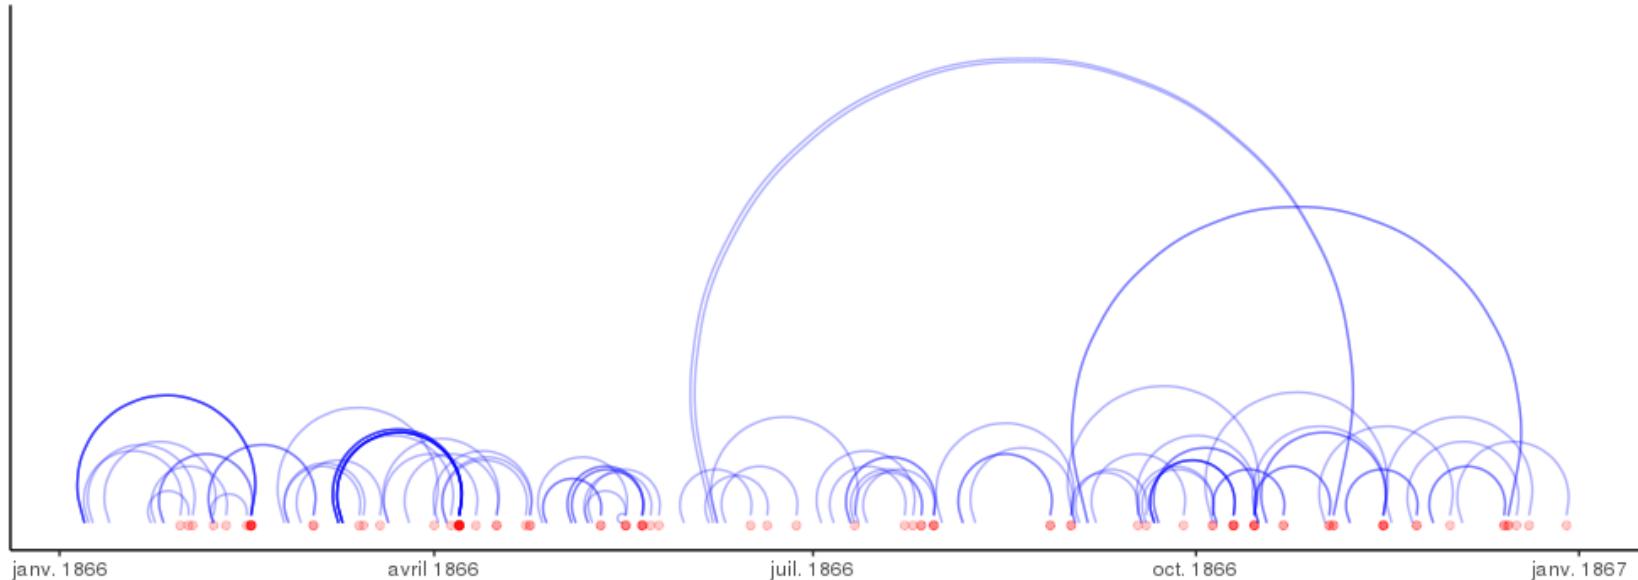
# The Mechanics of reprinting “flows”



The leading factor of reprinting in 1866: steamers. Most reprinting occur within 12 to 20 days, the standard time of transatlantic crossing.



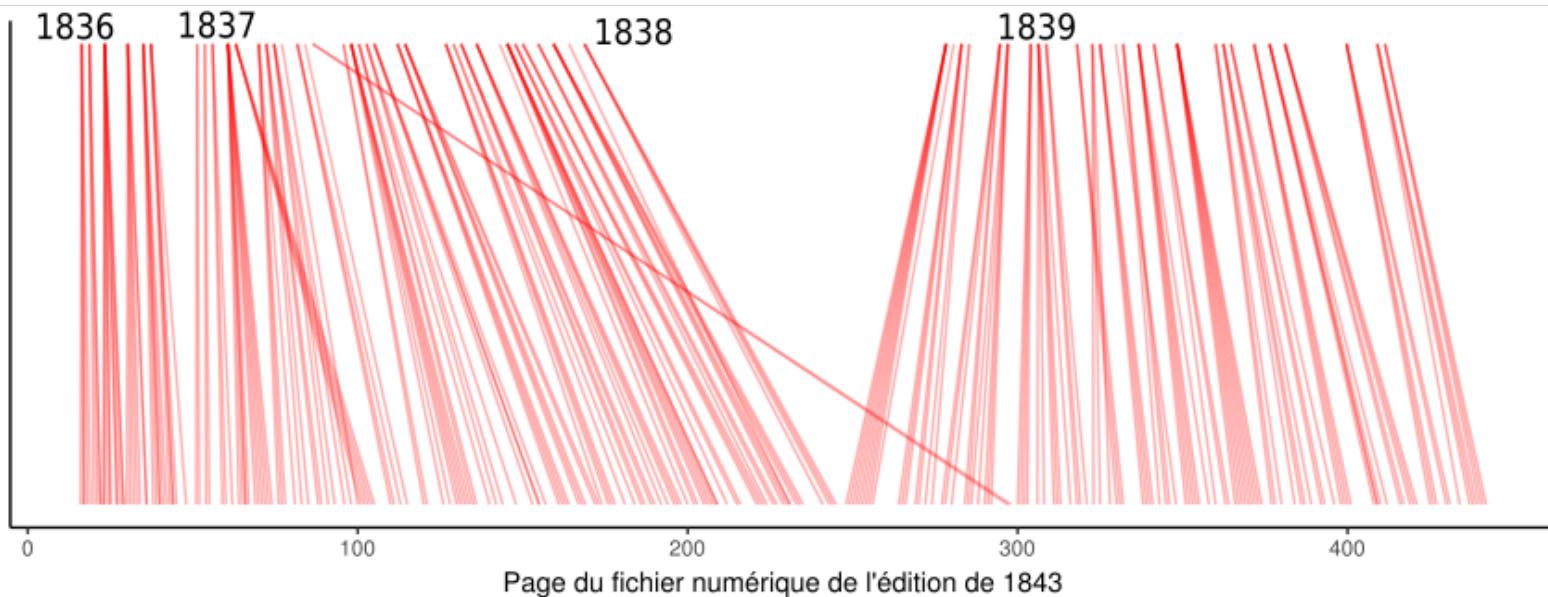
# The Mechanics of reprinting “flows”



Although they may come from different dates, reprintings usually occur in clusters (red points), which agrees with the maritime rhythms of the 1866 global media system.



# Virality beyond newspaper: from articles to book



In the XIXth century French journalists very frequently publish collections of their articles. A variation of *Viral Text* algorithm allows to uncover this mechanism of republication that alter widely the original text.



# Virality beyond newspaper: from articles to book



The viral analysis of book publication can also help to identify some pseudonyms. Émile de Girardin reused extensively the texts published under the pen name A. Fagnan.





# Virality beyond one language

Currently all the virality analysis we lead are limited to French-speaking press, but viral networks are clearly not limited to one language, especially not in locations with a high level of cross-linguistic contact like Canada or Switzerland.

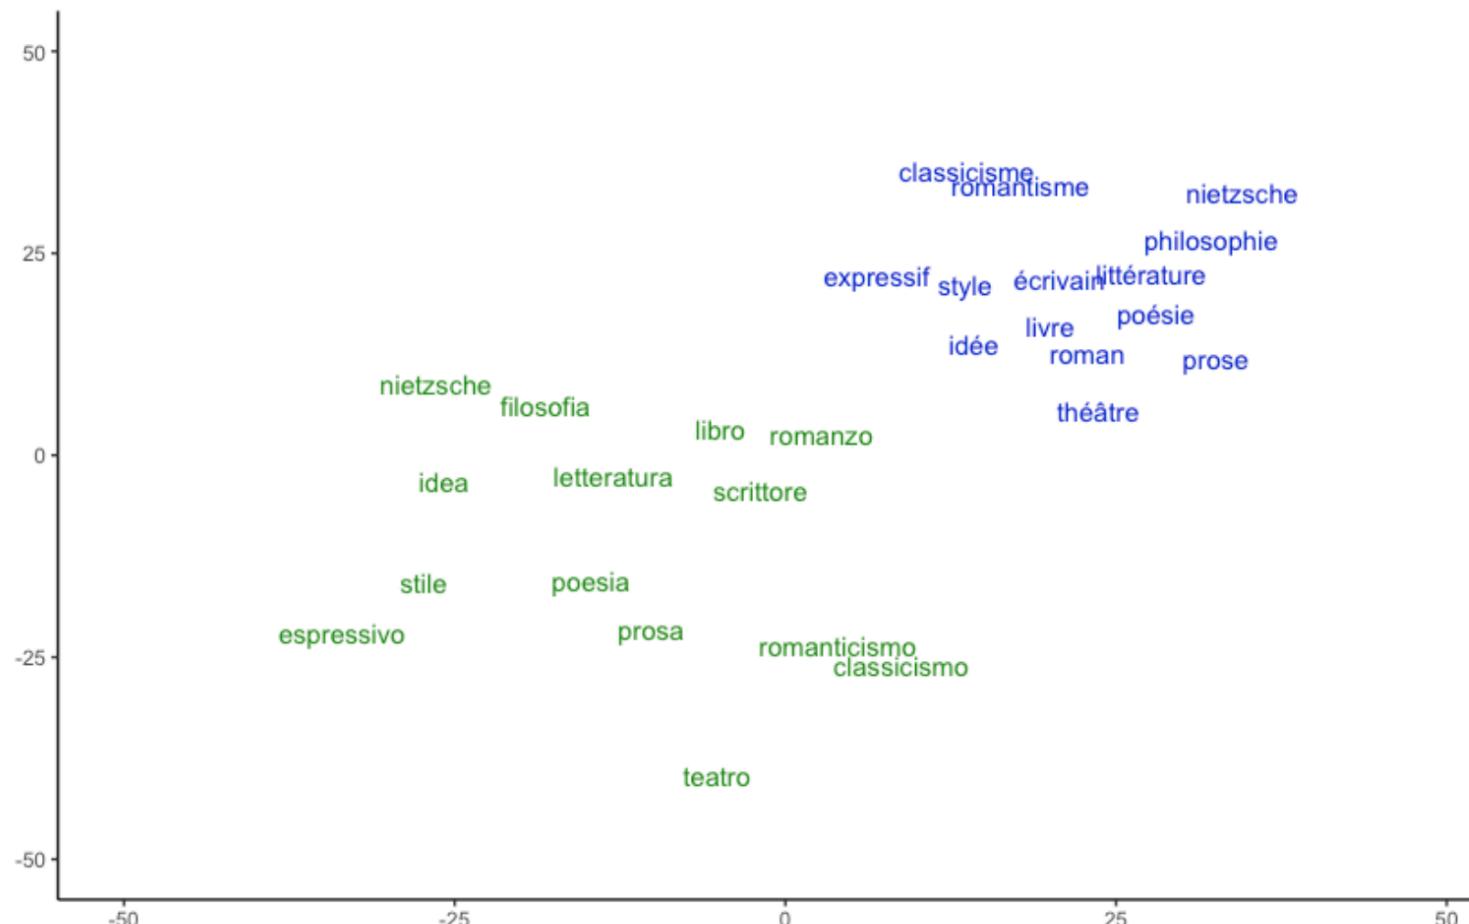
The key difficulty is methodological: most text mining approaches are based on lexical forms. Yet, between two languages most concepts will be expressed using different forms and, most of the time, they would not even exactly match.

An emerging techniques, word embeddings may partly circumvent this issue, by encoding all the neighbor relationships of each word. Since word embeddings in different languages will likely produce a similar network of relationships, a proper alignment may suffice to bring different languages to the same semantic ground.



## Projection des vecteurs de mots en deux dimensions

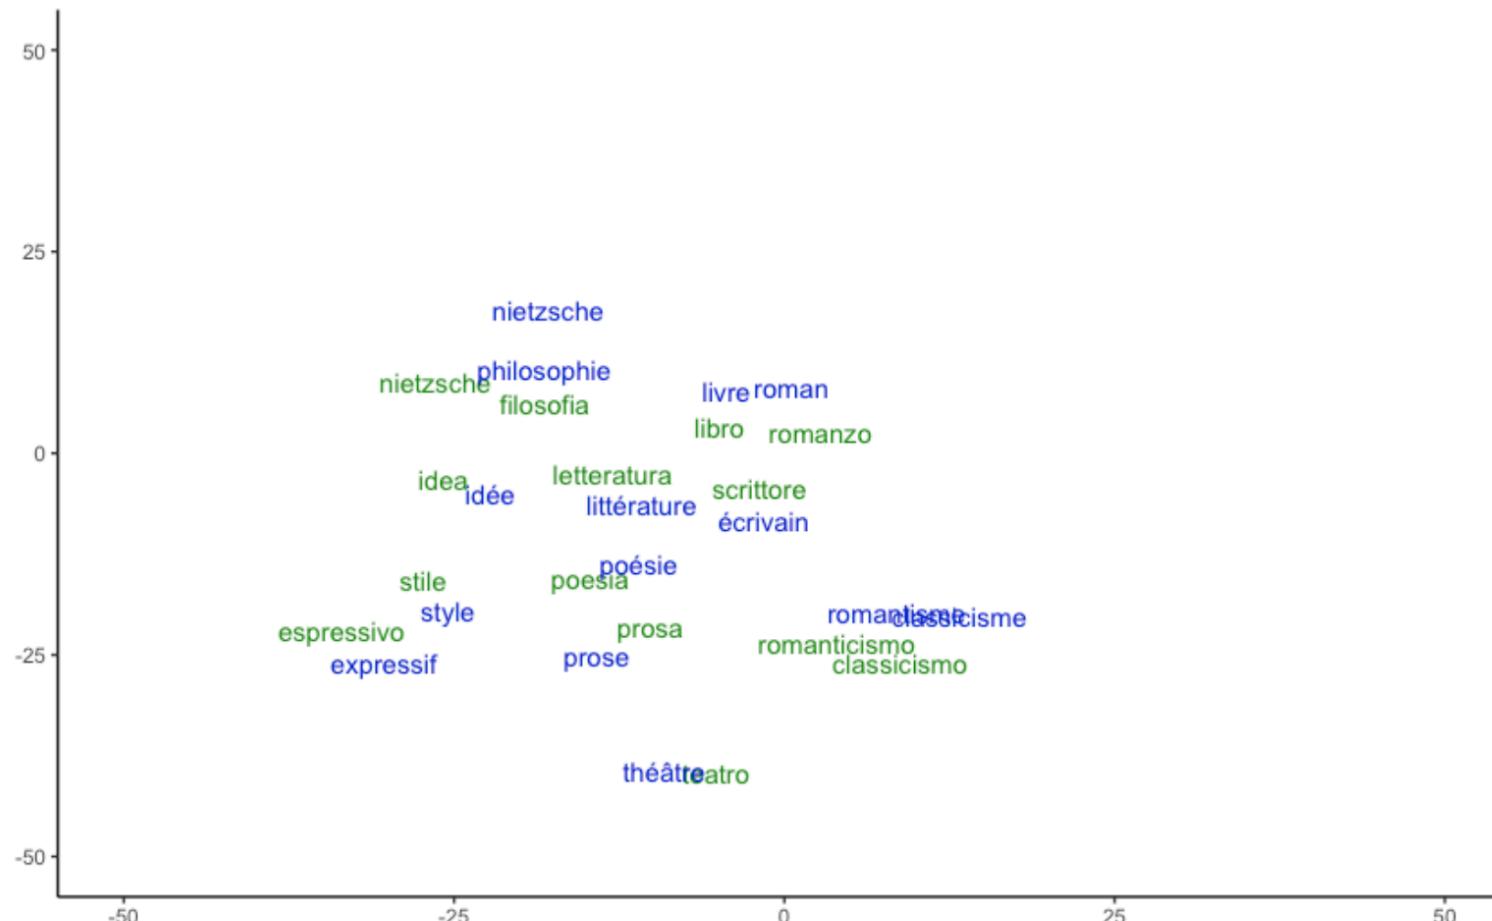
Vecteurs français et italiens non corrigés





## Projection des vecteurs de mots en deux dimensions

Vecteurs français corrigé et vecteurs italiens



# Virality beyond one language

```
> wordVectors::nearest_to(italian_vectors, french_vectors_corrected[["écrivain"]], 30)
  scrittore letterato romanziere artista prosatore novelliere poeta critico
  0.2621570 0.3841533 0.3859421 0.3908917 0.3972127 0.4074836 0.4565549 0.4661891
drammaturgo pensatore illustratore opera sociologo merito umorista contemporaneo
  0.4715974 0.4720035 0.4786143 0.4867049 0.4892099 0.4922769 0.5020004 0.5022718
  oltralpe spregiudicato pittore filosofo ingegno apprezzato descrittore divulgatore
  0.5041421 0.5042614 0.5084535 0.5108349 0.5113975 0.5132561 0.5147991 0.5170232
florilegio anconitano diciottesimo intervistare tradotto colto
  0.5207816 0.5213351 0.5219895 0.5220205 0.5253177 0.5259511

> wordVectors::nearest_to(italian_vectors, french_vectors_corrected[["revue"]], 30)
  rassegna rivista mensile quindicina letteraria giugno pubblicare fascicolo
  0.3976879 0.4218748 0.4366481 0.4576961 0.4646905 0.4724801 0.4768679 0.4778350
  apr preussische settimanale periodico pubblicazione sociali articolo maggio
  0.4809541 0.4913233 0.4923484 0.4925884 0.4955149 0.4974714 0.5004570 0.5068495
ebdomadario barth casini losanna settembre rundschau revue intervistare
  0.5080657 0.5089233 0.5096743 0.5136988 0.5171027 0.5180243 0.5214868 0.5261398
  ediz amy vitalia marzo aprile arie
  0.5300317 0.5301265 0.5304097 0.5304164 0.5363001 0.5386583
```

Une utilité immédiate : repérer dans le corpus des mots qui sont appelés de la même manière qu'un concept français (avec des associations trop contextuelles pour figurer dans un dictionnaire)



# Virality beyond newspapers: the need for a map.

Networks of reprints raised a whole new series of unresolved issues:

- What are the determining technical factors of circulation in a given context: steamers, telegraphs, trains, horses, pneumatics?
- How to account for the recurrent textual flow between some newspapers? Is this only the incidental result of informal scissors-and-paste? Or, is this the consequence of explicit partnerships?
- How reprinting happens? What pieces of the copied content is kept, permuted, rewritten, joined with other texts? All of this would require innovative tools to deal with automated philological analysis.



# Virality beyond newspapers: the need for a map.



## 5. The Numapresse database...

A bridge between the social and textual nature of newspapers?



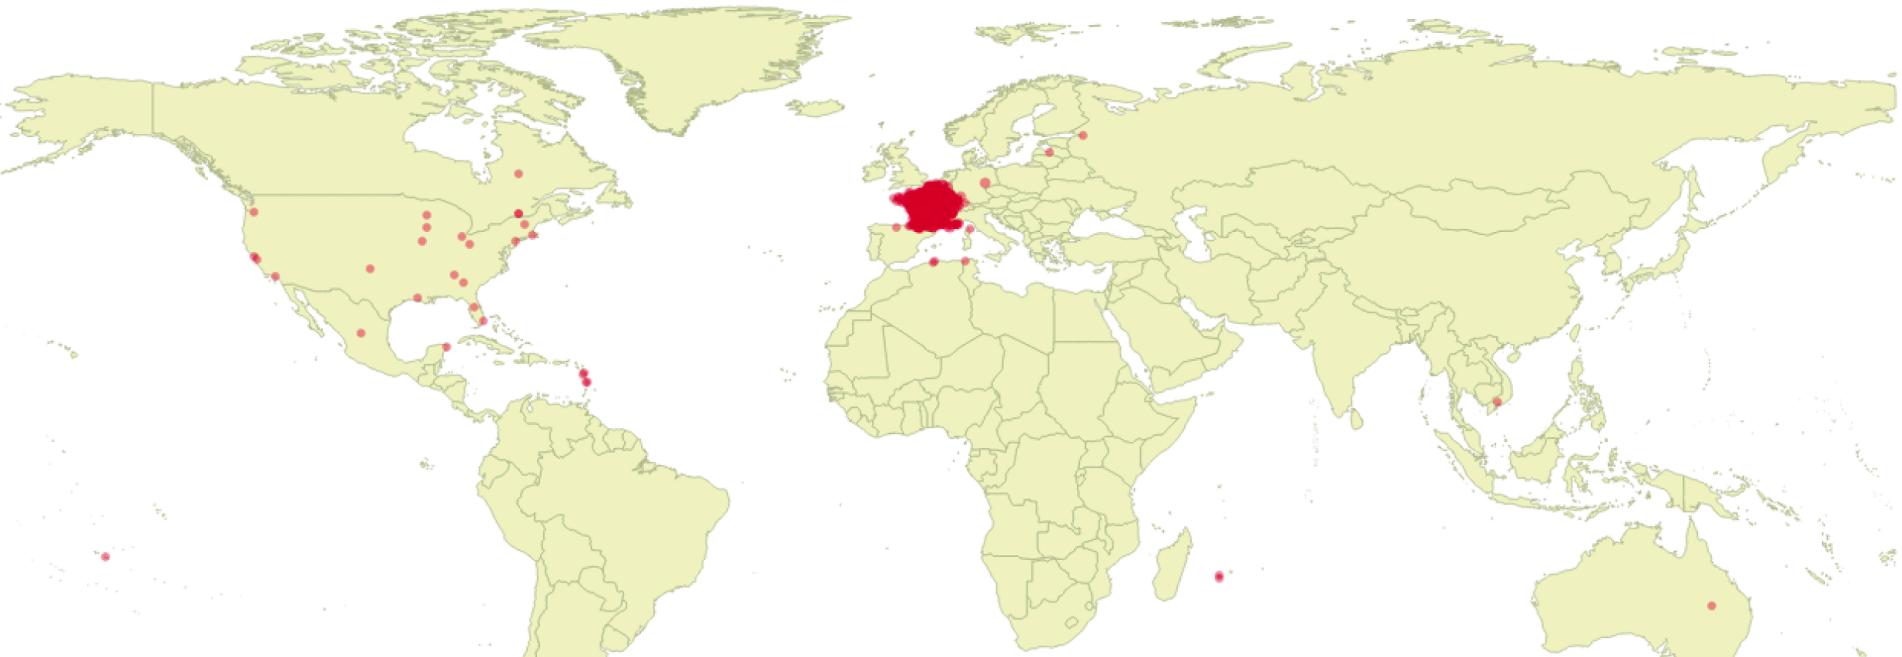
# Building on bibliographic data

The Numapresse database is currently developed by Olivier Lapointe. It initially aims to connect several distinct databases on French media and journalists.

- **The Ramseyer Database:** an unpublished collection of 50 000 pseudonyms used in the French press by Patrick Ramseyer (BNF).
- **Data BNF:** the leading bibliographic database in France. About 40,000 author records (from 2 millions) are explicitly linked to a journalists activities (for instance “journaliste” in the short bio).
- Specialized databases on the history of French news, such as **Petite Presse** or **Medias19**.



# Building on bibliographic data



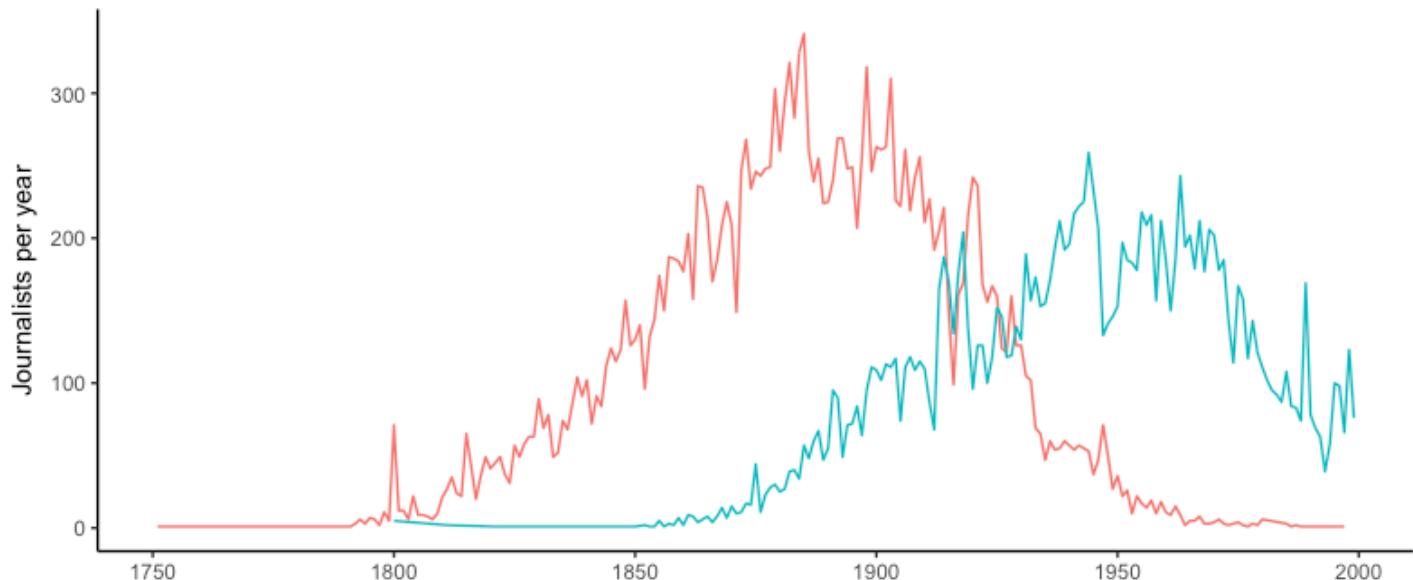
The French-speaking press in 1866



# Building on bibliographic data

Birth and death of journalists in the Ramseyer base

(the graph only applies to journalists whose birth and death dates are known at least with a year-level precision)



Source: The Ramseyer Database



# From a journalist index to a global repository

While initially conceived as a metadata-only service, the Numapresse database is starting to integrate text as well.

- **Metadata is *in* the text:** signatures, reprints and automated parsing of biographical information can extend the database beyond the focus of the existing sources (especially to avoid losing Guibert)
- **The text is significantly enriched:** OCR errors aside, the progress of text mining techniques would probably allow at some point to generate a TEI-like format for each article.
- **A lot of text can be put there.** Hosting by Humanum lifts a lot of concerns over size limitations.



# The Numapresse database

In its latest stage, the database host a wide array of interconnect objects (actors, events, places...) and texts (productions, ressources)

## LA BASE

Accueil / La base

La base de données « Numapresse » regroupe des informations concernant des productions culturelles, des acteurs, des lieux, des prix et récompenses et des événements associés à ce champ d'activité. Pour vous orienter au sein de cette base de données, vous pouvez consulter [le guide d'utilisation](#). L'Atelier « Numapresse » offre quant à lui la possibilité d'explorer les données de la base de diverses façons : frises chronologiques, graphes et tableaux, cartes géographiques, etc.

 ACTEURS  15615 fiches	 ANNOTATIONS  3601 fiches	 ÉTIQUETTES  3111 fiches	 ÉVÉNEMENTS  25241 fiches
 LIEUX  3 fiches	 PRIX  0 fiches	 PRODUCTIONS  35795 fiches	 RESSOURCES  6948 fiches



# The Numapresse database

In its latest stage, the database host a wide array of interconnect objects (actors, events, places...) and texts (productions, ressources)

## GIRARDIN, ÉMILE DE

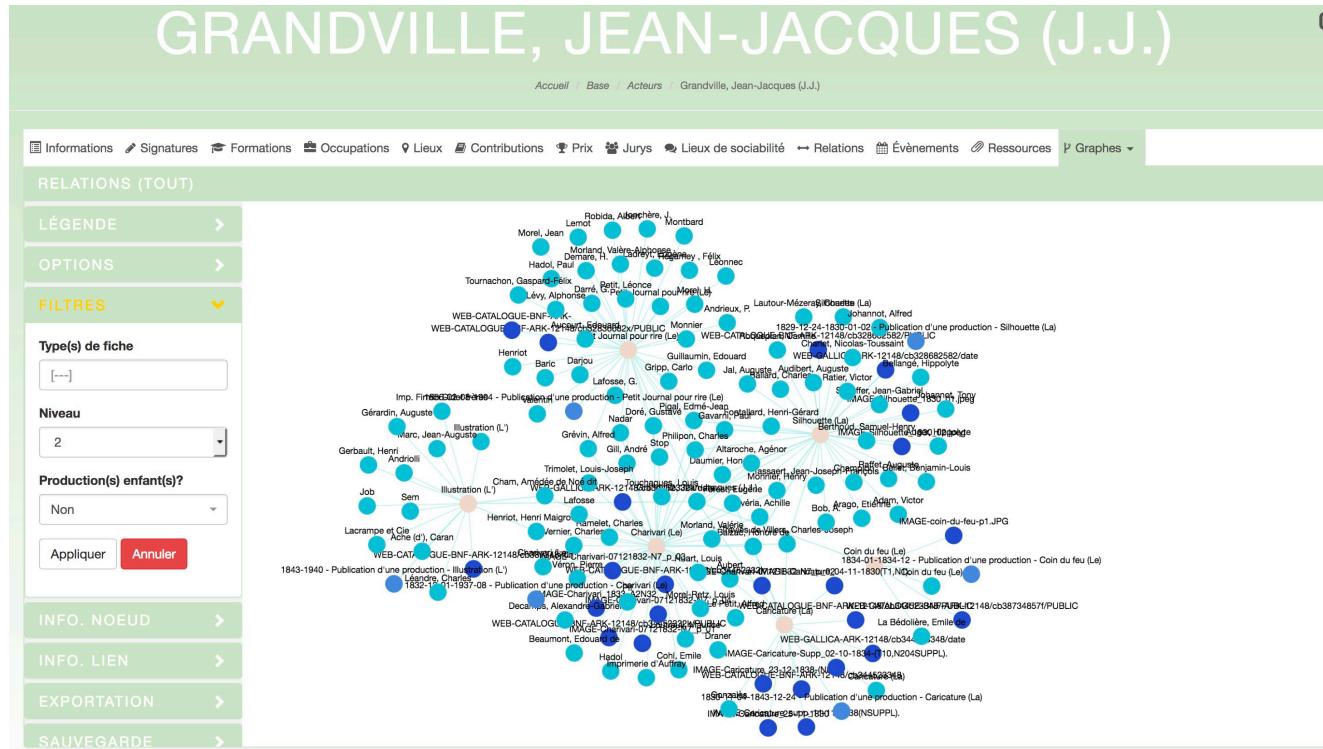
Accueil / Base / Acteurs / Girardin, Émile de

Graphes ▾

Début ↕	Fin ↕	Lieu	Secteur	Sous-secteur	Occupation	Occupation - Détail	Organisme(s)	Actions
AAAA-MM-J.	AAAA-MM-	[--]	[--]	[--]	[--]	[--]	[--]	[i]
[--]	[--]	[--]	Médias	Journaux	Associé	[--]	<ul style="list-style-type: none"><li>Silhouette (La) (Organisme)</li></ul>	[i]
3 oct. 1829	19 janv. 1831	[--]	Médias	Journaux	Directeur	[--]	<ul style="list-style-type: none"><li>Mode (La) (Organisme)</li></ul>	[i]
oct. 1831	1848	[--]	Médias	Journaux	Directeur	[--]	<ul style="list-style-type: none"><li>Journal des connaissances utiles (Organisme)</li></ul>	
3 oct. 1833	juin 1836	[--]	Médias	Journaux	Directeur	[--]	<ul style="list-style-type: none"><li>Musée des familles (Organisme)</li></ul>	[i]
juin 1836	1866	[--]	Médias	Journaux	Directeur de publication	[--]	<ul style="list-style-type: none"><li>Presse (La) (Organisme)</li></ul>	

# The Numapresse database

Since the database is bound to include a wide array of interconnections, Olivier Lapointe has created dataviz views, such as networks, that ease significantly the identification of collaborations or sociability links





# The Numapresse database

Thanks to an extensive collaborative work, the *Chat noir* has served as an experimental test to integrate the complete text metadata of a periodic.

**CHAT NOIR (LE), 14 JANVIER 1882, « LIVRAISON DU 1882-01-14 »**

Accueil / La base / Productions / Chat noir (Le), 14 janvier 1882, « Livraison du 1882-01-14 »

Informations Contributeurs Évènements Annotations Productions Productions enfants Ressources Graphes ▾

Article de périodique

Illustration (Livraison de périodique)

Date ↓↑	Titre	Référence bibliographique ↓↑	Sous-type(s)	Statut	Actions
AAAA-À					
14 janv. 1882	[Réclame]	ANONYME, « [Réclame] », dans « Livraison du 1882-01-14 », <i>Chat noir (Le)</i> , 14 janvier 1882, p. 4.	Réclame	Incomplète	
14 janv. 1882	Ballade du Chat Noir	Fulbert, Florent (Florent Fulbert), « Ballade du Chat Noir », dans « Livraison du 1882-01-14 », <i>Chat noir (Le)</i> , 14 janvier 1882, p. 4.	Poème en vers	Incomplète	
14 janv. 1882	Voyages de découvertes	Goudeau , Émile (A'Kempis), « Voyages de découvertes », dans « Livraison du 1882-01-14 », <i>Chat noir (Le)</i> , 14 janvier 1882, p. 2-3.	Récit de voyage	Incomplète	
14 janv. 1882	Les Polonais - Fragment d'un poème épique	Goudeau , Émile (Émile Goudeau ), « Les Polonais - Fragment d'un poème épique », dans « Livraison du 1882-01-14 », <i>Chat noir (Le)</i> , 14 janvier 1882, p. 2.	Poème en vers	Incomplète	
14 janv. 1882	Théâtres	Goudeau , Émile (Odio), « Théâtres », dans « Livraison du 1882-01-14 », <i>Chat noir (Le)</i> , 14 janvier 1882, p. 4.	Chronique théâtrale	Incomplète	
14 janv. 1882	Montmartre	Privé, Clément (Jacques Lehardy), « Montmartre », dans « Livraison du 1882-01-14 », <i>Chat noir (Le)</i> , 14 janvier 1882, p. 1.	Programme	Incomplète	



# The Numapresse database

All the documents enriched by Numapresse could also serve to generate well-defined corpora — such as all the serial novels published by Jean de la Hire in the *Matin* in 1911

Génération de corpus Numapresse

Récupérer l'ensemble des articles correspondant à une requête

[Conseils de recherche](#)

Tous ces mots    Jean de la Hire    in    Signature de l'article

ET    Cette phrase exacte    Mystère des XV    in    Texte complet

[+ Ajouter des champs complémentaires](#)

Restreindre la recherche à:

Période de publication: Durant l'année ou après    1911

Forme journalistique      Titre

<b>Roman-feuilleton</b>	<b>Le Matin</b>
Reportage	Le Petit Journal
Vie politique	Le Petit Parisien
Bourse	L'Intransigeant
Programme radio	Le Figaro
Carnet	L'Humanité
Publicité (annonce)	Le Journal des débats
Sport	Excelsior

**Récupérer le corpus**

# Conclusion

